

多阶段对齐的残差势能投影框架

从 KL-RLHF 闭式解到 Posterior Cumulant 景观递推

统一 LLM 对齐与扩散 / Flow Matching 后微调

Abstract

本文给出多阶段微调的统一数学框架。多阶段 **RLHF** / **SFT** / **FM** 后微调是一个”目标势能 – 当前势能 – 可达投影 – 路径投影 – 景观递推”的过程。要点如下：

- (1) 以累计对齐势能 $A_n := \log(dP_n/dP_0)$ 把残差 reward 写成精确命题；
- (2) 两座桥把工程对象接入 KL 框架：SFT 经由 *inverse RLHF* (密度比诱导 reward)，FM 经由 *path-KL* 投影进入路径空间；
- (3) 从局部线性化定义投影算子 $\Pi_{\mathcal{H}_{n+1}}^{M_n, \lambda}$ ，用 LoRA 方向级可达性 χ_k 刻画低秩约束；
- (4) 平滑边缘上的势能递推取 posterior log-moment generating function (cumulant 展开) 的形式；
- (5) Jet-FM 扰动训练作用在 FM 投影阶段的几何度量上，不改变 Gibbs target。

核心递推： $A_{n+1}(z) = A_n(z) + \eta_{n+1} \Pi_{\mathcal{H}_{n+1}}^{M_n, \lambda}[U_{n+1}^*(z) - A_n(z)] + \mathcal{E}_{n+1}(z)$,

其中 z 可为 LLM 输出 (c, y) 或扩散状态 x ； $\mathcal{E}_{n+1}$ 收集非线性、有限步、采样误差。

Contents

1	结论的三层分级	4
2	基本对象	4
3	KL-RLHF 的严格残差形式	5
3.1	Gibbs 闭式解	5
3.2	残差 reward 的精确命题	6
4	桥一：SFT / 数据微调作为 Inverse RLHF	6
4.1	密度比 reward	6
4.2	社区数据与用户数据的势能	7
5	桥二：FM 回归作为 Path-KL 投影	7
5.1	路径空间 KL	7
5.2	确定性 FM 的桥：vanishing-noise 与 transport-action	8
6	可训练子空间与投影算子	8
6.1	局部线性化	9
6.2	可达函数空间	9
7	核心递推	10
7.1	线性叠加何时成立	10
7.2	路径依赖	10

8	平滑边缘上的景观递推	10
8.1	Reweight-then-smooth 与 smooth-then-reweight 不交换	10
8.2	Cumulant 展开	10
8.3	景观曲率递推	11
9	Posterior Score Covariance 的正确位置	11
9.1	高斯混合 Hessian 分解	11
9.2	Probability Flow Jacobian 的稳健表述	11
9.3	进入训练递推的路径	11
10	谱坐标下的可达性递推	11
11	对齐税	12
12	Jet-FM / 扰动训练的位置	13
12.1	扰动 $\approx$ Sobolev 投影	13
13	多阶段中每一阶段改变了什么	13
14	四条核心命题	14
15	第一部分小结：无条件框架	14
16	联合条件测度与 fiberwise gauge	14
16.1	对象：一族条件分布，提升为联合测度	14
16.2	Fiberwise gauge：归一化是每个 fiber 上的约束	15
17	条件切空间与残差	15
17.1	切空间：残差是条件密度流的切向量	15
17.2	残差：自动吸收 fiberwise 归一化	15
18	条件残差投影递推（主递推）	16
19	无条件 / 对比分解	16
19.1	caption-invariant 子空间	16
20	Prompt 可控性：干预响应算子	17
21	Caption dropout ：腐化通道与互信息	17
22	架构： Jacobian range 与投影交换子	18
22.1	firewall = 投影交换子近似为零	18
22.2	SDXL / FLUX 的区别是可测命题	18
23	可辨识性： caption σ -代数与识别算子	19
24	衰退矩阵 = 三算子的组合	20
25	两阶段对齐税与交叉项	21
26	条件扩散 / Flow Matching ：文本作为静态变量	22
27	统一主定理	22
27.1	对象词典	24
27.2	框架的逻辑链	24

1 结论的三层分级

本文给出的所有结论并非同一种“真”。它们分属三层：精确恒等式、局部二阶近似、经验假设 / 可测诊断。三层的成立条件、可证伪性、以及“无条件成立”的资格各不相同。把不同层的结论混为一谈——尤其把第二、三类当作第一类来引用——是整个框架最主要的 over-claiming 来源。为避免这一点，后文每一个 boxed 结论都标注其所属层级；凡第二类与第三类结论，其成立都显式附带所需假设。读者在引用任一结论时，应先确认它属于哪一层，以及对应假设是否在当前工程语境下满足。

第 1 类 精确恒等式 (exact identities)。只要陈述中声明的测度条件（绝对连续性、目标势能存在、fiber 归一化、Girsanov 可积性等）成立，这类结论无条件成立，是定义与变分计算的直接后果，不依赖任何线性化或近似。典型例子：KL-RLHF 的 Gibbs 闭式解 (5) 及其残差 reward 形式 (Thm. 3.1)；条件 fiber 上的归一化约束 (fiberwise gauge)；reweight-then-smooth 给出的 posterior log-MGF (25)（在零时刻指数倾斜的设定下，这是恒等式而非近似）。此类结论一旦前提满足即不可证伪——它们是框架的骨架。

第 2 类 局部二阶近似 (local 2nd-order approximations)。这类结论并非恒等式，其成立需要附带显式假设：局部线性化有效、步长足够小、被作用对象足够正则、且优化在最优解附近收敛。脱离这些假设，结论的误差由 $\mathcal{E}_{n+1}$ 收集而不再可控。典型例子：把有限模型 / LoRA 训练写成可达更新 $h = J_n \delta\theta$ 的投影形式 (18)（依赖 $A_{\theta_n+\delta\theta} \approx A_n + J_n \delta\theta$ ）；把 FM 损失解释为 path-KL 的二次型 (13)（依赖 Girsanov 条件与 $\sigma(t)^{-2}$ 权重对齐）；把 Jet-FM 扰动训练解释为速度 + Jacobian 的 Sobolev 正则 (37)、(39)（依赖 $O(\varepsilon^3)$ 截断）。引用此类结论时，必须同时声明上述近似前提。

第 3 类 经验假设 / 可测诊断 (empirical assumptions / measurable diagnostics)。这类陈述涉及具体数据、架构、训练机制的实际行为，原则上不能写成无条件定理，只能作为可证伪的假设或可测量的诊断量给出。它们的“真”由实验在给定 Q, S, J_n 下检验，而非由推导保证。典型例子：caption dropout 增大 caption-invariant floor 上的泄漏比例 (Prop. 21.2，作为互信息单调性下的经验命题)；FLUX 比 SDXL 更易把特征写成 prompt-不可约的 floor (Prop. 22.2，写成可测的泄漏分数与交换子范数排序，而非定理)。此类结论的价值在于可测、可证伪；把它们陈述为普遍定理即构成 over-claiming。

Remark 1.1 (分级标注约定)。后文各节将其 boxed 核心结论显式归入上述三层之一。约定：第一类结论直接给出；第二类结论在叙述时随附其线性化 / 小步长 / 正则性 / 近最优假设；第三类结论以“经验假设”或“可测命题”的措辞出现，并指明对应的诊断算子（如泄漏分数 L_S 、交换子范数 κ_S 、识别算子 $\mathcal{I}_Q$ ）。同一对象在不同假设强度下可跨层移动：例如 *posterior cumulant* 递推在恒等式层 (log-MGF) 成立，但其只取 κ_1 项的“ $K_{n+1} = K_n + \eta \nabla^2 r$ ”写法降为第二类近似。

2 基本对象

令生成对象为 z 。在语言模型中 $z = (c, y)$ ；在图像生成模型中 $z = x_0$ 或整条路径 $X_{0:1}$ 。

给定基座分布 P_0 ，第 n 阶段后的模型分布为 P_n 。假设 $P_n \ll P_0$ 。

Definition 2.1 (累计对齐势能)。

$$A_n(z) := \log \frac{dP_n}{dP_0}(z). \quad (1)$$

A_n 不是 reward，而是模型从 P_0 到 P_n 的全部累计 **log-density** 偏移，记录了前面所有 SFT、RLHF、DPO、LoRA、FM 后微调共同刻入的分布性变化。初始条件 $A_0 \equiv 0$ 。

Caveat 2.2 (绝对连续性与参考测度)。定义 (1) 中的 $A_n = \log(dP_n/dP_0)$ 预设了绝对连续性 $P_n \ll P_0$ ，即 Radon-Nikodym 导数 dP_n/dP_0 存在且几乎处处有限。该前提对离散对象（LLM 的 $z = (c, y)$ ，token 序列上的计数测度）自动成立，但在以下三类生成空间中并不自动成立：

- 连续图像空间 $z = x_0 \in \mathbb{R}^d$: *post-finetuning* 可将质量搬移到 P_0 的低维支撑之外, 得到与 P_0 互奇异 (*mutually singular*) 的 P_n , 此时 dP_n/dP_0 不存在。
- 路径空间 $z = X_{0:1}$: 不同漂移诱导的路径测度仅在 *Girsanov* 条件 (同一扩散系数、漂移差落在 *Cameron–Martin* 方向) 下互相绝对连续; 扩散系数被改动时即互奇异。
- 确定性 flow 设定: P_n 为某可逆映射 T_n 的 *push-forward* $(T_n)_\# P_0$, 整体集中在测度零的图像集上, 相对 P_0 无密度。

故 $A_n = \log(dP_n/dP_0)$ 仅在 $P_n \ll P_0$ 成立时为良定义的精确恒等式。补救之道有二, 记于定义 2.3: 其一为固定一个公共参考测度 μ 使各阶 $P_n \ll \mu$; 其二为退到光滑边缘 $P_{n,t} = P_n K_t$ (卷积平滑核 K_t), 后者使一切势能良定义, 与 *caveat 4.2* 的平滑化处理一致。本框架的所有恒等式均应在此意义下理解。

Definition 2.3 (公共参考测度下的势能). 固定一个 σ -有限的公共参考测度 μ , 使得对所有阶 n 有 $P_n \ll \mu$ 。定义公共参考势能

$$A_n^\mu(z) := \log \frac{dP_n}{d\mu}(z)$$

其中 $dP_n/d\mu$ 为 P_n 关于 μ 的 *Radon–Nikodym* 导数。等价地, 可仅在光滑边缘 $P_{n,t} = P_n K_t$ 上以 $B_{n,t}(x) = \log(p_{n,t}/p_{0,t})(x)$ 定义势能 (见 *caveat 4.2*), 二者皆良定义于上述前提之下。

Remark 2.4. 原始累计势能 $A_n = \log(dP_n/dP_0)$ 是 $\mu = P_0$ 的特例: 当 $P_n \ll P_0$ 时 $A_n^{P_0} = A_n$, 初始条件 $A_0^{P_0} \equiv 0$ 亦相容。一般 μ 下初始势能 $A_0^\mu = \log(dP_0/d\mu)$ 不必为零; 它仅充当统一的规范基点 (*gauge*), 残差势能 $G_{n+1} = U_{n+1}^* - A_n$ 中的 μ -依赖项在相减时抵消, 故下游构造对 μ 的选取不变。

Remark 2.5. 本定义为第一类 (*definitional / exact*, 精确恒等式), 但其良定义性以绝对连续性假设 $P_n \ll \mu$ 为条件: 在该假设下 A_n^μ 是 μ -a.e. 唯一确定的精确对象; 假设失效 (互奇异或确定性映射) 时则须退至光滑边缘表述。

Definition 2.6 (目标势能与残差势能). 若第 $n+1$ 阶段存在理想目标分布 Q_{n+1}^* 且 $Q_{n+1}^* \ll P_0$, 定义:

$$U_{n+1}^*(z) := \log \frac{dQ_{n+1}^*}{dP_0}(z), \quad (2)$$

$$G_{n+1}(z) := U_{n+1}^*(z) - A_n(z). \quad (3)$$

G_{n+1} 是残差势能——当前模型到目标还差多少。

3 KL-RLHF 的严格残差形式

3.1 Gibbs 闭式解

以 P_n 为 reference 的 KL-regularized alignment:

$$P^* = \arg \max_P \{ \mathbb{E}_P[R(z)] - \beta \text{KL}(P \| P_n) \}. \quad (4)$$

标准变分计算给出:

$$\frac{dP^*}{dP_n}(z) \propto \exp(R(z)/\beta). \quad (5)$$

因此:

$$\log \frac{dP^*}{dP_0}(z) = A_n(z) + \frac{R(z)}{\beta} + \text{const.} \quad (6)$$

3.2 残差 reward 的精确命题

若希望本阶段的理想终点是 Q_{n+1}^* , 即 $\log(dQ_{n+1}^*/dP_0) = U_{n+1}^*$, 则由 (6):

$$\boxed{\frac{R_{n+1}^{\text{ideal}}(z)}{\beta_{n+1}} = U_{n+1}^*(z) - A_n(z) = G_{n+1}(z)} \quad (7)$$

Theorem 3.1 (残差 reward 定理). 若第 $n+1$ 阶段的目标是把 P_n 推向 Q_{n+1}^* (相对于 P_0 定义), 则以 P_n 为 *reference* 的 *KL-RLHF ideal reward* 必须等价于目标势能与当前势能之差。这不是无条件成立的递推, 而是在“存在绝对目标势能 U^* ”这一建模假设下的精确命题。

Remark 3.2 (步长系数的标定). 此处须澄清一处约定差异, 以与 (7) 及递推节中的条件 (C4) 保持一致。残差的归一化方式直接决定理想一步更新的匹配系数 η_i 。

若把第 i 阶段的逐阶段残差定义为已除以温度的量

$$g_i := R_i/\beta_i = U_i^* - A_{i-1},$$

则理想一步更新为

$$A_i = A_{i-1} + g_i, \quad \text{即 } \eta_i = 1.$$

此时 g_i 已自带 $1/\beta_i$ 的归一化, 匹配系数恒为 1。

系数 $\eta_i = 1/\beta_i$ 仅当残差以未除温度的 *reward* R_i 本身书写时才出现, 因为此时须在更新中显式补回 $1/\beta_i$ 才能复原 g_i 。

故递推节 (22) 中“线性叠加”条件 (C4) 之所以写作 $\eta_i = 1/\beta_i$, 正是因为那里的残差携带的是 R_i (而非 R_i/β_i); 两套约定在残差归一化固定之后完全一致, 二者描述的是同一恒等式。此为第一类 (*bookkeeping identity*), 无任何近似成分。

4 桥一: SFT / 数据微调作为 Inverse RLHF

4.1 密度比 reward

监督微调通常最小化 $\min_{\theta} \text{KL}(Q_{\mathcal{D}} \| P_{\theta})$, 其中 $Q_{\mathcal{D}}$ 是数据分布。若 $Q_{\mathcal{D}} \ll P_0$, 定义数据诱导势能:

$$U_{\mathcal{D}}(z) := \log \frac{dQ_{\mathcal{D}}}{dP_0}(z). \quad (8)$$

令 $R_{\mathcal{D}}^{(\beta)}(z) := \beta U_{\mathcal{D}}(z)$ 。代入 Gibbs 解 (5) (以 P_0 为 *reference*):

$$\frac{dP^*}{dP_0}(z) \propto \exp(U_{\mathcal{D}}(z)) = \frac{dQ_{\mathcal{D}}}{dP_0}(z),$$

故 $P^* = Q_{\mathcal{D}}$ 。

Proposition 4.1 (Inverse alignment bridge). *SFT* 的 *population optimum* 可被反解释为 *KL-RLHF* 的 *Gibbs optimum*。有限模型下, 实际 *SFT* 是该 *target* 在模型族中的 *KL* 投影。这不是狭义“人类反馈”, 而是数据诱导的 **KL** 分布对齐。

Caveat 4.2 (经验分布的平滑化). 若 $Q_{\mathcal{D}}$ 是有限样本经验分布 $\hat{q}_N = \frac{1}{N} \sum_i \delta_{x^{(i)}}$, 则 $\log(dQ_{\mathcal{D}}/dP_0)$ 不良定义。必须先引入平滑核 $K_t(x | z)$, 定义平滑边缘 $Q_{\mathcal{D},t}(x) = \int K_t(x | z) Q_{\mathcal{D}}(dz)$, 再讨论 *score*、*Hessian* 与 *posterior cumulant*。这一步是将经验数据接入连续几何的必要桥梁。

Remark 4.3 (*SFT* 是目标生成器, 而非一次 *RLHF* 执行). 须把 *Prop. 4.1* 读得更锐利: *SFT* 本身并不“执行”一次 *KL-RLHF* 步骤, 它只供给一个 *target* 分布 $Q_{\mathcal{D}}$ 。式 (8) 的 $U_{\mathcal{D}} = \log(dQ_{\mathcal{D}}/dP_0)$ 是相对 *base* 的绝对势能; 只有在 $Q_{\mathcal{D}}$ 给定之后, 才能把它相对当前模型 P_n 重读为一个 *residual*

$$\log \frac{dQ_{\mathcal{D}}}{dP_n}(z) = U_{\mathcal{D}}(z) - A_n(z),$$

并进一步 *center* 到切空间、投影到可达子空间，方才对应一次真正的 *alignment* 更新。换言之， Q_D 是 *reward* 的生成器，而非 *reward* 的施加；*inverse-RLHF* 恒等式给出的是“若以此 Q_D 为终点则等价的理想 *reward*”，不是数据已被写入 P_n 的断言。

在连续空间须再补一层有限样本的桥梁。经验测度

$$\hat{Q}_D = \frac{1}{N} \sum_i \delta_{z_i}$$

一般对 P_0 无密度（支撑在零测集上），故 $\log(d\hat{Q}_D/dP_0)$ 不良定义，残差无从谈起。须先按 *Cav. 4.2* 用平滑核 $K_t(x|z)$ 卷积，得 $\hat{Q}_{D,t} = \hat{Q}_D K_t$ ，定义平滑后的边缘势能

$$U_{D,t}(x) := \log \frac{d\hat{Q}_{D,t}}{dP_{0,t}}(x),$$

其中 $P_{0,t} = P_0 K_t$ ；随后才形成可良定义的 *residual* $\log(dQ_{D,t}/dP_{n,t})$ ，再 *center*、投影、传入一次局部可训练更新（即 $\eta \Pi_{\mathcal{H}_{n+1}}^{M_n, \lambda}$ 作用于该 *residual*）。整链可显式写成

$$\underbrace{\hat{Q}_D = \frac{1}{N} \sum_i \delta_{z_i}}_{\text{finite data}} \Rightarrow \underbrace{\hat{Q}_{D,t} = \hat{Q}_D K_t}_{\text{smoothed target}} \Rightarrow \underbrace{\log \frac{dQ_{D,t}}{dP_{n,t}}}_{\text{residual / current model}} \Rightarrow \underbrace{\eta \Pi_{\mathcal{H}_{n+1}}^{M_n, \lambda}}_{\text{local update}}.$$

分层标注。*inverse-RLHF* 恒等式 $U_D = \log(dQ_D/dP_0)$ （及 *Prop. 4.1* 的 *population optimum* 反解释）是第一类（精确恒等式），但仅在 $Q_D \ll P_0$ 时成立；有限样本到平滑 *target* 的 *bridge*（ $\hat{Q}_D \rightsquigarrow \hat{Q}_{D,t}$ 与 $U_{D,t}$ 的引入）是第二类（局部二阶近似），其精度受核宽 t 与样本数 N 共同支配，并把误差并入 $\mathcal{E}_{n+1}$ 。

4.2 社区数据与用户数据的势能

社区全量微调（inverse RLHF₁）：

$$U_{\text{com}}(z) = \log \frac{dQ_{\text{com}}}{dP_{\text{base}}}(z). \quad (9)$$

用户后微调（inverse RLHF₂，以 P_{com} 为 reference）：

$$R_{\text{user}}(z)/\beta_2 = U_{\text{user}}^*(z) - A_1(z), \quad A_1 = \log \frac{dP_{\text{com}}}{dP_{\text{base}}}. \quad (10)$$

若二者都是精确密度比且模型族无限，则两阶段望远镜式抵消，终点即 Q_{user} 。保留非平凡交互时，*reward* 是由数据、偏好、训练机制共同诱导的偏好势能，它一般不等于精确密度比。

5 桥二：FM 回归作为 Path-KL 投影

5.1 路径空间 KL

给定目标分布 Q^* ，选择 interpolant 或扩散桥得到路径测度 Q^{path} ，边缘为 Q_t ， $t \in [0, 1]$ 。设：

$$Q : dX_t = u_Q(X_t, t) dt + \sigma(t) dW_t, \quad (11)$$

$$P_\theta : dX_t = v_\theta(X_t, t) dt + \sigma(t) dW_t. \quad (12)$$

在 Girsanov 条件下：

$$\text{KL}(Q^{\text{path}} \| P_\theta^{\text{path}}) = \text{boundary term} + \frac{1}{2} \int_0^1 \mathbb{E}_{Q_t} [\|\sigma(t)^{-1}(u_Q - v_\theta)\|^2] dt. \quad (13)$$

若边界分布固定，boundary term 对 θ 是常数。因此：

$$\theta^* = \arg \min_{\theta} \text{KL}(Q^{\text{path}} \| P_\theta^{\text{path}}) \quad (14)$$

Caveat 5.1 (FM 损失与 path-KL 的对应条件). 标准 FM 损失 $\int \mathbb{E}_{Q_t} \|u_Q - v_\theta\|^2 dt$ 只有在 $\sigma(t)$ 常数或损失权重已吸收 $\sigma(t)^{-2}$ 时, 才与 *path-KL* 严格一致。

Remark 5.2 (严谨的桥链). 不能直接说 *reward-KL* 给出 FM 目标。完整链条是:

$$KL\text{-}RLHF / \text{inverse } RLHF \Rightarrow Q^* \Rightarrow Q^{\text{path}} \Rightarrow \text{path-KL projection} \Rightarrow FM \text{ regression}.$$

5.2 确定性 FM 的桥: vanishing-noise 与 transport-action

(13) 的 Girsanov 推导依赖共同的扩散系数 $\sigma(t)$ 。当 $\sigma(t) \rightarrow 0$, 即纯确定性 ODE 时, path-KL 桥不再直接成立。

Caveat 5.3 (确定性 FM 不直接是 path-KL). 考虑确定性流 $dX_t = v_\theta(X_t, t) dt$ ($\sigma \equiv 0$)。两个不同 drift $v_\theta \neq u_Q$ 一般诱导互相奇异 (*mutually singular*) 的路径测度: 其支撑集为不同的确定性轨迹族, Radon-Nikodym 导数不存在, $KL(Q^{\text{path}} \| P_\theta^{\text{path}})$ 取值 $+\infty$ 或无定义。故(14) 的 *path-KL* 投影解释不能原样套用到确定性 FM。此时确定性 FM 在本质上是一个 *dynamic-regression / action-matching / transport-velocity-matching* 问题——对速度场作 $L^2(Q_t)$ 回归——而不是严格意义的 KL 投影。这是第二类警示 (数学结构错配, 需更换几何)。

Proposition 5.4 (两种合法接回方式). 确定性 FM 可通过以下两条路径重新获得变分/投影解释:

(i) *Vanishing-noise* (随机化正则)。对每个 $\epsilon > 0$ 引入加噪流

$$dX_t = v_\theta(X_t, t) dt + \epsilon dW_t, \quad (15)$$

则 $\sigma(t) \equiv \epsilon > 0$ 时路径测度互相绝对连续, Girsanov 适用, 且

$$KL(Q^{\text{path}, \epsilon} \| P_\theta^{\text{path}, \epsilon}) = \text{boundary term} + \frac{1}{2\epsilon^2} \int_0^1 \mathbb{E}_{Q_t} [\|u_Q - v_\theta\|^2] dt.$$

该量虽随 $\epsilon \rightarrow 0$ 发散 (前因子 ϵ^{-2}), 但其极小化方向收敛到确定性速度匹配目标: 在固定权重 $w(t)$ 下, $\arg \min_\theta \int w(t) \mathbb{E}_{Q_t} \|u_Q - v_\theta\|^2 dt$ 在 $\epsilon \rightarrow 0$ 极限处恢复标准 FM 损失。即 FM 回归是 *path-KL* 极小化问题在 *vanishing-noise* 极限下的良定义残余 (第二类, 需正则化解释)。

(ii) *Transport / Benamou-Brenier* 几何。将 FM 直接读作 Wasserstein-2 几何下的速度场投影, 而非 KL 几何下的投影。给定边缘曲线 $(Q_t)_{t \in [0,1]}$, 由连续性方程 $\partial_t Q_t + \nabla \cdot (Q_t u_Q) = 0$ 确定速度场 u_Q (动量通量为 $Q_t u_Q$); FM 损失

$$\int_0^1 \mathbb{E}_{Q_t} [\|u_Q - v_\theta\|^2] dt$$

即 Benamou-Brenier 动作泛函 (*transport-action*) 下、对可达速度场 $v_\theta \in \text{Range}(J_n)$ 的 $L^2(Q_t)$ 正交投影。此处度规 M_n 取 $L^2(Q_t)$ (Wasserstein 切空间内积), 与(18) 的投影算子框架在形式上一致, 仅几何由 KL (Fisher-Rao) 换为 *transport* (Otto)。这是第三类警示 (解释需更换底层几何, 结论仍成立)。

Remark 5.5 (小结). 两条接回方式在 σ 选取下统一: *path-KL* 桥成立于 $\sigma(t) > 0$ (随机化) 或权重已吸收 $\sigma(t)^{-2}$ 的加权路径几何下; 确定性 FM 则需 *vanishing-noise* 极限或 *transport-action* 重读。

FM 桥成立于随机化或加权路径几何下; 确定性 FM 需要 *vanishing-noise* 或 *transport-action* 解释。

6 可训练子空间与投影算子

真实训练不可能直接完成 $A_{n+1} = U_{n+1}^*$ 。需要把理想残差 $G_{n+1} = U_{n+1}^* - A_n$ 投影到可达函数空间。

6.1 局部线性化

设当前参数为 θ_n ，第 $n+1$ 阶段可训练参数子空间为 $S_{n+1} \subseteq \mathbb{R}^d$ （如 LoRA 的 rank- r 子空间）。局部线性化：

$$A_{\theta_n + \delta\theta}(z) \approx A_n(z) + J_n(z) \delta\theta, \quad (16)$$

其中 $J_n(z) := \nabla_{\theta} A_{\theta}(z)|_{\theta_n}$ 是 log-density potential Jacobian。

6.2 可达函数空间

Definition 6.1 (可达函数空间与投影算子). 定义可达函数空间：

$$\mathcal{H}_{n+1} := \{h(z) = J_n(z) \delta\theta : \delta\theta \in S_{n+1}\}. \quad (17)$$

给定由当前模型、数据和优化器诱导的二次度量 M_n (*Fisher* / *NTK* / *loss Hessian* / $L^2(P_n)$)，定义投影：

$$\Pi_{\mathcal{H}_{n+1}}^{M_n, \lambda} G := \arg \min_{h \in \mathcal{H}_{n+1}} \|G - h\|_{M_n}^2 + \lambda \|\delta\theta\|^2. \quad (18)$$

其中 $\lambda \|\delta\theta\|^2$ 吸收了 weight decay、有限步优化的隐式正则、以及 LoRA 秩约束的 Lagrange 对偶。

Definition 6.2 (岭正则线性响应算子). 固定 θ_n 、可训练子空间 S_{n+1} 、Jacobian J_n 、训练度量 M_n 、参数度量 Γ_n 与 *ridge* 权重 $\lambda \geq 0$ 。把残差拟合写成可训练参数 $\delta\theta$ 上的局部二次问题：

$$\delta\theta^* := \arg \min_{\delta\theta \in S_{n+1}} \left\{ \frac{1}{2} \|g_{n+1} - J_n \delta\theta\|_{M_n}^2 + \frac{\lambda}{2} \|\delta\theta\|_{\Gamma_n}^2 \right\}, \quad (19)$$

其残差侧的可达响应 (*reachable response*) 为

$$h_{n+1}^* := J_n \delta\theta^* =: \mathcal{L}_{n+1} g_{n+1}, \quad \mathcal{L}_{n+1} = J_n (J_n^* M_n J_n + \lambda \Gamma_n)^{-1} J_n^* M_n|_{S_{n+1}} \quad (20)$$

称 $\mathcal{L}_{n+1}$ 为由元组 $(J_n, S_{n+1}, M_n, \Gamma_n, \lambda)$ 诱导的岭正则线性响应算子 (*ridge-regularized linear response operator*)，其中 J_n^* 为 J_n 关于 M_n 与 Γ_n 的伴随，逆取为 S_{n+1} 上的 (伪) 逆。 $\mathcal{L}_{n+1}$ 把理想中心化残差 $g_{n+1} \in T_n$ 映为该阶段实际写入 A_n 的、属于可达空间 $\mathcal{H}_{n+1} = \text{Range}(\mathcal{C}_n J_n|_{S_{n+1}})$ 的分量。此为第二类 (局部二阶近似) 刻画：式 (19) 是把训练 *loss* 在 θ_n 处截断到二阶的结果， $\mathcal{L}_{n+1}$ 的解析形式在该近似内为精确恒等式。

Remark 6.3 (为何不是投影). 对 $\lambda > 0$ ， $\mathcal{L}_{n+1}$ 一般不是正交投影：其谱被 *ridge* 压缩到 $(0, 1)$ 内，故

$$\mathcal{L}_{n+1}^2 \neq \mathcal{L}_{n+1}, \quad \mathcal{L}_{n+1} \preceq \text{id (在 } M_n \text{ 内)},$$

即它是一个收缩 (*shrinkage*) 型响应，而非幂等的 *Hilbert* 投影。只有当四个条件同时成立时 $\mathcal{L}_{n+1}$ 才退化为 M_n -正交投影 $\Pi_{\mathcal{H}_{n+1}}$ ：(i) $\lambda = 0$ ；(ii) 值域 $J_n S_{n+1}$ 在 $L^2(P_n)$ 中闭；(iii) 度量 M_n 在该步固定、不随 $\delta\theta$ 漂移；(iv) 拟合确为关于 M_n 的最小二乘投影 ($J_n^* M_n J_n$ 在 S_{n+1} 上可逆)。此时 $\mathcal{L}_{n+1} = \Pi_{\mathcal{H}_{n+1}}$ 幂等，对齐税 (34) 的第二项 (景观移动代价) 恰为零。

因此，本文符号 $\Pi_{\mathcal{H}_{n+1}}^{M_n, \lambda}$ 自此应一律读作此线性响应算子 $\mathcal{L}_{n+1}$ (带 *ridge* 的正则化响应)，而非严格投影；其在 $\lambda = 0$ 极限下与 (18) 的正交投影一致。这样，下游一切递推——核心递推 (22)、条件递推 (49)、以及对齐税 (34)——都自动继承正确解释：写入残差按 $\mathcal{L}_{n+1}$ 收缩，”不可达残差” = $(\text{id} - \mathcal{L}_{n+1})g_{n+1}$ 同时含方向不可达 ($\mathcal{H}_{n+1}^\perp$) 与 *ridge* 抑制 ($\lambda > 0$ 的收缩亏损) 两部分。保留 Π 记号仅为与前文衔接；其代数行为以 (20) 为准。

7 核心递推

Theorem 7.1 (多阶段对齐的残差投影递推). 在局部二阶近似下, 有效更新为:

$$\Delta A_{n+1} = \eta_{n+1} \Pi_{\mathcal{H}_{n+1}}^{M_n, \lambda}(U_{n+1}^* - A_n). \quad (21)$$

完整递推:

$$A_{n+1}(z) = A_n(z) + \eta_{n+1} \Pi_{\mathcal{H}_{n+1}}^{M_n, \lambda}[U_{n+1}^*(z) - A_n(z)] + \mathcal{E}_{n+1}(z) \quad (22)$$

其中 $\mathcal{E}_{n+1}$ 收集非线性误差、有限步优化误差、采样误差和 *reward/model mismatch*。

7.1 线性叠加何时成立

当且仅当以下四个条件同时满足时, 递推退化为线性叠加 $A_N = \sum_i R_i / \beta_i$:

- (C1) U_i^* 不依赖 P_{i-1} (reward 固定);
- (C2) $\Pi_i = \text{id}$ (模型表达能力无限且无约束);
- (C3) $\mathcal{E}_i = 0$ (优化精确收敛);
- (C4) $\eta_i = 1/\beta_i$ (学习率与 KL 温度匹配)。

真实后微调中 (C1)–(C4) 通常不成立, 因此线性叠加只是一阶近似。

7.2 路径依赖

由于 M_n 、 $\mathcal{H}_{n+1}$ 、甚至 U_{n+1}^* 都依赖当前模型 P_n , 一般有:

$$\text{Train}_2 \circ \text{Train}_1 \neq \text{Train}_1 \circ \text{Train}_2 \quad (23)$$

路径依赖来自三个层面: A_n 改变残差; P_n 改变训练几何 M_n ; θ_n 改变可达子空间 $\mathcal{H}_{n+1}$ 。

8 平滑边缘上的景观递推

8.1 Reweight-then-smooth 与 smooth-then-reweight 不交换

设从 z 到 x_t 的平滑核为 $K_t(x | z)$ 。零时刻 Gibbs reweighting 与扩散平滑一般不交换。定义平滑边缘势能:

$$B_{n,t}(x) := \log \frac{p_{n,t}(x)}{p_{0,t}(x)}, \quad p_{n,t}(x) = \int K_t(x | z) dP_n(z). \quad (24)$$

若零时刻更新为 $dP_{n+1}(z) \propto e^{\Delta A_{n+1}(z)} dP_n(z)$, 则平滑边缘势能增量为后验 **log-moment generating function**:

$$B_{n+1,t}(x) - B_{n,t}(x) = \log \mathbb{E}_{P_n(z|X_t=x)}[e^{\Delta A_{n+1}(z)}] - \text{const} \quad (25)$$

8.2 Cumulant 展开

对 (25) 的右端做 cumulant 展开:

$$\log \mathbb{E}[e^{\Delta A} | X_t=x] = \underbrace{\mathbb{E}[\Delta A | x]}_{\kappa_1} + \frac{1}{2} \underbrace{\text{Var}(\Delta A | x)}_{\kappa_2} + \frac{1}{6} \underbrace{\kappa_3(\Delta A | x)}_{\kappa_3} + \dots \quad (26)$$

因此平滑边缘的严格递推是:

$$B_{n+1,t}(x) = B_{n,t}(x) + \sum_{k=1}^{\infty} \frac{1}{k!} \kappa_{n,t}^{(k)}(x) - \text{const}, \quad (27)$$

其中 $\kappa_{n,t}^{(k)}(x)$ 是 $\Delta A_{n+1}(z)$ 在后验 $P_n(z | X_t=x)$ 下的第 k 阶 cumulant。

8.3 景观曲率递推

对 x 求 Hessian:

$$K_{n+1,t}(x) = K_{n,t}(x) + \nabla_x^2 \log \mathbb{E}_{P_n(z|X_t=x)}[e^{\Delta A_{n+1}(z)}] \quad (28)$$

其中 $K_{n,t}(x) := \nabla_x^2 \log p_{n,t}(x)$ 。

小步长近似:

$$K_{n+1,t} \approx K_{n,t} + \nabla_x^2 \mathbb{E}[\Delta A_{n+1} | X_t] + \frac{1}{2} \nabla_x^2 \text{Var}(\Delta A_{n+1} | X_t) + \dots \quad (29)$$

Remark 8.1 (协方差进入景观的路径). $K_{n+1} = K_n + \eta \nabla^2 r$ 是 (29) 只取 κ_1 项的近似; 完整递推还含方差项与更高阶 *cumulant*。协方差场要先经 *reweighting* $\rightarrow$ 后验 *cumulant* $\rightarrow$ *Hessian* 化, 才进入景观更新。

9 Posterior Score Covariance 的正确位置

9.1 高斯混合 Hessian 分解

对经验数据经高斯平滑得到的混合密度 $p_t(x) = \frac{1}{N} \sum_i p_t^{(i)}(x)$, $p_t^{(i)}(x) = \mathcal{N}(\alpha_t x^{(i)}, \sigma_t^2 I)$, 后验权重 $w_i(x, t) = p_t^{(i)}(x) / \sum_k p_t^{(k)}(x)$, 条件 score $s_i(x, t) = \nabla_x \log p_t^{(i)}(x)$:

$$\nabla_x^2 \log p_t(x) = \underbrace{-\sigma_t^{-2} I}_{\text{空间常数}} + \underbrace{\text{Cov}_w(s_I)}_{\text{全部空间变化}} \quad (30)$$

其中 $\text{Cov}_w(s_I) = \sum_i w_i \bar{s}_i \bar{s}_i^\top \succeq 0$, $\bar{s}_i = s_i - \sum_k w_k s_k$ 。

9.2 Probability Flow Jacobian 的稳健表述

许多 score-based probability flow ODE 共享形式 $u_t(x) = a(t)x + b(t)\nabla_x \log p_t(x) + c(t)$ 。因此:

$$\nabla_x u_t(x) = [a(t) - b(t)\sigma_t^{-2}]I + b(t) \text{Cov}_w(s_I). \quad (31)$$

去掉空间常数项:

$$\nabla_x u_t(x) - (\text{space constant}) = b(t) \text{Cov}_w(s_I) \quad (32)$$

Corollary 9.1 (Frobenius 正比性). 若 $b(t) \neq 0$ 且场非退化, 则 $\|\nabla_x u_t - \text{const}\|_F$ 与 $\|\text{Cov}_w(s_I)\|_F$ 逐点成比例。这避免了对特定 *noise schedule* 系数的过度承诺。

9.3 进入训练递推的路径

Posterior score covariance 沿这条链进入训练递推:

$$\text{Cov}_w(s_I) \Rightarrow K_{n+1,t}^* \Rightarrow K_{n+1,t}^* - K_{n,t} \Rightarrow \Pi_{n+1}(K_{n+1,t}^* - K_{n,t}) \Rightarrow K_{n+1,t}.$$

10 谱坐标下的可达性递推

在局部区域内, 设当前景观曲率为 $K_{n,t} = \sum_k a_{n,k} v_{n,k} v_{n,k}^\top$, 目标为 $K_{n+1,t}^* = \sum_k a_{n+1,k}^* v_{n,k} v_{n,k}^\top + \text{offdiag}$ 。

Proposition 10.1 (谱递推). 若 K_n 与 K_{n+1}^* 近似共谱, Π_{n+1} 在该谱基下近似对角, 且更新足够小 (特征方向旋转可忽略), 则:

$$a_{n+1,k} = a_{n,k} + \eta_{n+1} \chi_{n+1,k} (a_{n+1,k}^* - a_{n,k}) \quad (33)$$

其中 $\chi_{n+1,k} \in [0, 1]$ 是第 k 个方向的可达性系数, 受数据覆盖、LoRA rank、target modules、NTK/Fisher 谱、优化器和正则化共同影响。

Remark 10.2 (LoRA 是方向性投影). *LoRA* 的效果是方向性的: 某些方向 $\chi_k \approx 1$ (完全可达), 另一些 $\chi_k \approx 0$ (完全不可达)。它取决于低秩矩阵 BA 的列空间与目标残差在各方向上的对齐程度, 因此 χ_k 沿方向变化, 而非一个各向同性的标量。

11 对齐税

Definition 11.1 (对齐税的二次近似). 假设训练阶段求解局部二次问题 (18), 最优可达更新 $h^* = \Pi_{\mathcal{H}_{n+1}}^{M_n, \lambda} G_{n+1}$ 。对齐税为:

$$Tax_{n+1} = \underbrace{\|(I - \Pi_{\mathcal{H}_{n+1}}^{M_n}) G_{n+1}\|_{M_n}^2}_{\text{不可达残差}} + \underbrace{\lambda \langle h^*, \Lambda_n h^* \rangle}_{\text{景观移动代价}} \quad (34)$$

第一项: 残差中当前训练机制无法学习的部分 (*LoRA* 秩不够、数据覆盖不足、 $\chi_k \approx 0$)。第二项: 为改变已有景观所需付出的迁移代价 (高 $\lambda_{n,k}$ 方向偏移代价高)。

在谱坐标下:

$$Tax_{n+1} \approx \sum_k (1 - \chi_{n+1,k})^2 g_{n+1,k}^2 m_{n,k} + \lambda \sum_k \chi_{n+1,k}^2 g_{n+1,k}^2 \lambda_{n,k}, \quad (35)$$

其中 $g_{n+1,k} = \langle G_{n+1}, v_{n,k} \rangle_{M_n}$ 是残差在第 k 方向的分量。

Definition 11.2 (对齐税的原始优化定义). 不经由投影算子, 直接将对齐税定义为局部训练问题的最优值: 给定中心化残差 $g_{n+1} \in T_n$ 、可训练子空间 S_{n+1} 、*Jacobian* $J_n = \nabla_{\theta} A_{\theta}|_{\theta_n}$ 、训练度量 M_n 与参数度量 Γ_n ,

$$Tax_{n+1}(g_{n+1}) := \min_{\delta\theta \in S_{n+1}} \left\{ \frac{1}{2} \|g_{n+1} - C_n J_n \delta\theta\|_{M_n}^2 + \frac{\lambda}{2} \|\delta\theta\|_{\Gamma_n}^2 \right\}. \quad (36)$$

(36) 是第二类 (value form) 刻画: 税不是先解出最优更新、再把残差项与移动项相加, 而是直接取该局部目标的下确界。其优势在于把两类成本自动、无重复地一并纳入:

1. 不可达残差。 g_{n+1} 中无法被 $C_n J_n S_{n+1}$ 表示的分量, 无论 $\delta\theta$ 如何选取都留在目标的第一项里——这正是 *LoRA* 秩不足、数据覆盖不足、 $\chi_{n+1,k} \approx 0$ 所造成的、当前机制学不到的部分。
2. 移动代价。即便方向可达, 写入它仍需付出参数 / 高曲率移动的代价, 由第二项 $\frac{\lambda}{2} \|\delta\theta\|_{\Gamma_n}^2$ 计入; Γ_n 中大特征值方向 (高景观曲率) 上的偏移更昂贵。

二者在同一极小化中被联合权衡: λ 越大, 最优 $\delta\theta$ 越收缩, 越多本可达的分量被让渡回第一项, 体现了”宁可学、也不付高迁移代价”的取舍。

Remark 11.3 (与描述形式 (34) 的一致性). 当 $\lambda = 0$ 且 $\Pi_{\mathcal{H}_{n+1}}$ 退化为 M_n 度量下到 $\mathcal{H}_{n+1} = \text{Range}(C_n J_n|_{S_{n+1}})$ 的正交投影时, 最优 $\delta\theta$ 使 $C_n J_n \delta\theta = \Pi_{\mathcal{H}_{n+1}}^{M_n} g_{n+1}$, 于是

$$Tax_{n+1}(g_{n+1}) = \frac{1}{2} \|(I - \Pi_{\mathcal{H}_{n+1}}^{M_n}) g_{n+1}\|_{M_n}^2,$$

即 (34) 的不可达残差项在无 *ridge* 极限下的 *value form*。整体而言, (36) 的两项都带一个 $\frac{1}{2}$ 的常规归一, 其值恰为 (34) 的一半; $\lambda > 0$ 时第二项 $\frac{\lambda}{2} \|\delta\theta\|_{\Gamma_n}^2$ 对应 (34) 的景观移动代价 $\lambda \langle h^*, \Lambda_n h^* \rangle$, 二者经由中心化 *Jacobian* 推前 $h = C_n J_n \delta\theta$ 把参数度量 Γ_n 拉回为函数空间曲率 Λ_n 而相互对应 (差一个统一的 $\frac{1}{2}$)。因此 (36) 是 (34) 的原始 (*primal*) 来源, 而非另一个量。

Remark 11.4 (与线性响应算子的一致性). (36) 与线性响应算子 $\mathcal{L}$ (定义 6.2) 属同一 *value form*: $\mathcal{L}$ 给出局部问题最优更新对残差的线性依赖, 而 Tax_{n+1} 给出对应的最优目标值。二者由同一二次规划的解与值同时确定, 故由 $\mathcal{L}$ 可读出税的谱分解 (35), 反之税的下确界结构也固定了 $\mathcal{L}$ 的可达像与零空间。此处的局部二阶 (二次) 模型本身是近似; 在该模型给定后, (36) 作为其下确界是精确的最优值, 故归为第二类刻画——局部二阶近似下的精确值, 而非全局精确恒等式。

12 Jet-FM / 扰动训练的位置

扰动训练改变的不是 KL-RLHF 的 Gibbs target，而是 FM 投影阶段的几何度量。

12.1 扰动 $\approx$ Sobolev 投影

对输入加小扰动 $\tilde{x} = x + \varepsilon\xi$, $\mathbb{E}[\xi] = 0$, $\mathbb{E}[\xi\xi^\top] = I$ 。记速度残差 $f(x) := v_\theta(x) - u_Q(x)$ 。对 $f(x + \varepsilon\xi)$ 作逐分量二阶 Taylor 展开并对 ξ 取期望（用到 $\mathbb{E}[\xi] = 0$ 、 $\mathbb{E}[\xi\xi^\top] = I$ ）：

$$\mathbb{E}_\xi[\|f(x + \varepsilon\xi)\|^2] = \|f\|^2 + \varepsilon^2 \left(\|\nabla_x f\|_F^2 + f \cdot \Delta_x f \right) + O(\varepsilon^3). \quad (37)$$

这是精确的二阶恒等式（精确恒等式，非近似）。原朴素写法只保留 $\|\nabla_x f\|_F^2 = \|\nabla_x v_\theta - \nabla_x u_Q\|_F^2$ ，丢掉了 $f \cdot \Delta_x f$ 这一项（速度残差与其 Laplacian 的内积）。展开成 v_θ, u_Q 的形式：

$$\mathbb{E}_\xi[\|v_\theta(\tilde{x}) - u_Q(\tilde{x})\|^2] = \|v_\theta - u_Q\|^2 + \varepsilon^2 \|\nabla_x v_\theta - \nabla_x u_Q\|_F^2 + \varepsilon^2 (v_\theta - u_Q) \cdot \Delta_x (v_\theta - u_Q) + O(\varepsilon^3). \quad (38)$$

其中 $\Delta_x = \text{tr} \nabla_x^2$ 逐分量作用， $f \cdot \Delta_x f = \sum_i f_i \Delta_x f_i$ 。该交叉项符号不定（可正可负），一般非零；只有当残差 f 本身小（接近最优 / 接近 target）时它才相对可忽略，此时 ε^2 阶主效应才退化为纯 Jacobian / Sobolev 罚。

Proposition 12.1 (Jet-FM 的 Sobolev 解释需残差小条件). 设 $f = v_\theta - u_Q$ 二阶可微、边界贡献可略。由 (37)，扰动训练损失的 ε^2 阶项为 $\|\nabla_x f\|_F^2 + f \cdot \Delta_x f$ 。当 $f \approx 0$ (*near optimum / near target*) 时， $f \cdot \Delta_x f \rightarrow 0$ （与 $\|f\|$ 同阶），在 $\nabla_x f$ 不退化时相对 $\|\nabla_x f\|_F^2$ 可忽略，二阶主效应才约化为

$$\mathbb{E}_\xi[\|f(\tilde{x})\|^2] \approx \|f\|^2 + \varepsilon^2 \|\nabla_x v_\theta - \nabla_x u_Q\|_F^2.$$

此为充分条件而非必要（例如 f 近调和、 $\Delta_x f \approx 0$ 时交叉项亦可忽略）。故“扰动训练 $\approx$ *velocity matching* + ε^2 *Sobolev* 正则”仅在残差小的局部成立，并非无条件恒等。在远离 *target*、 f 不小处，*Laplacian* 交叉项符号不定，可改变甚至反号该二阶罚的有效曲率，此时不能把 *Jet-FM* 直接读作 *Sobolev* 投影。本命题为第二类（局部二阶近似）。

因此（在 Prop. 12.1 的残差小区域内）扰动训练把 FM 投影度量从纯速度空间扩展为速度 + Jacobian 的 Sobolev 型度量：

$$\Pi^{\text{velocity}} \rightsquigarrow \Pi^{\text{velocity}+\text{Jacobian}}. \quad (39)$$

由 (32)，该 Jacobian 匹配项直接迫使网络学习 $\text{Cov}_w(s_I)$ 的空间分布。

Remark 12.2. 扰动训练不自动等同于“*RLHF₁ covariance-aware*”，除非训练样本覆盖了 *RLHF₁* 的高协方差区域，且当前模型 *Jacobian* 继承了这些结构；并且，由 Prop. 12.1，这一 *Sobolev* 读法还要求残差 f 已足够小。

13 多阶段中每一阶段改变了什么

Table 1: 多阶段递推中各阶段的作用

阶段	主要改变	数学对象	风险
RLHF ₁	建立粗坐标系	$A_1 = \eta_1 \Pi_{\mathcal{H}_1}^{M_0, \lambda}(U_1^*)$	粗粒度偏差固化
RLHF ₂	坐标系内条件化细分	$A_2 = A_1 + \eta_2 \Pi_{\mathcal{H}_2}^{M_1, \lambda}(U_2^* - A_1)$	子空间太窄 $\rightarrow$ 只学表面
RLHF ₃	例外、边界、冲突	$A_3 = A_2 + \eta_3 \Pi_{\mathcal{H}_3}^{M_2, \lambda}(U_3^* - A_2)$	规则互相打架
第 n 次 +	残差收敛或漂移	$A_{n+1} = A_n + \eta \Pi(U^* - A_n) + \mathcal{E}$	遗忘 / 僵化 / 不可达累积

14 四条核心命题

Proposition 14.1 (命题 1: Inverse alignment bridge). 若 $Q_{\mathcal{D}} \ll P_0$, 则监督数据分布 $Q_{\mathcal{D}}$ 可诱导势能 $U_{\mathcal{D}} = \log(dQ_{\mathcal{D}}/dP_0)$ 。在无限容量和全局优化下, SFT 的 *population target* 可被反解释为 KL - $RLHF$ 的 *Gibbs optimum*。有限模型下, SFT 是该 *target* 在模型族中的 KL 投影。

Proposition 14.2 (命题 2: Residual reward theorem). 以 P_n 为 *reference* 的 *ideal KL-RLHF reward* 满足 $R_{n+1}/\beta_{n+1} = U_{n+1}^* - A_n$ 。多阶段对齐作用在残差势能上, 每一阶段以当前模型为 *reference*。

Proposition 14.3 (命题 3: Projected residual dynamics). 在局部线性化和二次近似下, 有限模型、 $LoRA$ 、优化器和正则化共同诱导投影 $\Pi_{\mathcal{H}_{n+1}}^{M_n, \lambda}$ 。实际更新为 (22)。路径依赖来自 A_n 、 M_n 、 $\mathcal{H}_{n+1}$ 随历史改变。

Proposition 14.4 (命题 4: Posterior cumulant landscape recursion). 平滑边缘上的势能更新不是简单相加, 而是后验 $\log$ - MGF (25)。*Posterior score covariance* 给出目标景观的局部曲率来源 (30), 但它必须先经残差化、路径构造和训练投影, 才进入最终模型 (28)。

15 第一部分小结: 无条件框架

第一部分给出的层次结构是:

目标分布 $\neq$ 训练过程 $\neq$ 模型可达更新 $\neq$ 扩散平滑景观。

它作用在无条件层面——对象是 z , 没有显式的文本条件 c 。T2I 的核心是 $T \rightarrow I$ 的条件回归: 模型学的是 $p(x | c)$, 且架构中有的部分看得到文本、有的部分看不到。第二部分把条件 c 装进框架, 并由此推导衰退矩阵。

第一部分一句话: 多阶段对齐在每一阶段把目标势能相对于当前势能取残差, 再通过当前模型几何、可训练子空间和路径投影得到有限可达更新; 扩散/FM 场景下, 该更新在平滑边缘上由 posterior cumulant 控制。

第二部分: 条件化 (Text $\rightarrow$ Image) 扩展

把文本回归装回框架, 并推导衰退矩阵

16 联合条件测度与 fiberwise gauge

把文本条件 c 作为测度空间的一部分, 在联合条件测度上直接做残差、投影、分解与可辨识性。本节先建立联合测度和它的归一化约束。

16.1 对象: 一族条件分布, 提升为联合测度

设文本空间 $\mathcal{C}$ 、图像 latent 空间 $\mathcal{X}$, 固定一个 caption 环境分布 $\rho(dc)$ 。T2I 模型是一族条件分布 $p_n(dx | c)$, 提升为联合测度:

$$P_n^{\rho}(dc, dx) = \rho(dc) p_n(dx | c). \quad (40)$$

只要 ρ 固定, 文本条件就不是附加结构, 而是生成对象的一部分。条件累计势能直接定义为二元函数:

$$A_n(c, x) := \log \frac{p_n(x | c)}{p_0(x | c)}. \quad (41)$$

16.2 Fiberwise gauge: 归一化是每个 fiber 上的约束

势能的 gauge 不是随便加常数。每个 c -fiber 上 $p_n(\cdot | c)$ 必须归一化，故

$$\int_{\mathcal{X}} \exp(A_n(c, x)) p_0(dx | c) = 1 \quad \rho\text{-a.e. } c. \quad (42)$$

第一部分 KL-RLHF 中出现的 $\text{const}(c)$ 不是无害常数，而是 **fiberwise gauge**，必须按(42) 统一处理。这是条件化相对无条件框架的第一个本质差别。

17 条件切空间与残差

17.1 切空间：残差是条件密度流的切向量

沿某 c -fiber 改变 log-density 时，必须保持 $\int p_n(dx | c) = 1$ 。因此真正有效的无穷小更新不是任意函数，而是条件中心化后的函数。定义阶段- n 的条件切空间：

$$T_n := \{ h(c, x) : \mathbb{E}_{P_n}[h(C, X) | C = c] = 0 \quad \rho\text{-a.e. } c \}. \quad (43)$$

条件零均值约束是(42) 的切向版本。引入条件中心化算子

$$\mathcal{C}_n[f] := f - \mathbb{E}_{P_n}[f | C], \quad \mathcal{C}_n : L^2(P_n^\rho) \rightarrow T_n. \quad (44)$$

17.2 残差：自动吸收 fiberwise 归一化

若本阶段目标为 $Q_{n+1}^*(dx | c)$ ，理想残差应写为条件中心化的对数密度比：

$$g_{n+1}(c, x) = \mathcal{C}_n \left[\log \frac{dQ_{n+1}^*}{dP_n} \right] = \log \frac{q_{n+1}^*(x | c)}{p_n(x | c)} - \mathbb{E}_{P_n} \left[\log \frac{q_{n+1}^*(X | C)}{p_n(X | C)} \mid C = c \right] \quad (45)$$

故 $g_{n+1} \in T_n$ 。条件中心化使 g_{n+1} 在每个 caption fiber 上自动吸收归一化常数，不留 gauge 自由度。

Remark 17.1 (切空间是 Hilbert bundle). (第一类，结构性。) 以上构造可一次性几何化。设 base 为 caption 空间 $(\mathcal{C}, \rho)$ 。对每个 $c \in \mathcal{C}$ ，阶段- n 的 fiber 取为该 fiber 上的零均值 L^2 空间

$$T_n(c) := L_0^2(p_n(\cdot | c)) = \{ h(c, \cdot) \in L^2(p_n(\cdot | c)) : \mathbb{E}_{P_n}[h | C = c] = 0 \},$$

而整体切空间(43) 恰是这族 fiber 关于 ρ 的直积分 (*direct integral*)

$$T_n = \int_{\mathcal{C}}^{\oplus} T_n(c) \rho(dc), \quad \langle h, h' \rangle_{T_n} = \int_{\mathcal{C}} \mathbb{E}_{P_n}[h h' | C = c] \rho(dc).$$

故 $\{T_n(c)\}_{c \in \mathcal{C}}$ 是一个 **Hilbert bundle**， T_n 是其 ρ -直积分。中心化算子(44) $\mathcal{C}_n$ 即 $L^2(P_n^\rho)$ 上到这些零均值 fiber 的逐 **fiber** 正交投影：在每个 c 上独立减去 $\mathbb{E}_{P_n}[\cdot | C = c]$ 。这从几何上说明了为何 gauge 是 fiberwise 的——每个 caption 各自一个归一化常数，而非全局单一常数（对照(42)）。

由此，残差 g_{n+1} 与各阶段更新都不是单个 L^2 函数，而是该 bundle 的截面 (*section*)： $c \mapsto g_{n+1}(c, \cdot) \in T_n(c)$ 。无条件 floor 子空间 $\mathcal{U}_n$ (50) 则是一个子 **bundle**：其 fiber $\mathcal{U}_n(c) = \{a - \mathbb{E}_{P_n}[a | C = c] : a \in L^2(P_n^X)\}$ 由同一图像侧函数 a 在所有 fiber 上同步生成，故截面受跨 fiber 的相干约束；后续的 $\mathcal{U}_n/\mathcal{V}_n$ 正交分解(52) 即此子 bundle 与其正交补 bundle 上的逐 fiber 分解。本注记仅厘清几何对象，不引入新近似。

18 条件残差投影递推（主递推）

设本阶段可训练参数子空间 S_{n+1} 。完整模型 Jacobian $J_n(c, x) = \nabla_{\theta} A_{\theta}(c, x)|_{\theta_n}$ 经中心化给出线性化可达子空间：

$$\mathcal{H}_{n+1} := \text{Range}(\mathcal{C}_n J_n|_{S_{n+1}}) = \{\mathcal{C}_n[J_n(c, x) \delta\theta] : \delta\theta \in S_{n+1}\} \subset T_n. \quad (46)$$

在 Fisher / $L^2(P_n^{\rho})$ / path-Fisher 度量 M_n 下投影（含岭正则 λ ）：

$$h_{n+1}^* = \Pi_{\mathcal{H}_{n+1}}^{M_n, \lambda} g_{n+1}. \quad (47)$$

Theorem 18.1 (条件残差投影递推). 有限步更新在每个 *fiber* 上为指数倾斜：

$$\frac{dP_{n+1}(\cdot | c)}{dP_n(\cdot | c)} \propto \exp(\eta h_{n+1}^*(c, \cdot)), \quad (48)$$

即

$$\boxed{A_{n+1}(c, x) = A_n(c, x) + \eta h_{n+1}^*(c, x) - \psi_{n+1}(c) + \mathcal{E}_{n+1}(c, x)} \quad (49)$$

其中 *fiberwise* 对数配分 $\psi_{n+1}(c) = \log \mathbb{E}_{P_n(\cdot | c)}[\exp(\eta h_{n+1}^*(c, X))]$ 自动满足 *gauge* (42), $\mathcal{E}_{n+1}$ 收集非线性、有限步与采样误差。

这是条件版主定理。它不需要空 caption、不需要 CFG、不需要 token、不需要任何 SDXL/FLUX 结构假设。工程细节只通过 Q^* 、 S_{n+1} 、 J_n 三个对象进入。

19 无条件 / 对比分解

对所有文本条件共同的图像侧分量，是切空间 T_n 中的一个 Hilbert 正交投影。下面定义这个子空间，并把残差正交分解为图像侧 floor 与文本对比两部分。

19.1 caption-invariant 子空间

Definition 19.1 (caption-invariant 与对比子空间). 在 T_n 内定义

$$\mathcal{U}_n := \overline{\{a(X) - \mathbb{E}_{P_n}[a(X) | C] : a \in L^2(P_n^X)\}} \subset T_n, \quad (50)$$

即所有“图像侧函数经条件中心化”张成的闭子空间——它是对所有文本条件共同施加的图像侧 *floor*。对比子空间为正交补

$$\mathcal{V}_n := T_n \ominus \mathcal{U}_n. \quad (51)$$

注意 $\mathcal{U}_n$ 中的元素不是简单的 $a(x)$ ：条件分布必须在每个 fiber 归一化，故须减去 $\mathbb{E}[a(X) | C]$ 。

Proposition 19.2 (残差的正交分解). 任意残差唯一分解

$$\boxed{g_{n+1} = g_{n+1}^u + g_{n+1}^c, \quad g_{n+1}^u = \Pi_{\mathcal{U}_n} g_{n+1}, \quad g_{n+1}^c = (I - \Pi_{\mathcal{U}_n}) g_{n+1}} \quad (52)$$

其中 $\Pi_{\mathcal{U}_n}$ 是 M_n 下到 $\mathcal{U}_n$ 的正交投影。

Remark 19.3 (caption-invariant 分量与 null-caption fiber). *caption-invariant* 分量是正交投影 $\Pi_{\mathcal{U}_n} A_n$ (残差侧为 $\Pi_{\mathcal{U}_n} g_{n+1}$)。空 *caption* 上的求值 $A(x | \emptyset)$ 是 $\emptyset$ 这一个 *fiber* 上的 **null-caption fiber potential**；它与 *caption-invariant* 分量在一般 ρ 下不重合，两者只在参考测度关于 *dropout* 对称时才相等。

Remark 19.4 (正交分解依赖度量). 分解(52) 中的正交投影 $\Pi_{\mathcal{U}_n}$ 不是绝对的: 它依赖所选内积。把这一依赖显式写出,

$$g_{n+1}^u = \Pi_{\mathcal{U}_n}^{M_n} g_{n+1}, \quad g_{n+1}^c = (I - \Pi_{\mathcal{U}_n}^{M_n}) g_{n+1},$$

其中 $\Pi_{\mathcal{U}_n}^{M_n}$ 是 M_n 下到 $\mathcal{U}_n$ 的正交投影。给定 M_n , 该分解是唯一的 (*Hilbert* 正交投影), 故对固定度量而言(52) 是精确恒等式 (第一类)。

它在 $L^2(P_n^c)$ 下最干净: $\mathcal{U}_n$ 由条件中心化的图像侧函数张成(50), 正交补 $\mathcal{V}_n = T_n \ominus \mathcal{U}_n$ 直接由 $\mathbb{E}_{P_n}[\cdot | C]$ 给出, *floor* 与 *contrastive* 的几何与条件期望一致。但换用 *Fisher* / *path-Fisher* / 优化器诱导度量 M_n 时, $\langle \cdot, \cdot \rangle_{M_n}$ 重新加权各方向, 于是两件事同时改变: (i) 哪些方向算作 *floor*、哪些算作 *contrastive*——即 $\mathcal{U}_n$ 与其 M_n -正交补 $\mathcal{V}_n^{M_n}$ 的相对位置; (ii) 投影算子 $\Pi_{\mathcal{U}_n}^{M_n}$ 本身。 $\mathcal{U}_n$ 作为线性子空间不变, 但其正交补、从而分量 g^u, g^c 随 M_n 漂移; 仅当 M_n 关于 $\mathcal{U}_n$ 与 $\mathcal{V}_n$ 块对角时各度量给出同一分解。

警示: 由此, 下游一切由该分解定义的量——*caption-invariant* 泄漏 Leak_{n+1} 、对齐税 Tax_{n+1} 、*firewall* 交换子 $[\Pi_{\mathcal{H}_{n+1}}, \Pi_{\mathcal{U}_n}]$ ——都是隐式相对于度量的, 应统一携带 M_n 上标 (如 $\Pi_{\mathcal{U}_n}^{M_n}$ 、 $\text{Leak}_{n+1}^{M_n}$)。这些陈述属第一类 (精确恒等式), 但带度量依赖 **caveat**: 换 M_n 即换基准, 跨度量比较泄漏/税值之前必须先对齐内积。

20 Prompt 可控性: 干预响应算子

prompt 对某特征的控制由干预响应算子刻画: 改变 caption 时该特征的条件期望如何变化。

Definition 20.1 (caption 干预响应). 给定图像特征 $\phi: \mathcal{X} \rightarrow \mathbb{R}$, 定义

$$\mathcal{R}_n \phi(c, c') := \mathbb{E}_{P_n(\cdot | c')} [\phi(X)] - \mathbb{E}_{P_n(\cdot | c)} [\phi(X)]; \quad (53)$$

若文本 *embedding* 连续, 则微分响应 $D_c \mathbb{E}_{P_n(\cdot | c)} [\phi(X)]$ 。

Definition 20.2 (prompt-不可约). 特征 ϕ 为 **prompt**-不可约 当且仅当 $\phi \in \ker \mathcal{R}_n$, 近似意义下 $\|\mathcal{R}_n \phi\| \approx 0$ 。

Remark 20.3 (CFG 与响应算子). *CFG* 采样 $s_{\text{cfg}} = s_\emptyset + \omega(s_c - s_\emptyset)$ 是某个特定 *sampler* 在 *score* 层面对 $\mathcal{R}_n$ 的近似放大。一个特征是否 *prompt*-可控, 由 $\mathcal{R}_n \phi$ 是否显著非零决定。

21 Caption dropout: 腐化通道与互信息

Caption dropout 是一个作用在文本上的腐化通道: 以概率 p_{drop} 把 caption 替换为 $\emptyset$ 。它降低图像与 caption 之间的互信息, 从而抬高残差在 *caption-invariant* 子空间上的投影比例。

Definition 21.1 (腐化 caption 通道).

$$\mathcal{K}(d\tilde{c} | c) = (1 - p_{\text{drop}}) \delta_c(d\tilde{c}) + p_{\text{drop}} \delta_\emptyset(d\tilde{c}). \quad (54)$$

训练数据不是原始 $Q(dx, dc)$, 而是腐化联合 $\tilde{Q}(dx, d\tilde{c}) = \int Q(dx, dc) \mathcal{K}(d\tilde{c} | c)$ 。

dropout 诱导的目标残差 $\tilde{g} = \mathcal{C}_n[\log d\tilde{Q}/dP_n^{\hat{P}}]$, 再投影到 T_n 。

Proposition 21.2 (dropout 在收缩假设下抬高 floor 比例). 分两层陈述. (i) **DPI** (第一类, 精确恒等式不等式): 腐化通道 $\mathcal{K}$ 是只作用于 C 的 *Markov* 通道, 故 *data-processing inequality* 给出

$$I_{\tilde{Q}}(X; \tilde{C}) \leq I_Q(X; C). \quad (55)$$

注意这里只能是 $\leq$, 不能写成严格 $<$; 且 *DPI* 本身并不蕴含 *floor*-投影比例上升——互信息是标量信息量, 与残差 $\tilde{g}$ 在 $\mathcal{U}_n/\mathcal{V}_n$ 上的能量分配没有逻辑等价关系。要得到比例结论, 必须额外引入对几何分量的收缩假设。

(ii) 收缩假设（经验假设，但可测）：存在 $\rho(p_{\text{drop}}) \in [0, 1]$ 且 $\rho(p_{\text{drop}}) < 1$ ，使得 *dropout* 收缩 *contrastive* 分量、并近似保持 *invariant* 分量：

$$\|\Pi_{\mathcal{V}_n} \tilde{g}\|_{M_n} \leq \rho(p_{\text{drop}}) \|\Pi_{\mathcal{V}_n} g\|_{M_n}, \quad \|\Pi_{\mathcal{U}_n} \tilde{g}\|_{M_n} \approx \|\Pi_{\mathcal{U}_n} g\|_{M_n}. \quad (56)$$

(iii) 结论（第三类，条件于收缩假设）：在(56)下，因 $T_n = \mathcal{U}_n \oplus \mathcal{V}_n$ 正交（见 19.2），有 $\|\tilde{g}\|_{M_n}^2 = \|\Pi_{\mathcal{U}_n} \tilde{g}\|_{M_n}^2 + \|\Pi_{\mathcal{V}_n} \tilde{g}\|_{M_n}^2$ ；分子近似不变、*contrastive* 能量被 $\rho(p_{\text{drop}}) < 1$ 压低使分母严格不增，故 *floor* 比例（至少近似地）抬高：

$$\frac{\|\Pi_{\mathcal{U}_n} \tilde{g}\|_{M_n}^2}{\|\tilde{g}\|_{M_n}^2} \geq \frac{\|\Pi_{\mathcal{U}_n} g\|_{M_n}^2}{\|g\|_{M_n}^2}. \quad (57)$$

Remark 21.3. 口语版：*caption dropout* 降低 *caption channel* 的信息量，并倾向于收缩 *contrastive* 残差；若图像-*marginal* 残差（*invariant* 分量）被保持、且 *contrastive* 残差被压缩，则 *caption-invariant* 投影比例上升。第一类只到(55)的 $\leq$ ；比例上升的结论属第三类，条件于收缩假设(56)——该假设是可测的：固定 g 与 M_n ，逐 p_{drop} 估计 $\rho(p_{\text{drop}})$ 即可证伪。

于是 *caption dropout* 的作用沿这条链展开：

$$\text{dropout} \Rightarrow \text{caption channel degradation} \Rightarrow \Pi_{\mathcal{U}_n} \tilde{g} \text{ 增大}.$$

22 架构：Jacobian range 与投影交换子

架构的作用，由完整 **Jacobian range** 与 **caption-invariant** 子空间的相对位置刻画：可训练子空间能写入残差的哪一部分。

22.1 firewall = 投影交换子近似为零

对可训练子空间 S ，可达空间 $\mathcal{H}_S = \text{Range}(C_n J_n|_S) \subset T_n$ 。架构对”无条件/对比”分解的尊重程度由投影交换子度量：

$$[\Pi_{\mathcal{H}_S}, \Pi_{\mathcal{U}_n}] := \Pi_{\mathcal{H}_S} \Pi_{\mathcal{U}_n} - \Pi_{\mathcal{U}_n} \Pi_{\mathcal{H}_S}. \quad (58)$$

Definition 22.1 (数学 firewall). S 上存在 *firewall* 当且仅当

$$\boxed{\|[\Pi_{\mathcal{H}_S}, \Pi_{\mathcal{U}_n}]\| \approx 0 \iff \mathcal{H}_S \approx (\mathcal{H}_S \cap \mathcal{U}_n) \oplus (\mathcal{H}_S \cap \mathcal{V}_n).} \quad (59)$$

即可训练子空间近似尊重无条件/对比分解，更新不混合两个分量。交换子大则一个更新会同时搅动 *unconditional* 与 *contrastive*。

22.2 SDXL / FLUX 的区别是可测命题

定义两个 operator 量：

$$L_S(g) := \frac{\|\Pi_{\mathcal{U}_n} \Pi_{\mathcal{H}_S} g\|_{M_n}^2}{\|\Pi_{\mathcal{H}_S} g\|_{M_n}^2} \quad (\text{泄漏分数：残差经架构学习后落入 floor 的比例}), \quad (60)$$

$$\kappa_S := \|[\Pi_{\mathcal{H}_S}, \Pi_{\mathcal{U}_n}]\| \quad (\text{交换子范数：架构是否混合两分量}). \quad (61)$$

Proposition 22.2 (架构序作为可测命题). *SDXL* 与 *FLUX* 的区别写成可测命题

$$L_{\text{FLUX}}(g) > L_{\text{SDXL}}(g), \quad \kappa_{\text{FLUX}} > \kappa_{\text{SDXL}}, \quad (62)$$

对相关目标残差 g 成立。工程结构（*cross-attention* 与 *joint/single-stream*）通过它如何塑造 $\mathcal{H}_S$ ，进而决定 L_S 与 κ_S 。

Proposition 22.3 (交换子控制 floor 泄漏上界). 设残差为纯 *contrastive* 分量 $g^c \in \mathcal{V}_n$, 即 $\Pi_{\mathcal{U}_n} g^c = 0$ 。则该更新被架构写入后泄漏进 *caption-invariant floor* 的部分 $\Pi_{\mathcal{U}_n} \Pi_{\mathcal{H}_S} g^c$ 完全由投影交换子承载:

$$\begin{aligned}\Pi_{\mathcal{U}_n} \Pi_{\mathcal{H}_S} g^c &= \Pi_{\mathcal{U}_n} \Pi_{\mathcal{H}_S} g^c - \Pi_{\mathcal{H}_S} \Pi_{\mathcal{U}_n} g^c \quad (\text{因 } \Pi_{\mathcal{U}_n} g^c = 0) \\ &= -[\Pi_{\mathcal{H}_S}, \Pi_{\mathcal{U}_n}] g^c,\end{aligned}$$

从而得 *floor* 泄漏的算子上界

$$\|\Pi_{\mathcal{U}_n} \Pi_{\mathcal{H}_S} g^c\|_{M_n} \leq \|[\Pi_{\mathcal{H}_S}, \Pi_{\mathcal{U}_n}]\| \|g^c\|_{M_n} = \kappa_S \|g^c\|_{M_n}. \quad (63)$$

解读。交换子范数 κ_S (见(61)) 严格控制一次 **contrastive** 更新有多少漏进 **caption-invariant floor**: 恒等式 $\Pi_{\mathcal{U}_n} \Pi_{\mathcal{H}_S} g^c = -[\Pi_{\mathcal{H}_S}, \Pi_{\mathcal{U}_n}] g^c$ 表明, *floor* 泄漏不是来自残差本身 (它在 $\mathcal{V}_n$ 中、对 $\mathcal{U}_n$ 正交), 而纯粹是架构不尊重无条件/对比分解的产物。极限 $\kappa_S \approx 0$ (firewall, 见(59)) 即强制 $\Pi_{\mathcal{U}_n} \Pi_{\mathcal{H}_S} g^c \approx 0$: *contrastive* 更新近似零泄漏地停留在 *contrastive* 子空间, 不污染 *floor*。

Caveat 22.4. 须区分两个 *tier*。界(63) 是精确恒等式所导出的算子不等式 (第一类): 它对任意 $g^c \in \mathcal{V}_n$ 、任意 S 无条件成立, 无近似。而由 *Prop. 22.2* 给出的架构序

$$L_{\text{FLUX}} > L_{\text{SDXL}}, \quad \kappa_{\text{FLUX}} > \kappa_{\text{SDXL}},$$

是对 κ_S 、 L_S 数值的经验估计 (第三类), 依赖具体的 *cross-attention* 与 *joint/single-stream* 结构如何塑造 $\mathcal{H}_S$, 并非定理。故(63) 给出的是“泄漏 $\leq \kappa_S \cdot$ 残差范数”这一普适机制; 至于某架构的 κ_S 究竟多大, 须经测量, 不得由本命题推出。

23 可辨识性: caption σ -代数与识别算子

特征能否被文本辨识, 由 caption 生成的 σ -代数 $\sigma(C)$ 与识别算子刻画: 它度量某个图像特征方向在不同 caption 下的条件均值变化。

Definition 23.1 (caption-feature 识别算子). 给定图像特征 *map* $\Phi: \mathcal{X} \rightarrow \mathbb{R}^k$, 条件均值算子

$$\mathcal{I}_Q v := \mathbb{E}_Q[v^\top \Phi(X) \mid C], \quad v \in \mathbb{R}^k. \quad (64)$$

方向 v 是否被文本条件辨识, 取决于 $\text{Var}_C(\mathbb{E}[v^\top \Phi(X) \mid C])$ 。

Proposition 23.2 (常量特征衰退 = 识别算子的近零方向). 若 $\text{Var}_C(\mathbb{E}[v^\top \Phi(X) \mid C]) = 0$, 即 $v \in \ker \mathcal{I}_Q$, 则该特征方向在训练分布中对 $\sigma(C)$ 不可辨识: 数据无法把它与文本条件分开。此时训练目标不能唯一决定它应归入身份、服装、风格、*trigger* 还是 *caption-invariant floor*; 最终落点由可达投影 $\Pi_{\mathcal{H}_S}$ 、预训练增益 (J_n 奇异值谱)、岭最小范数偏置共同决定。

衰退的根因是对 **caption** σ -代数不可辨识: 当 $v \in \ker \mathcal{I}_Q$, 特征落点由可达性与最小范数偏置接管, 而训练目标本身给不出确定答案。

式(64) 的诊断量 $\text{Var}_C(\mathbb{E}[v^\top \Phi(X) \mid C])$ 只检验单个一阶条件均值方向; 它落入零集仅说明该特定线性统计量对 caption 不敏感, 并不蕴含图像的条件分布本身对 $\sigma(C)$ 不可分辨。为把“可辨识”的判据从单一一阶均值升级到一整族检验函数, 引入相对于特征类的识别算子。

Definition 23.3 (相对特征类的识别算子). 给定检验函数类 (*feature class*) $\mathcal{F} \subset L^2(Q)$, 定义识别算子 $\mathcal{I}_Q: \mathcal{F} \rightarrow L^2(\rho)$

$$(\mathcal{I}_Q \phi)(c) := \mathbb{E}_Q[\phi(X) \mid C = c], \quad \phi \in \mathcal{F}, \quad (65)$$

其中 ρ 为 C 的边缘分布。若 $\mathcal{I}_Q \phi$ 为 ρ -a.e. 常量, 则称 ϕ 在该特征类内、在一阶条件均值层级上对 *caption* 不可辨识, 记 $\phi \in \ker \mathcal{I}_Q$ (此处 $\ker$ 取商去常量后的零空间, 即 $\text{Var}_C((\mathcal{I}_Q \phi)(C)) = 0$)。该判据为第一类 (精确恒等式): 在给定 Q 与 $\mathcal{F}$ 下, $\phi \in \ker \mathcal{I}_Q$ 与“ ϕ 的条件期望不随 c 变化”是同一陈述, 不含近似。

Remark 23.4 (从一阶均值到特征类可辨识). (一) 原诊断 $\text{Var}_C(\mathbb{E}[v^\top \Phi \mid C])$ 恰是(65) 取 $\mathcal{F} = \{v^\top \Phi : v \in \mathbb{R}^k\}$ (固定 Φ 、扫描线性读出) 的特例; 式(64) 的 $\mathcal{I}_Q$ 即此处 $\mathcal{I}_Q$ 限制在该有限维类上的版本。

(二) 单一类的零判据弱于分布层级的不可分辨。若要 $\phi \in \ker \mathcal{I}_Q$ ($\forall \phi \in \mathcal{F}$) 逼近”条件分布 $Q(\cdot \mid C = c)$ 在 c 上彼此不可区分”, 需 $\mathcal{F}$ 足够丰富: 例如取为某 *characteristic RKHS* 的单位球, 或一族能分离测度的检验函数 (充分多的矩 / 指示型 / 核特征)。此时”所有 $\phi \in \mathcal{F}$ 的条件均值都与 c 无关”经由 $\mathbb{E}[\phi(X) \mid C = c] = \mathbb{E}[\phi(X) \mid C = c']$ ($\forall \phi$) 收紧为条件分布在弱拓扑下重合。 $\mathcal{F}$ 越小, $\ker \mathcal{I}_Q$ 越大——更多特征被误判为”不可辨识”。

(三, *scope caveat* 警示) 因此 $\phi \in \ker \mathcal{I}_Q$ 应读作”在 $\mathcal{F}$ 所能看到的统计量范围内不可辨识”, 而非绝对不可辨识: 存在 $\psi \notin \mathcal{F}$ 使 $\mathcal{I}_Q \psi$ 非常量是完全可能的。*Prop. 23.2* 中”对 $\sigma(C)$ 不可辨识”的结论, 其强度因而以诊断所用特征类 $\mathcal{F}$ 的丰富程度为上界; 用单一方向 v 的一阶均值否定可辨识性, 只是该谱系中最弱的一端。

24 衰退矩阵 = 三算子的组合

衰退矩阵由三个算子组合而成: 识别、可达、泄漏。

Definition 24.1 (三算子). (i) 识别算子 $\mathcal{I}_Q$: 训练数据有没有把该特征与文本条件分开? $\mathcal{I}_Q v \approx 0 \Rightarrow$ 不可辨识。

(ii) 可达算子 $\Pi_{\mathcal{H}_S}$: 当前 *LoRA* / *full-finetune* / *target modules* 能否写这个残差? $\|\Pi_{\mathcal{H}_S} g_v\| \approx 0 \Rightarrow$ 数据可辨识也学不动。

(iii) 泄漏投影 $\Pi_{\mathcal{U}_n}$: 学到的更新有多少变成 *caption-invariant floor*?

Theorem 24.2 (衰退严重度的算子分解). 对特征方向 v (残差 g_v), 定义经架构学习后的泄漏

$$\text{Leak}_S(g_v) = \frac{\|\Pi_{\mathcal{U}_n} \Pi_{\mathcal{H}_S} g_v\|^2}{\|\Pi_{\mathcal{H}_S} g_v\|^2}. \quad (66)$$

则衰退严重度分解为三个独立通道

$$\boxed{\text{衰退严重度} \sim \underbrace{\text{不可辨识}}_{v \in \ker \mathcal{I}_Q} + \underbrace{\text{不可达}}_{\Pi_{\mathcal{H}_S} g_v \approx 0} + \underbrace{\text{泄漏到 floor}}_{\text{Leak}_S(g_v)}} \quad (67)$$

Corollary 24.3 (标签策略 $\times$ 数据丰富度作为 Q 的形态). 衰退矩阵的每一格是数据分布 Q 的一种形态在三算子下的取值:

- 无触发词 / 通用标签: *caption* 与对象互信息低 $\Rightarrow$ 对象方向 $v \in \ker \mathcal{I}_Q$ (不可辨识) + 高 Leak_S (进 *floor*)。
- 只有触发词、同装束: 装束方向 $\mathcal{I}_Q$ -近零 (与 *trigger corr*=1, 对 $\sigma(C)$ 不可分) $\Rightarrow$ 焊入 *trigger fiber* 或 *floor*。
- 触发词 + 描述: 描述 *token* 是 J_n 高增益方向 (小所需残差) $\Rightarrow$ 部分把装束从 $\ker \mathcal{I}_Q$ 移出 (软杠杆, 概率性)。
- 多装束 (数据方差): $\text{Var}_C(\mathbb{E}[\phi \mid C]) > 0 \Rightarrow v \notin \ker \mathcal{I}_Q$ (可辨识, 硬锁); 但仍需 $\Pi_{\mathcal{H}_S}$ 覆盖 (可达) 才学得动——可辨识与可达独立。
- **SDXL vs FLUX**: 同一 Q 下, $\text{Leak}_{\text{FLUX}} > \text{Leak}_{\text{SDXL}}$ (*Prop. 22.2*) $\Rightarrow$ 更多对象特征以 *prompt*-不可约的 *floor* 形式被记住。

Definition 24.4 (衰退的三通道风险诊断). 定理 24.2 给出的是定性分解: 衰退严重度 $\sim$ 不可辨识 + 不可达 + 泄漏。本定义把它落成三个可测、可估计、可实验验证的标量通道。固定特征方向 v , 其残差为 g_v , 对应图像特征 $\phi_v(X) := v^\top \Phi(X)$ (Φ 同 (64))。定义:

(i) 识别强度 (*identifiability*)。数据分布 Q 能把该特征与文本条件分开的程度,

$$\text{Id}_Q(v) := \text{Var}_C(\mathbb{E}_Q[\phi_v(X) \mid C]). \quad (68)$$

此即识别算子 $\mathcal{I}_Q$ 的输出方差 (参 *Prop. 23.2*)。 $\text{Id}_Q(v) \rightarrow 0$ (即 $v \in \ker \mathcal{I}_Q$) $\Rightarrow$ *caption* 无法将其分离, 训练目标不能唯一决定其落点。

(ii) 可达强度 (**reachability**)。当前可训练子空间 S ($LoRA$ / $full-finetune$ / $target$ modules) 能写入该残差的比例,

$$\text{Reach}_S(v) := \frac{\|\Pi_{\mathcal{H}_S} g_v\|^2}{\|g_v\|^2}, \quad \mathcal{H}_S = \text{Range}(\mathcal{C}_n J_n|_S) \subset T_n. \quad (69)$$

$\text{Reach}_S(v) \rightarrow 0 \Rightarrow$ 即便数据可辨识, 模型/ $LoRA$ 几何也写不动它 (不可达通道)。

(iii) 泄漏强度 (**leakage**)。已写入部分中落入 *caption-invariant floor* $\mathcal{U}_n$ 的比例,

$$\text{Leak}_S(v) := \frac{\|\Pi_{\mathcal{U}_n} \Pi_{\mathcal{H}_S} g_v\|^2}{\|\Pi_{\mathcal{H}_S} g_v\|^2 + \epsilon}, \quad \epsilon > 0. \quad (70)$$

此即 (66) 的稳健化形式: 分母 $+\epsilon$ 避免在 $\|\Pi_{\mathcal{H}_S} g_v\| \approx 0$ (即特征本就不可达) 时比值爆炸——不可达方向的泄漏率不再良定义, ϵ 使诊断在该退化处平滑趋零, 把退化交回通道 (ii) 处理。

衰退风险 (**decay risk**)。把三通道合成单一诊断

$$\text{Risk}(v) = F\left(\text{Id}_Q(v)^{-1}, 1 - \text{Reach}_S(v), \text{Leak}_S(v)\right) \quad (71)$$

其中 $F: \mathbb{R}_{\geq 0}^3 \rightarrow \mathbb{R}_{\geq 0}$ 关于每个分量单调不减, 但不假设线性: F 由实验校准 (*calibrate*), 其形式与权重需经数据拟合, 而非先验设定。三个自变量分别对应“越不可辨识越糟” (Id_Q^{-1})、“越不可达越糟” ($1 - \text{Reach}_S$)、“越泄漏越糟” (Leak_S)。

Remark 24.5 (定性 $\rightarrow$ 可测: 三通道与分层标签). (68)–(70) 把定理 24.2 的三个口头通道 (不可辨识、不可达、泄漏到 *floor*) 各自换成一个可从训练分布与模型 **Jacobian** 直接估计的标量: Id_Q 由 *caption* 分组的条件均值方差估计, Reach_S 与 Leak_S 由对 $\mathcal{C}_n J_n$ 的投影范数估计。由此推论 24.3 中的每一格 (无触发词、同装束、触发词 + 描述、多装束、*SDXL vs FLUX*) 都成为可在 $(\text{Id}_Q, \text{Reach}_S, \text{Leak}_S)$ 三元组上读出的坐标, 而非定性断言。

分层。三个通道量 $\text{Id}_Q(v)$, $\text{Reach}_S(v)$, $\text{Leak}_S(v)$ 各为第一类 (可测、可估计的明确定义量, 给定 Q 、 Φ 、 J_n 后由期望/投影确定); 而把它们合成 $\text{Risk}(v)$ 的函数 F 为第三类 (经验校准的诊断假设, 单调但非线性, 须由实验确定形式与权重)。

25 两阶段对齐税与交叉项

不强行 $\text{Tax}_2 = \text{Tax}_2^u + \text{Tax}_2^c$ ——那只在投影、度量、可达空间都块对角时成立。先保留交叉项。

Theorem 25.1 (两阶段税的交叉项分解).

$$\text{Tax}_2(g) = \|(I - \Pi_{\mathcal{H}_2})g\|_{M_1}^2 + \lambda \|\delta\theta^*\|^2. \quad (72)$$

令 $g = g^u + g^c$, $g^u = \Pi_{\mathcal{U}_1} g$, $g^c = (I - \Pi_{\mathcal{U}_1})g$, 展开

$$\text{Tax}_2(g) = \text{Tax}_2^u + \text{Tax}_2^c + 2 \text{Cross}_2(g^u, g^c) \quad (73)$$

其中交叉项 Cross_2 由交换子 $[\Pi_{\mathcal{H}_2}, \Pi_{\mathcal{U}_1}]$ 控制。仅当 $\|[\Pi_{\mathcal{H}_2}, \Pi_{\mathcal{U}_1}]\| \approx 0$ (*firewall*) 时才可近似块对角化 $\text{Tax}_2 \approx \text{Tax}_2^u + \text{Tax}_2^c$ 。

Corollary 25.2 (社区风格泄漏 = *floor* 在 $\mathcal{U}_1$ 中不可达). 社区全量微调把 $\Pi_{\mathcal{U}_1} A_1$ (*caption-invariant floor*, *anime* 风格) 深度写入。用户 $LoRA$ 残差在 $\mathcal{U}_1$ 方向上: (i) 秩饥饿—— $\mathcal{U}_1$ 高维分布式, 秩- r $LoRA$ 至多覆盖 r 维, $\|\Pi_{S_2} \Pi_{\mathcal{U}_1}\|$ 容量受限; (ii) 移动代价——景观曲率大。 *floor* 对所有 c (含 $\emptyset$) 同在, 且由 *Prop. 23.2* 的响应算子, $\mathcal{R}_2$ 对它近零 $\Rightarrow$ *prompt*-不可约。这是势能 *floor* 层面的陈述。

Corollary 25.3 (交叉项的交换子上界). 延续 *Thm. 25.1* 的分解 (73)。交叉项 $\text{Cross}_2(g^u, g^c)$ 的来源精确地是: 可达投影 $\Pi_{\mathcal{H}_2}$ 不尊重 $\mathcal{U}_1/\mathcal{V}_1$ 分解, 即 $[\Pi_{\mathcal{H}_2}, \Pi_{\mathcal{U}_1}] \neq 0$ 。分两档陈述。

- (精确恒等式) 若交换子消失 $[\Pi_{\mathcal{H}_2}, \Pi_{\mathcal{U}_1}] = 0$ (*block-diagonal*, 完美 *firewall*), 则 $\Pi_{\mathcal{H}_2}$ 保持 $\mathcal{U}_1$ 与 $\mathcal{V}_1$ 不变, $\Pi_{\mathcal{H}_2}g^u \in \mathcal{U}_1$ 、 $\Pi_{\mathcal{H}_2}g^c \in \mathcal{V}_1$, 二者在 M_1 下正交, 故

$$\text{Cross}_2(g^u, g^c) = 0, \quad \text{Tax}_2 = \text{Tax}_2^u + \text{Tax}_2^c.$$

- (局部二阶近似) 当交换子小而非零时, $\Pi_{\mathcal{H}_2}g^u$ 会渗入 $\mathcal{V}_1$ 、 $\Pi_{\mathcal{H}_2}g^c$ 会渗入 $\mathcal{U}_1$, 渗入量由交换子范数控制, 交叉项满足近似上界

$$|\text{Cross}_2(g^u, g^c)| \lesssim \|[\Pi_{\mathcal{H}_2}, \Pi_{\mathcal{U}_1}]\| \|g^u\|_{M_1} \|g^c\|_{M_1} \quad (74)$$

(范数取 M_1 度量; $\lesssim$ 略去对 $\Pi_{\mathcal{H}_2}$ 有界性的常数因子)。

解读。交叉项的大小由同一个交换子范数 $\kappa_2 = \|[\Pi_{\mathcal{H}_2}, \Pi_{\mathcal{U}_1}]\|$ 支配——这正是泄漏上界 (61) 中度量 *firewall* 强度的量。换言之, 两阶段税的不可分离性 (Tax_2 不块对角) 与社区风格泄漏 (*floor* 被搅动) 由同一架构常数驱动: κ_2 大则二者同时大, $\kappa_2 \approx 0$ 则二者同时消失。本结论为第二类陈述 (局部二阶近似): 它依赖 *Thm. 25.1* 的二次税近似与算子有界性, 而非无条件恒等式。

26 条件扩散 / Flow Matching: 文本作为静态变量

扩散/FM 下不需单独处理文本。令路径 $(C, X_{0:1})$, C 静态、 X_t 图像路径, 条件 path measure $P_n^{\text{path}, \rho}(dc, dX_{0:1}) = \rho(dc)P_n^{\text{path}}(dX_{0:1} | c)$, 路径势能

$$\mathcal{A}_n(c, X_{0:1}) = \log \frac{dP_n^{\text{path}}(\cdot | c)}{dP_0^{\text{path}}(\cdot | c)}(X_{0:1}), \quad B_{n,t}(c, x_t) = \log \frac{p_{n,t}(x_t | c)}{p_{0,t}(x_t | c)}. \quad (75)$$

Theorem 26.1 (条件版 posterior cumulant 递推). 若路径上更新 $\Delta A(c, z)$, 则平滑边缘势能更新为后验 *log-MGF* (条件于 $C = c, X_t = x_t$):

$$B_{n+1,t}(c, x_t) - B_{n,t}(c, x_t) = \log \mathbb{E}_{P_n}[e^{\Delta A(C, Z)} | C = c, X_t = x_t] - \psi(c) \quad (76)$$

完全继承第一部分的 *cumulant* 展开, 无需引入 “CFG score covariance” 这类工程解释。caption-invariant/contrastive 分解亦在 $L^2(C, X_t)$ 上做投影 $\Pi_{\mathcal{U}_{n,t}}, I - \Pi_{\mathcal{U}_{n,t}}$ 。

27 统一主定理

Theorem 27.1 (Conditional projected residual dynamics). 给定 caption 环境 ρ 、条件模型族 $p_\theta(x | c)$ 、当前模型 P_n^ρ 、目标 Q_{n+1}^* , 令条件残差

$$g_{n+1} = C_n \left[\log \frac{dQ_{n+1}^*}{dP_n} \right] \in T_n,$$

可训练子空间诱导可达空间 $\mathcal{H}_{n+1} = \text{Range}(C_n J_n |_{S_{n+1}}) \subset T_n$ 。则局部二阶近似下有效更新

$$h_{n+1}^* = \Pi_{\mathcal{H}_{n+1}}^{M_n, \lambda} g_{n+1}, \quad \frac{dP_{n+1}(\cdot | c)}{dP_n(\cdot | c)} \propto \exp(\eta h_{n+1}^*(c, \cdot)).$$

进一步:

- **caption-invariant** 泄漏 由 $\text{Leak}_{n+1}(g) = \frac{\|\Pi_{\mathcal{U}_n} h_{n+1}^*\|_{M_n}^2}{\|h_{n+1}^*\|_{M_n}^2}$ 给出, $\mathcal{U}_n = \overline{\{a(X) - \mathbb{E}_{P_n}[a(X) | C]\}}$;
- **prompt** 可控性 由响应算子 $\mathcal{R}_n$ 给出;
- 数据可辨识性 由识别算子 $\mathcal{I}_Q$ 给出;
- 架构影响 由 $\mathcal{H}_{n+1}$ 与 $\Pi_{\mathcal{U}_n}$ 的相对位置 (交换子 κ 、泄漏 L) 给出。

Theorem 27.2 (Conditional Regularized Residual Response Dynamics (补强版主定理)). 设 *caption* 环境 ρ , 联合测度 $P_n^\rho(dc, dx) = \rho(dc) p_n(dx | c)$; 目标条件测度 $Q_{n+1}^*(\cdot | c)$ 满足 ρ -a.e. 的绝对连续性 $Q_{n+1}^*(\cdot | c) \ll P_n(\cdot | c)$ 。逐 *fiber* 取条件 *centered residual*

$$g_{n+1} = \mathcal{C}_n \left[\log \frac{dQ_{n+1}^*}{dP_n} \right] \in T_n, \quad T_n = \{h : \mathbb{E}_{P_n}[h | C = c] = 0 \text{ } \rho\text{-a.e.}\}.$$

令 *centered Jacobian* $\bar{J}_n = \mathcal{C}_n J_n$ ($J_n = \nabla_\theta A_\theta|_{\theta_n}$); 局部训练问题

$$\delta\theta^* = \arg \min_{\delta\theta \in S_{n+1}} \left\{ \frac{1}{2} \|g_{n+1} - \bar{J}_n \delta\theta\|_{M_n}^2 + \frac{\lambda}{2} \|\delta\theta\|_{\Gamma_n}^2 \right\},$$

其唯一解给出可达响应 (*reachable response*)

$$h_{n+1}^* = \bar{J}_n \delta\theta^* = \mathcal{L}_{n+1} g_{n+1}, \quad \mathcal{L}_{n+1} = \bar{J}_n (\bar{J}_n^\top M_n \bar{J}_n + \lambda \Gamma_n)^{-1} \bar{J}_n^\top M_n,$$

其中 $\mathcal{L}_{n+1} : T_n \rightarrow \mathcal{H}_{n+1} = \text{Range}(\mathcal{C}_n J_n|_{S_{n+1}})$ 是 M_n 自伴的 *ridge*-正则响应算子 ($\lambda \rightarrow 0^+$ 时退化为 $\Pi_{\mathcal{H}_{n+1}}^{M_n, \lambda}$)。则有以下结论。

(i) 条件势能更新 (精确恒等式, 第一类)。写入比例 $\alpha \in [0, 1]$,

$$A_{n+1}(c, x) = A_n(c, x) + \alpha h_{n+1}^*(c, x) - \psi_{n+1}(c) + \mathcal{E}_{n+1}(c, x) \quad (77)$$

其中 *fiberwise* 归一化 (*log-partition*) 项

$$\psi_{n+1}(c) = \log \mathbb{E}_{P_n(\cdot|c)} \exp(\alpha h_{n+1}^*(c, X)). \quad (78)$$

(77) 按构造为恒等式: $\mathcal{E}_{n+1}$ 被定义为使等式逐 *fiber* 严格成立的残项, 故其本身属第一类。 $\psi_{n+1}(c)$ 是理想 *tilt* $\exp(\alpha h_{n+1}^*)$ 的 *log-MGF* 配平量; 当 $\mathcal{E}_{n+1} \equiv 0$ 时

$$\frac{dP_{n+1}(\cdot | c)}{dP_n(\cdot | c)}(x) = \exp(\alpha h_{n+1}^*(c, x) - \psi_{n+1}(c))$$

在每条 *fiber* 上自动归一 ($\mathbb{E}_{P_n(\cdot|c)}[\cdot] = 1$); $\mathcal{E}_{n+1} \neq 0$ 时真实更新对纯 *tilt* 的偏离全部计入 $\mathcal{E}_{n+1}$ 。注意 $-\psi_{n+1}(c) \in \sigma(C)$, 是纯条件 *gauge*, 不落在 T_n 中。

(ii) 误差分解 (第二类记账)。残项

$$\mathcal{E}_{n+1} = \mathcal{E}_{\text{lin}} + \mathcal{E}_{\text{opt}} + \mathcal{E}_{\text{sample}} + \mathcal{E}_{\text{model}} + \mathcal{E}_{\text{target}}, \quad (79)$$

依次为: $\mathcal{E}_{\text{lin}}$ 一阶 *Jacobian* 线性化 (A_θ 关于 $\delta\theta$ 的非线性高阶项); $\mathcal{E}_{\text{opt}}$ 有限步优化未达 $\delta\theta^*$; $\mathcal{E}_{\text{sample}}$ 经验 M_n 、有限样本与采样近似; $\mathcal{E}_{\text{model}}$ 度量误指定 (M_n 偏离真 *Fisher/NTK*); $\mathcal{E}_{\text{target}}$ 目标 Q_{n+1}^* 估计偏差 (含 *reward/posterior* 误差)。故补强之义在于: 所有近似都被显式归入 $\mathcal{E}_{n+1}$, 不再隐含于裸投影中; 当 $\mathcal{E}_{n+1} \equiv 0$ 时(77) 退化为精确恒等式。

(iii) 平滑边缘的精确形式 (第一类)。对任意 *smoothing kernel* 诱导的边缘势能 $B_{n,t}(c, x_t) = \log(p_{n,t}/p_{0,t})$, 逐 *fiber* 后验 *log-MGF*

$$B_{n+1,t}(c, x_t) - B_{n,t}(c, x_t) = \log \mathbb{E}_{P_n}[e^{\alpha h_{n+1}^*(C, X)} | C = c, X_t = x_t] - \psi_{n+1}(c) \quad (80)$$

(取 $\mathcal{E}_{n+1} \equiv 0$, 否则在指数内追加 $\mathcal{E}_{n+1}(C, X)$)。其 *posterior-cumulant* 展开

$$B_{n+1,t} - B_{n,t} = \mathbb{E}[\alpha h_{n+1}^* | c, x_t] + \frac{1}{2} \text{Var}(\alpha h_{n+1}^* | c, x_t) + \frac{1}{6} \kappa_3(\alpha h_{n+1}^* | c, x_t) + \cdots - \psi_{n+1}(c),$$

其中 $\kappa_j(\cdot | c, x_t)$ 为后验分布 $P_n(\cdot | C = c, X_t = x_t)$ 下的 j 阶 *cumulant*。小步 $\alpha \rightarrow 0$ 时一阶项主导, 恢复(26) 的无条件 *cumulant* 结构; 高阶 Var 、 κ_3 项即 *fiberwise* 的曲率/偏度修正。

Remark 27.3 (与 27.1 的关系). (77)–(80) 是 *Thm. 27.1* 的严格合并版: 把其中裸投影 $\Pi_{\mathcal{H}_{n+1}}^{M_n, \lambda}$ 换成正则响应算子 $\mathcal{L}_{n+1}$ (使 λ 、 Γ_n 与 S_{n+1} 容量显式入账), 把裸加性更新 $A_{n+1} \approx A_n + \eta h^*$ 换成 *fiberwise posterior log-MGF* ((78) 的 $\psi_{n+1}(c)$ 配平与(80) 的高阶 *cumulant*)。其中恒等式部分 (势能配平、*log-MGF*) 为第一类, 永真; 局部训练解 $\delta\theta^*$ 、线性化 $h_{n+1}^* = \mathcal{L}_{n+1} g_{n+1}$ 及小步 *cumulant* 截断为第二类 (局部二阶近似), 其偏差全部归入(79) 的 $\mathcal{E}_{n+1}$ 。

27.1 对象词典

框架中的每个对象及其刻画的内容：

Table 2: 框架的对象及其含义

对象	含义
$A_n(c, x)$	条件累计势能，相对基座的 log-density 偏移
T_n	条件切空间（每个 fiber 上零均值）
$g_{n+1} = \mathcal{C}_n[\cdot]$	条件中心化残差
$\Pi_{\mathcal{U}_n} A_n$	caption-invariant 分量（对所有 caption 共同的图像侧 floor）
$A(x \emptyset)$	null-caption fiber potential ($\emptyset$ fiber 上的求值)
$\mathcal{R}_n$	干预响应算子，刻画 prompt 可控性
$\mathcal{K}(d\tilde{c} c)$	caption dropout 通道，降低 $I(X; \tilde{C})$
$\sigma(C)$	caption 生成的 σ -代数
$\ker \mathcal{I}_Q$	识别算子的近零方向（对 $\sigma(C)$ 不可辨识）
$\mathcal{H}_S = \text{Range}(\mathcal{C}_n J_n _S)$	可达子空间，由架构与训练参数决定
$\ [\Pi_{\mathcal{H}_S}, \Pi_{\mathcal{U}_n}]\ $	firewall 强度（交换子范数 κ_S ）
$L_S(g)$	泄漏分数，残差落入 floor 的比例
Cross_2	两阶段税的交叉项，由交换子控制
$\mathcal{I}_Q, \Pi_{\mathcal{H}_S}, \Pi_{\mathcal{U}_n}$	衰退矩阵的三个组合算子

27.2 框架的逻辑链

整条逻辑链是

(C, X) 联合测度 $\rightarrow T_n$ 切空间 $\rightarrow g$ 中心化残差 $\rightarrow \Pi_{\mathcal{H}} g$ 可达更新 $\rightarrow \Pi_{\mathcal{U}} \Pi_{\mathcal{H}} g$ floor 泄漏 $\rightarrow \mathcal{R}, \mathcal{I}$ 判可控/可辨识

工程细节只通过三个对象进入：训练数据分布 Q 、可训练子空间 S 、完整 Jacobian J_n 。

全局一句话：加入文本条件后，T2I 后微调是联合条件测度上的残差投影动力学。把文本作为测度空间的一部分，在条件切空间 T_n 上做中心化残差 g 、可达投影 $\Pi_{\mathcal{H}} g$ 、caption-invariant 泄漏 $\Pi_{\mathcal{U}} \Pi_{\mathcal{H}} g$ ；prompt 可控性由响应算子 $\mathcal{R}_n$ 给出、数据可辨识性由识别算子 $\mathcal{I}_Q$ 给出、架构影响由 $\mathcal{H}$ 与 $\mathcal{U}$ 的交换子给出。衰退矩阵、对齐税、firewall、SDXL/FLUX 排序都是这三个算子在不同 Q, S, J_n 下的取值。

28 补强要点：原框架跳跃的修补

本节集中修补原框架中五处“把近似当恒等式”的跳跃，逐条以“原表述 X 应替换为 Y”给出更精确的层级归属（精确恒等式 / 局部二阶近似 / 经验假设），并以最精炼的新版总述收束全文。

- 投影即更新（修补一）：原表述把有限模型的训练写成纯几何投影

$$A_{n+1} - A_n \approx \eta \Pi_{\mathcal{H}_{n+1}} (U_{n+1}^* - A_n),$$

应替换为正则化线性响应。设 $J_n = \nabla_{\theta} A_{\theta}|_{\theta_n}$ 、可训练子空间 S_{n+1} 、训练度量 M_n 、岭权 λ ，定义

$$\mathcal{L}_{J,S,M,\lambda}(f) := \mathcal{C}_n J_n (J_n^{\top} \mathcal{C}_n^{\top} M_n \mathcal{C}_n J_n + \lambda \Gamma_n)^{-1} J_n^{\top} \mathcal{C}_n^{\top} M_n f, \quad f = \log \frac{dQ_{n+1}^*}{dP_n}.$$

则有效更新是 $h_{n+1}^* = \mathcal{L}_{J,S,M,\lambda}(f)$ ，而非 $\Pi_{\mathcal{H}_{n+1}}^{M_n, \lambda} f$ 。层级：局部二阶近似。仅当 $\lambda \rightarrow 0$ 、 J_n 在 S_{n+1} 上满秩且 $\Gamma_n = \text{id}$ 时， $\mathcal{L}_{J,S,M,\lambda}$ 才退化为到 $\mathcal{H}_{n+1} = \text{Range}(\mathcal{C}_n J_n |_{S_{n+1}})$ 的 M_n -正交投影。有限模型的训练不是纯投影：参数化几何 Γ_n 、岭最小范数偏置与 J_n 的奇异值谱共同决定残差在 $\mathcal{H}_{n+1}$ 内的实际写入（局部线性响应定义 6.2），参见(16)–(18)。

- **FM 桥（修补二）**：原表述直接把目标 Q^* 接到 Flow-Matching 损失。应替换为经路径测度的三步链

$$Q^* \rightsquigarrow Q^{\text{path}} \rightsquigarrow \text{stochastic path-KL (Girsanov)} \rightsquigarrow \text{weighted FM}.$$

即先把零时刻目标提升为路径测度 Q^{path} ，再用 Girsanov 把随机 path-KL 写成漂移差的二次型，最后得到带 Radon–Nikodym 权重的 FM 目标（见(13)–(14)）。层级：随机情形为精确恒等式（**Girsanov**）；确定性情形为极限/近似。确定性 FM 不是该链的特例，须经 vanishing-noise 极限或改用 transport-action（最优传输作用量）刻画，方能与随机 path-KL 对齐（确定性 FM 命题 5.4）。

- **dropout 抬升 floor（修补三）**：原表述断言 caption dropout 使互信息 $I(X; \tilde{C})$ 严格下降并由此推得 floor 比例上升。应替换为两段式陈述。数据处理不等式（DPI）只给

$$I_{\tilde{Q}}(X; \tilde{C}) \leq I_Q(X; C)$$

（弱不等式，可取等；见(55)），这是精确（可证）层级的弱上界。要把“互信息不增”升级为“caption-invariant 投影比例严格上升”，须额外引入 *contrastive-contraction* 假设：腐化通道对 contrastive 子空间 $\mathcal{V}_n$ 的能量为严格压缩。在该经验假设下方得 floor 比例 $\|\Pi_{\mathcal{U}_n} \tilde{g}\|^2 / \|\tilde{g}\|^2$ 严格增大（contrastive-contraction 命题 21.2），见 Prop. 21.2。层级：上界精确，比例上升为经验假设。

- **FLUX/SDXL 排序（修补四）**：原表述把“FLUX 比 SDXL 更易把对象写进 floor”当作结构性定论。应替换为可测量 + 经验估计。框架只定义两个 operator 量

$$L_S(g) = \frac{\|\Pi_{\mathcal{U}_n} \Pi_{\mathcal{H}_S} g\|_{M_n}^2}{\|\Pi_{\mathcal{H}_S} g\|_{M_n}^2}, \quad \kappa_S = \|\Pi_{\mathcal{H}_S}, \Pi_{\mathcal{U}_n}\|,$$

见(60)–(61)（floor-泄漏与交换子命题 22.3）。“谁更大”（ $L_{\text{FLUX}} \gtrless L_{\text{SDXL}}, \kappa_{\text{FLUX}} \gtrless \kappa_{\text{SDXL}}$ ）是对相关目标残差 g 的实验估计，不是框架推论，见 Prop. 22.2 与(62)。层级：量为定义/精确，排序为经验假设。

- **衰退矩阵（修补五）**：原表述以“衰退矩阵伪定理”列举数据/标签格子。应替换为三通道风险诊断。对特征方向 v （残差 g_v ），把衰退严重度写成三个独立通道的函数

$$\text{Risk}(v) = F(\mathcal{I}_Q^{-1}, 1 - \text{Reach}_S(g_v), \text{Leak}_S(g_v)),$$

其中识别通道 $\mathcal{I}_Q^{-1}$ 度量对 $\sigma(C)$ 的不可辨识（ $v \in \ker \mathcal{I}_Q$ ）、可达通道 $\text{Reach}_S(g_v) = \|\Pi_{\mathcal{H}_S} g_v\| / \|g_v\|$ 、泄漏通道 Leak_S 同(66)；三者由三通道诊断定义 `def:three_channel` 给出，对应 Thm. 24.2 的算子分解。层级：三通道为精确算子诊断，矩阵格子降级为该诊断在不同 Q, S, J_n 下的取值（**Cor. 24.3**）。

最精炼的新版总述：多阶段对齐 = 每阶段相对当前模型 P_n 的条件 log-density 残差 $\log(dQ_{n+1}^*/dP_n)$ ，在每个 caption fiber 上中心化（ C_n ，落入条件切空间 T_n ），再由 Jacobian J_n 、可训练子空间 S_{n+1} 、训练度量 M_n 与岭正则 λ 共同诱导的局部线性响应 $\mathcal{L}_{J,S,M,\lambda}$ 写入——不是纯投影。在扩散 / Flow-Matching 中，所写入的势能经平滑核变为后验 log-MGF 的边缘景观（cumulant 展开，(76)），随机情形由 Girsanov 精确、确定性情形取 vanishing-noise / transport-action 极限。T2I 衰退由三通道诊断：识别（数据对 $\sigma(C)$ 的可辨识性 $\mathcal{I}_Q$ ）、可达（ $\Pi_{\mathcal{H}_S}$ 能否写该残差）、floor-泄漏（ $\Pi_{\mathcal{U}_n} \Pi_{\mathcal{H}_S}$ 落入 caption-invariant 子空间的比例）。其中 SDXL/FLUX 的架构排序是经验命题（对 L_S, κ_S 的实验估计），而非框架推论；prompt 可控性由响应算子 $\mathcal{R}_n$ 、阶段间对齐税的交叉项由交换子 $[\Pi_{\mathcal{H}}, \Pi_{\mathcal{U}}]$ 控制。