

全集-真子集多阶段对齐的状态递推理论

残差势能、全局 COV 几何、纤维继承/重建与复合二次型最优控制

(严格化重写：补全逻辑跳步、消除误导性符号，逐步建立逻辑链)

Abstract

本文把”全集 D_1 与真子集 $D_2 \subsetneq D_1$ 的两阶段对齐”整理为一套状态递推控制理论。第一阶段用 D_1 训练后，模型不仅得到一个全局数据场 / COV 几何估计 G_1 ，也在该几何上为 D_2 中的子点建立了势能估计 B_1^S ；第二阶段用 D_2 继续训练，真正的决策不是”学不学”，而是继承第一阶段的同一 **fiber**，还是用真子集重建 **fiber** 以降低全集投影偏差。该决策由偏差、方差、可达性、势能残差与终端目标共同决定。

本稿是对原始讨论稿的严格化重写。相对原稿，本稿 (i) 统一并消除误导性符号 (COV 而非卷积、三个不同的 R 、Hessian H_Y 与假设空间 $\mathcal{H}_i$ 、投影 Π 与线性响应 $\mathcal{L}$)；(ii) 补全原稿中以” $\approx$ ”或未定义算子 ($\mathcal{R}_z$ 、 A_S 、 δ_B) 掩盖的逻辑跳步，给出显式定义与所需假设；(iii) 对每一结论标注其层级 (精确恒等式 / 局部二阶近似 / 经验假设)。所有”某策略更好”的判断都落到可测诊断量，而非无条件定理。

核心状态递推: $S_{i+1} = F_i(S_i, u_i) = S_i + \eta_i \mathcal{L}_i(S_i, u_i) \mathbf{g}_i(S_i, u_i) + E_i$, $S_i = (B_i, G_i)$, 残差 $\mathbf{g}_i = (g_i^{(0)}, \sqrt{\rho_G} g_i^{(G)})$ 由势能残差与全局 COV 残差堆叠; $\mathcal{L}_i$ 是带岭收缩的线性响应算子, 而非正交投影。

Contents

1	使用说明、符号约定与结论分级	4
2	总论与状态空间	5
2.1	核心论点：策略空间受状态递推控制	5
2.2	复合状态空间	6
2.3	状态递推	6
2.4	控制变量	7
2.5	三条推论	7
3	数据分布：全集、真子集与隐变量测度	8
3.1	隐变量结构	8
3.2	无标签纯图像分布： N 阶联合测度	8
3.3	阶段数据分布	9
3.4	全集与真子集	10
4	从经验测度到全局 COV 几何	11
4.1	经验测度与平滑条件密度	11
4.2	无标签 N 阶 posterior 与 COV 场	11
4.3	Posterior responsibility 是精确的 Radon-Nikodym 权重	13
4.4	Score 与 Hessian 的精确分解	13
4.5	全局 COV 几何状态与局部还原算子	14

5	残差势能与 RLHF 形式	14
5.1	累计势能与目标势能	15
5.2	Gibbs 闭式解与残差 reward	15
5.3	目标分布的几何平均与 preference-tilt 形式	16
5.4	fiberwise centering 与势能残差 $g_i^{(0)}$	17
6	双残差：势能残差与全局 COV 残差	17
6.1	动机：单看势能残差不够	17
6.2	全局 COV 残差	18
6.3	复合残差 Hilbert 空间	18
6.4	局部二阶残差分解（修正“ $\approx$ ”）	19
6.5	概念修正：不直接优化局部 COV，而是限制全局几何	19
7	复合二次型最优控制与 minmax	20
7.1	控制变量	20
7.2	可达响应算子	20
7.3	状态递推与阶段二次型损失	21
7.4	多步最优：Bellman 递推	22
7.5	Robust minmax	22
8	全集-真子集推论：偏差、方差与可达性	23
8.1	子集势能 B_1^S ：在受限几何上的对齐映射	23
8.2	几何估计的偏差-方差分解	23
8.3	势能可定义性误差：从几何扰动到势能扰动	24
8.4	核心张力与重建判据	24
9	重点案例：先画风后人物	25
9.1	正确的设定：两阶段、真子集、而非新数据	26
9.2	第一阶段的实质：同时做两件事	27
9.3	第二阶段的实质：是否用子集几何修正全集投影	27
10	纤维继承与纤维重建的策略空间	29
10.1	纤维继承： $c_S^{(2)} = c_S^{(1)}$	29
10.2	纤维重建： $c_S^{(2)} \neq c_S^{(1)}$	29
10.3	核心判别式：期望残差能量的二次型比较	30
11	单步与多步策略分类	30
11.1	为什么大合集 LoRA 常失败	31
12	推广到 LLM 与一般任务	32
12.1	潜变量与几何的对应映射	32
12.2	两阶段结构的同构	32
12.3	LLM 中的几何状态 G	33
12.4	一般化结论	34
13	可测诊断量、判别条件与失败模式	34
13.1	诊断量总表	35
13.2	失败模式	36
14	形式化命题与推论	36
14.1	残差势能与数据场曲率（精确结构）	37
14.2	全集-真子集的偏差-方差分解	38
14.3	策略最优性的条件结构	38

15 术语表、参考文档与公式总览 **39**

15.1 术语表 39

15.2 参考文档 39

15.3 公式总览 41

1 使用说明、符号约定与结论分级

本文是对原始讨论稿《全集-真子集多阶段对齐理论框架与策略空间》的严格化重写。重写的目标有三：(a) 补全原稿以“ $\approx$ ”或未定义算子掩盖的逻辑跳步，使每一步推理链显式且可检验；(b) 消除原稿中误导性或一符多义的记号；(c) 对每一条结论显式标注其逻辑地位，使读者在引用时即可判断它在何种前提下成立。本节为元章节（不含定理），仅约定阅读方式、结论分级与全篇贯通的符号修正。后文各节的 boxed 核心结论均按本节的分级规则加标。

COV 的含义

全篇“COV 场”一律指 *posterior score covariance* / 数据场协方差几何（即对 posterior responsibility α_i 取的 score 协方差 $\Sigma_i^D = \text{Cov}_{\alpha_i}(s_Y)$ 及其全局聚合），绝不指卷积 **convolution**。原稿在个别处误写为“CONV”，凡此皆应读作 COV。卷积仅以光滑核 K_t 的作用出现，且始终显式写作 $q_t(x|y) = \int K_t(x - x') q(x'|y) dx'$ ，不与 COV 混用。

结论的三层分级

本文所有结论分属三层，其成立条件、可证伪性与“无条件成立”的资格各不相同。把不同层混为一谈——尤其把第二、三类当第一类引用——是本框架最主要的 over-claiming 来源。三层定义如下。

- 第 1 类 精确恒等式 (**exact identities**)。只要陈述中声明的测度前提（绝对连续性、目标势能存在、fiber 归一化、Girsanov 可积性等）成立，此类结论无条件成立，是定义与变分计算的直接后果，不依赖任何线性化或近似，前提满足即不可证伪。
- 第 2 类 局部二阶近似 (**local 2nd-order approximations**)。此类结论并非恒等式，其成立需显式附带假设：局部线性化有效、步长 η_i 足够小、被作用对象足够正则、且优化在最优解附近。脱离这些假设，误差进入残差项 E_i 而不再可控。引用时必须同时声明上述近似前提。
- 第 3 类 经验假设 / 可测诊断 (**empirical assumptions / measurable diagnostics**)。此类陈述涉及具体数据、架构与训练机制的实际行为，原则上不能写成无条件定理，只能作为可证伪的假设或可测量的诊断量给出，其“真”由实验在给定语境下检验，而非由推导保证。

据此，原稿的若干典型断言归层如下：

- RLHF 的残差势能形式（目标势能与基座之差落为 Gibbs 型残差 reward 的变分结构）为第一类——精确变分结构，见 Sec. 5。
- LoRA 可达投影（将有限参数 / LoRA 更新写成在可达子空间 $\mathcal{H}_i$ 上的投影更新）、局部线性响应（训练算子 $\mathcal{L}_i$ 的线性化）、COV $\rightarrow$ 局部景观的投影（全局几何 G_i 经 $\mathcal{R}_z$ 还原为局部二阶型 $\Sigma_i^{\text{loc}}(z)$ ）均为第二类——局部二阶近似，所需线性化 / 小步长 / 正则性假设在 Sec. 4、Sec. 7、Sec. 8 显式补足。
- 任何“某训练策略更好”的判断必须是第三类——落到可测诊断量（偏差、方差、可达性、势能残差的可测代理），而非无条件定理，见 Sec. 13。

阅读重点

全篇最易被误读、也最需要先行确立的抽象，归纳于下框。

Remark 1.1 (阅读重点: B_1^S 的正确解读).

第一阶段（用全集 D_1 训练）后，限制在真子集 $S = D_2$ 上得到的“已经正确学会 D_2 ”的标志。它的准确含义是：全集几何 G_1 经限 **fiber** S 上之后，得到的一个稳定但可能有偏的势能估计。其“稳定”指低方差，其“偏”来自全集投影未必对齐子集真实目标。因此第二阶段的核心问题，不是“学不学 D_2 ”，而是是否纠正这一投影偏差：继续意味着低方差、低残差但保留偏差；用真子集重建 **fiber** 意味着可能更高的方差与可达性风险。

符号与跳步修正清单

为消除原稿一符多义与跳步，本稿强制以下修正与约定。引用任一记号时以此为准。

Remark 1.2 (符号与跳步修正清单). • COV $\neq$ 卷积。COV 指 *posterior score covariance* / 数据场协方差几何 ($\Sigma_i^D = \text{Cov}_{\alpha_i}(s_Y)$ 及其全局态 G_i)；原稿偶写的“CONV”一律读作 COV，与卷积 *convolution* 无关。

- 三个 R 严格分离。(i) *reward* 记为 R_i (*plain* R ，带阶段下标)；(ii) *restriction* / 全局 $\rightarrow$ 局部算子记为 $\mathcal{R}_z, \mathcal{R}_S$ (*calligraphic* $\mathcal{R} = \mathcal{R}$)；(iii) 隐变量残差因子记为分量 R ，且仅出现在隐变量元组 $y = (A, P, W, R)$ 内部 (A 风格/域、 P 角色/实体、 W 可控属性、 R 残差视觉因子)，不作独立标量使用。
- **Hessian** $H_Y \neq$ 子空间 $\mathcal{H}_i$ 。条件 *log-density* 的 *Hessian* 记为 $H_Y = \nabla_x^2 \log q_t(x|y)$ (*plain* H ，二阶导张量)；可达 / 假设 / *LoRA* 子空间记为 $\mathcal{H}_i$ (*calligraphic* $\mathcal{H}$ ，线性子空间)。二者是不同对象，绝不以裸 H_i 指代子空间。
- 训练算子是线性响应 $\mathcal{L}_i$ ，不是投影 Π 。 $\mathcal{L}_i$ 为带岭收缩 (*ridge* λ_i) 的线性响应算子，一般不是投影；仅当 $\lambda_i \rightarrow 0$ 、值域闭、度量 M_i 固定的极限下， $\mathcal{L}_i$ 才退化为正交投影 Π 。叙述中不得把 $\mathcal{L}_i$ 称作投影，见 *Sec. 7*。
- 补足被跳步掩盖的算子定义。原稿以“ $\approx$ ”或未加定义的 $\mathcal{R}_z$ 、 A_S 、 δ_B 掩盖的步骤，本稿给出显式定义： $\mathcal{R}_z : \mathcal{G} \rightarrow \text{Sym}$ 的局部还原与子集还原 $\mathcal{R}_S$ 在 *Sec. 4* 定义；偏差 / 方差分解中的 A_S 、 δ_B 类量在 *Sec. 8* 给出严格定义与所需假设。*fiberwise* 中心化算子统一为 $\mathcal{C}_{i-1}[f](c, x) = f(c, x) - \mathbb{E}_{p_{i-1,t}(\cdot|c)}[f(c, X)]$ 。

全局状态记号备查。复合状态 $S_i = (B_i, G_i) \in \mathcal{S} = \mathcal{B} \times \mathcal{G}$ ，其中 B_i 为累计势能状态、 G_i 为全局 COV / 几何状态；复合残差 $\mathbf{g}_i = (g_i^{(0)}, \sqrt{\rho_G} g_i^{(G)})$ 由势能残差 $g_i^{(0)} = \mathcal{C}_{i-1}[U_i^* - B_{i-1}]$ 与全局 COV 残差 $g_i^{(G)} = G_i^* - G_{i-1}$ 堆叠；训练控制 $u_i = (\nu_i, T_i, \gamma_i, \Phi_i^\dagger, \mathcal{H}_i, M_i, \lambda_i, \eta_i)$ 。核心递推 $S_{i+1} = S_i + \eta_i \mathcal{L}_i \mathbf{g}_i + E_i$ 中， E_i 为高阶残差项（承接第二类近似的误差）。

2 总论与状态空间

本节给出全文的核心论点与状态空间定义，并写出贯穿全文的状态递推方程。后续各节（数据测度、COV 几何、残差势能、双残差、复合二次型控制等）都是对本节算子 $\mathcal{L}_i$ 、残差 $\mathbf{g}_i$ 与误差项 E_i 的具体化。

2.1 核心论点：策略空间受状态递推控制

本理论不主张存在一份固定的数据配方使其在所有阶段、所有任务中恒为最优。我们要证明的是一条结构性命题：在“全集 D_1 与真子集 $D_2 \subsetneq D_1$ 的多阶段对齐”中，可行策略的空间本身被一个状态递推（**state recursion**）所支配。具体而言，每一步训练的目标（*target potential* 与 *target geometry*）由当前模型状态重新定义；该步训练的结果又改变下一步所面对的四类对象：

- 累计势能 B_i (*cumulative potential*)，即相对基座模型的对数密度比；
- 全局 COV 几何 G_i (*posterior score covariance* / *data-field geometry*，见 *Sec. 4*)；

- (iii) 训练度量 M_i (training metric) 与其诱导的可达响应;
- (iv) 可达空间 $\mathcal{H}_i$ (reachable / hypothesis / LoRA subspace)。

因此“哪种策略更好”不是一个无条件定理，而是一个依赖当前状态的条件最优问题。下面先精确定义状态对象，再写出递推，最后把上述论点落为三条带层级标注的推论。

2.2 复合状态空间

Definition 2.1 (复合状态空间与状态对象). 设

$$\mathcal{S} = \mathcal{B} \times \mathcal{G}, \quad S_i = (B_i, G_i) \in \mathcal{S}, \quad (1)$$

其中:

- $\mathcal{B}$ 是纤维中心化 (fiberwise-centered) 的累计势能函数空间。其元素 $B_i(c, x, t) = \log[p_{i,t}(x|c)/p_{0,t}(x|c)]$ 是阶段- i 模型相对基座模型 $p_{0,t}$ 的对数密度比; 只依赖条件 c 的常数被归一化吸收, 故在每个 *caption fiber* 上以中心化算子 $C_{i-1}[f](c, x) = f(c, x) - \mathbb{E}_{p_{i-1,t}(\cdot|c)}[f(c, X)]$ 取等价类 (详见 Sec. 5)。
- $\mathcal{G}$ 是全局 COV / posterior-cumulant 几何空间。其元素 G_i 刻画由阶段数据测度 ν_i 与 posterior responsibility α_i 诱导的全局二阶 (score covariance) 几何; 它通过 restriction 算子 $\mathcal{R}_z: \mathcal{G} \rightarrow \text{Sym}$ 投影为局部点 $z = (c, x, t)$ 处的局部二阶型 $\Sigma_i^{\text{loc}}(z)$ (详见 Sec. 4)。

Remark 2.2. 强调 G_i 是全局几何而非某个局部点的 Hessian: 局部景观 $\Sigma_i^{\text{loc}}(z) \approx \mathcal{R}_z(G_i)$ 由全局几何在目标 fiber 上的投影给出。这一区分是后文“全集投影偏差” ($\mathcal{R}_S(G_1)$ 对子集 S 可能有偏) 的数学基础 (见 Sec. 9)。

2.3 状态递推

Definition 2.3 (核心状态递推). 第 i 步的训练控制为 u_i (见下文(4)), 状态按下式演化:

$$S_{i+1} = F_i(S_i, u_i) = S_i + \eta_i \mathcal{L}_i(S_i, u_i) \mathbf{g}_i(S_i, u_i) + E_i \quad (2)$$

其中 η_i 是学习强度 (step), $\mathcal{L}_i$ 是当前训练机制诱导的带岭收缩的线性响应算子 (ridge-regularized linear response operator, 见 Sec. 7), $\mathbf{g}_i$ 是复合残差 (见 Sec. 6), E_i 收集所有未被一阶展开捕获的项。

块结构 (block structure)。递推(2) 在 $\mathcal{S} = \mathcal{B} \times \mathcal{G}$ 上是分量耦合而块结构化的: 复合残差按势能分量与几何分量堆叠,

$$\mathbf{g}_i = (g_i^{(0)}, \sqrt{\rho_G} g_i^{(G)}), \quad g_i^{(0)} = C_{i-1}[U_i^* - B_{i-1}], \quad g_i^{(G)} = G_i^* - G_{i-1}, \quad (3)$$

其中 $g_i^{(0)} \in \mathcal{B}$ 是势能残差 (target potential U_i^* 相对当前势能 B_{i-1} 的中心化差), $g_i^{(G)} \in \mathcal{G}$ 是全局 COV 几何残差 (target geometry G_i^* 相对 G_{i-1} 之差), $\rho_G > 0$ 是两分量的相对权重; 算子 $\mathcal{L}_i$ 相应地作用于 (B, G) 两个分量上。势能残差的精确变分来历见 Sec. 6, 算子 $\mathcal{L}_i$ 的构造见 Sec. 7。

Caveat 2.4 ($\mathcal{L}_i$ 不是投影). $\mathcal{L}_i$ 是线性响应而非正交投影: 一般情形下它带岭正则 $\lambda_i > 0$ 与度量 M_i , 并不幂等。只有在 $\lambda_i \rightarrow 0$ 、闭值域 (closed-range) 且固定度量的极限下, $\mathcal{L}_i$ 才退化为某子空间上的正交投影 $\Pi_{\mathcal{H}_i}$ 。原始讨论稿曾把它直接写作 $\Pi_{\mathcal{H}_i}^{M_i[G_i], \lambda_i}$ 而以“投影”称之, 这是误导性的; 本文统一称 $\mathcal{L}_i$ 为线性响应算子, 仅在上述极限处引用 Π 。

Remark 2.5 (层级标注: 递推(2) 属第二类). 第二类 (局部二阶近似)。递推(2) 是把一步训练对状态的影响在当前状态 S_i 处作一阶 (线性响应) 展开的结果, 其有效性依赖如下局部化假设:

- (a) 小步长 / 局部线性化: η_i 足够小, 使训练算子在 S_i 邻域内可由线性响应 $\mathcal{L}_i$ 近似;
- (b) 局部性: G_i 到局部景观的 *restriction* $\mathcal{R}_z$ 在目标 *fiber* 邻域内近似线性;
- (c) 有限样本与模型误差可控: *emission/smoothing* 估计、*COV* 估计、标签映射 T_i 的误差进入 E_i 而不破坏一阶项的主导地位。

误差项 E_i 正是收集这些被略去的对象: 非线性高阶项、有限步长残差、采样/经验测度误差、以及模型容量不足导致的可达性误差。当上述假设失效时, 应回到精确表述 (第一类, 见 *Sec. 6* 的残差势能恒等式) 或诉诸可测诊断 (第三类, 见 *Sec. 13*)。

2.4 控制变量

Definition 2.6 (第 i 步训练控制).

$$u_i = (\nu_i, T_i, \gamma_i, \Phi_i^\dagger, \mathcal{H}_i, M_i, \lambda_i, \eta_i) \in \mathcal{U}_i, \quad (4)$$

其各分量含义为: 阶段隐变量测度 ν_i (数据选择, 见 *Sec. 3*); 标签映射 $T_i: y \mapsto c$; *data-tilt* 指数 $\gamma_i \in [0, 1]$ (阶段数据相对基座的混合权重); *preference potential* $\Phi_i^\dagger$ (偏好/reward 势能); 可达/假设/LoRA 子空间 $\mathcal{H}_i$; 训练度量 M_i ; 岭正则 λ_i ; 学习强度 η_i 。控制 u_i 取自第 i 步的可行集 $\mathcal{U}_i$ 。

2.5 三条推论

下面把核心论点落为三条推论。它们均依赖具体任务的可测诊断量, 故标注为结构性 / 经验层级。

Proposition 2.7 (最优策略是条件最优, 而非固定排序). 第三类 (结构性 / 经验)。给定状态 S_i 与可行控制集 $\mathcal{U}_i$, 递推(2) 上的多步最优控制问题一般不存在跨状态、跨任务恒定的策略排序: 最优策略是 *Pareto / Bellman* 型的条件最优。势能残差 $g_i^{(0)}$ 更小的控制可能使几何残差 $g_i^{(G)}$ 更差 (*COV* 几何更不稳定); 反之, 几何更优的控制可能使终端势能未对齐。因此“更优”只能相对某个固定的终端代价 $D_T(\cdot, S^\dagger)$ 与权重 ρ_G, Q_i 而言 (*minmax/Bellman* 表述见 *Sec. 7*), 而非无条件成立。

Proposition 2.8 (全集-真子集的关键是继承还是重建同一 fiber). 第三类 (经验)。在 $D_2 = S \subseteq D_1$ 的两阶段对齐中, 第二阶段的真正决策不是“ D_2 是否继续训练”, 而是是否继承第一阶段已在同一 *caption fiber* 上建立的人物/子点路径:

- 继承 (T_2 沿用第一阶段同一 *fiber*): 势能路径连续, 残差 $U_S^* - B_1^S$ 通常更小, 几何只需在全集先验 $\mathcal{R}_S(G_1)$ 上修正, 故低方差、低残差; 代价是保留全集投影偏差 (若 $\mathcal{R}_S(G_1)$ 对 S 有偏)。
- 重建 (T_2 启用真子集自身几何 $\hat{G}_S$ 定义新 *fiber*): 可能降低投影偏差、上限更高; 代价是高方差、对可达性 $\mathcal{H}_i$ 与数据质量更敏感。

是否重建为正收益取决于“偏差下降”是否超过“方差上升 + 可达性损失 + 额外势能高度”, 这是一组可测诊断条件 (见 *Sec. 9*、*Sec. 11*、*Sec. 13*), 而非无条件定理。

Proposition 2.9 (非 LoRA 专属: 任意真子集再对齐都有同一张力). 第三类 (结构性)。本理论不局限于角色/画风 LoRA。只要存在 $D_2 \subsetneq D_1$ 、且在全集对齐后对子集再对齐, 就出现 *Proposition 2.8* 所述的“继承低方差有偏几何 vs. 重建低偏高方差几何”的张力。差别仅在几何 G_i 的实现形式: *Flow Matching* / 扩散使 *COV* 场 (*posterior score covariance*) 非常显式; LLM 对齐中 G_i 由语义场、偏好场、*reward manifold* 或数据分布几何类比承担 (见 *Sec. 12*)。

Remark 2.10. 综上: 本节既未承诺一份固定数据配方, 也未给出无条件最优策略, 而是确立了“策略空间被状态递推(2) 支配”这一框架——后续所有定量结论都是在此框架内、对 $\mathcal{L}_i$ 、 $\mathbf{g}_i$ 、 E_i 与终端代价的具体化, 并按第一/第二/第三类逐一标注其严格程度。

3 数据分布：全集、真子集与隐变量测度

本节把”全集 D_1 与真子集 D_2 的两阶段对齐”所依赖的数据分布结构形式化。约定全部沿用 Sec. 1 的全局对象：点 $z = (c, x, t)$ 、隐变量 y 、发射核 $q(x|y)$ 、平滑核 K_t 与基模型 $p_{0,t}(x|c)$ 。本节只刻画数据侧的测度对象（隐变量测度 ν_i 、阶段数据密度 $q_{i,t}^D$ 、子集限制），而把由它们诱导的几何量（posterior responsibility、score、Hessian H_Y 、posterior score covariance Σ_i^D 、全局几何 G_i ）留到 Sec. 4。本节所有结论是第一类（精确恒等式），唯一的第三类风险出现在 §3.4 末尾的 remark。

3.1 隐变量结构

Definition 3.1 (隐变量分解). 设隐变量取值于乘积空间 $\mathcal{Y} = \mathcal{Y}_A \times \mathcal{Y}_P \times \mathcal{Y}_W \times \mathcal{Y}_R$ ，记

$$y = (A, P, W, R), \quad (5)$$

其中各分量的语义为：

- A : *artist / style source / domain* (画师、风格来源、域)；
- P : *character / entity / subject* (人物、实体、主体)；
- W : *clothing / controllable attribute* (服装及可控属性)；
- R : *residual visual factors* (残差视觉因子: *pose*、*lighting*、*crop*、*background*、*composition* 等)。

Caveat 3.2 (y 是数据混合的形式化，而非可观测变量). 分解(5) 是对异质数据如何混合的形式化记号，并不断言模型显式观测或显式恢复 A, P, W, R 中任一分量。模型在训练时仅见到点 $z = (c, x, t)$: *caption* c 与图像 *latent* x 。隐变量 y 只作为生成数据的潜在标注，用来把”同一 *caption* 下混入了哪些子群”写清楚。下文凡涉及 y 的积分，均指对数据生成测度的积分，而非对模型可见量的积分。

此外，符号 R 在本文中只作为隐变量元组 $y = (A, P, W, R)$ 的第四分量标签出现，绝不充当独立标量；*reward* 一律记为 R_i (带阶段下标)，*restriction/global*→*local* 算子一律记为 $\mathcal{R}_z, \mathcal{R}_S$ 。三者互不混淆（见 Sec. 1 的符号约定）。

Definition 3.3 (阶段隐变量测度与 caption fiber). 第 i 阶段的数据由 $\mathcal{Y}$ 上的概率测度 $\nu_i(dy)$ 刻画。设可测的标签映射（*caption* 标注）

$$T_i: \mathcal{Y} \rightarrow \mathcal{C}, \quad c = T_i(y), \quad (6)$$

把隐变量映到文本条件 c 。给定 c ，定义 caption fiber 上的条件测度为正则条件分布

$$\nu_i(dy | c) := \nu_i(dy | T_i(y) = c), \quad (7)$$

即 ν_i 在事件 $\{y: T_i(y) = c\}$ 上的条件化（对 $(T_i)_\# \nu_i$ 几乎处处的 c 良定义）。 $\nu_i(dy | c)$ 是支撑在 *fiber* $T_i^{-1}(c)$ 上的概率测度，它描述”贴同一标签 c 的所有隐变量子场的相对权重”。

Remark 3.4. (7) 把”一个 *caption* 背后是一锅混合的子群”显式化：同一 c 通常对应 A, P, W, R 的多种取值组合， $\nu_i(\cdot | c)$ 给出它们在该 *fiber* 内的混合比例。这一 *fiber* 视角是后文”继承同一 *fiber* 还是用子集重建 *fiber*”决策（见 Sec. 10）的测度论起点。

3.2 无标签纯图像分布： N 阶联合测度

上面的 $T_i: y \mapsto c$ 只描述打标以后如何形成 caption fiber。若暂时完全不考虑标签，只问”这一阶段的纯图片数据分布是什么”，则答案更基础：它是隐变量联合测度经发射核 q_t 推前后的边缘混合。为避免把画师、人物、衣服误写成彼此独立，本节先给出一般 N 阶形式。

Definition 3.5 (N 阶纯图像数据测度). 设第 i 阶段选取 N 个异质因子

$$Y^{(N)} = (Y_1, \dots, Y_N) \in \mathcal{Y}^{(N)} := \prod_{k=1}^N \mathcal{Y}_k,$$

并以一个联合概率测度刻画数据组成:

$$\nu_i^{(N)}(dy_{1:N}). \quad (8)$$

这里 $\nu_i^{(N)}$ 一般不是边缘测度的乘积; 只有在显式假设各因子独立时, 才可写成 $\bigotimes_{k=1}^N \nu_{i,k}$. 给定平滑发射核 $q_t(x | y_{1:N})$, 无标签纯图像数据密度定义为

$$q_{i,t}^{D,N}(x) = \int_{\mathcal{Y}^{(N)}} q_t(x | y_{1:N}) \nu_i^{(N)}(dy_{1:N}). \quad (9)$$

(9) 是本文数据侧最底层的形式: 所有”单画师/多画师、单人物/多人物、单衣服/多衣服”都只是联合测度 $\nu_i^{(N)}$ 在不同坐标或条件坐标上的支撑大小不同。例如 $\text{supp}(\nu_i^A)$ 为单点表示单画师; $\text{supp}(\nu_i^P)$ 含多个点表示多人物; 而”每个人物一套衣服”不是 ν_i^W 单点, 而是条件支撑 $\text{supp} \nu_i(dw | p)$ 对每个 p 近似单点。

Remark 3.6 (有限样本矩阵形式). 若每个因子是离散索引, (9) 可写成多维训练矩阵的加权和:

$$q_{i,t}^{D,N}(x) = \sum_{j_1, \dots, j_N} \omega_i(j_1, \dots, j_N) q_t(x | j_1, \dots, j_N), \quad \sum_{j_1, \dots, j_N} \omega_i(j_1, \dots, j_N) = 1. \quad (10)$$

权重 $\omega_i(j_1, \dots, j_N)$ 才是数据矩阵的真实结构; 把它拆成 $\prod_k \omega_{i,k}(j_k)$ 等价于额外假设各维独立, 通常会抹掉人物-衣服、画师-人物等绑定关系。

Definition 3.7 (三阶 A, P, W 纯图像分布). 在画师案例中, 最小需要显式保留的三个联合变量是画师 A 、人物 P 与衣服/可控属性 W 。残差视觉因子 R 可先并入条件发射核:

$$\bar{q}_{i,t}(x | a, p, w) := \int_{\mathcal{Y}_R} q_t(x | a, p, w, r) \nu_i(dr | a, p, w). \quad (11)$$

令 $\nu_i^{APW} := (\pi_{APW})_{\#} \nu_i$ 为 ν_i 在 (A, P, W) 上的边缘联合测度, 则无标签三阶纯图像分布为

$$q_{i,t}^{D,APW}(x) = \int_{\mathcal{Y}_A \times \mathcal{Y}_P \times \mathcal{Y}_W} \bar{q}_{i,t}(x | a, p, w) \nu_i^{APW}(da, dp, dw). \quad (12)$$

Remark 3.8 (标签化是后续的条件化, 而非数据分布本身). (12) 不含 c , 因此它回答的是”纯图片数据分布是什么”。若之后引入标签映射 $T_i(A, P, W, R) = c$, 则 *caption* 条件分布 $q_{i,t}^D(x | c)$ 是在同一联合测度上再做一次 *fiber* 条件化, 得到(14)。因此打标策略会改变可见条件结构, 但不会改变底层多维图片测度的基本形式。

3.3 阶段数据分布

阶段数据密度是同一 **caption fiber** 下、所有隐变量子场的混合: 固定 c 后, 对 *fiber* 内的全部 y 按权重 $\nu_i(\cdot | c)$ 把各子场的发射密度 $q(x|y)$ 叠加。

Definition 3.9 (阶段数据密度). 第 i 阶段在 *caption fiber* c 上的 (未平滑) 数据密度为

$$q_i^D(x | c) = \int_{\mathcal{Y}} q(x | y) \nu_i(dy | c). \quad (13)$$

若引入平滑核 K_t 或前向 *SDE*, 令 $q_t(x | y) = \int K_t(x | x_1) q(dx_1 | y)$ 为时间 t 上的平滑发射密度, 则平滑阶段数据密度为

$$q_{i,t}^D(x | c) = \int_{\mathcal{Y}} q_t(x | y) \nu_i(dy | c). \quad (14)$$

(13)–(14) 是定义式，属第一类，不含任何近似。注意混合只发生在固定 **fiber** 内部：条件测度 $\nu_i(\cdot | c)$ 把权重限制在 $T_i^{-1}(c)$ 上，因此 $q_{i,t}^D(\cdot | c)$ 是该 caption 下”所有子场（不同 A, P, W, R 组合）”在同一标签内的混合，而非跨 caption 的混合。

Remark 3.10. 密度 $q_{i,t}^D$ 是 Sec. 4 中 *posterior responsibility* $\alpha_i(y | x, c, t) = q_t(x | y) \nu_i(dy | c) / \int q_t(x | y') \nu_i(dy' | c)$ 的分母，亦即 α_i 是(14) 被积测度关于其积分的 *Radon–Nikodym* 权重。本节只需 $q_{i,t}^D$ 的良定义；其 *score* $s_i^D = \mathbb{E}_{\alpha_i}[s_Y]$ 与 *posterior score covariance* $\Sigma_i^D = \text{Cov}_{\alpha_i}(s_Y)$ 的分解在 Sec. 4 给出。

3.4 全集与真子集

两阶段对齐的关键设定是： D_2 是 D_1 的真子集，而非两个不相交目标，也非第二阶段引入新图片。下面把”子集”在测度层面精确化——原稿仅写 $\nu_2(dy) = \nu_1(dy | y \in S)$ ，此处补全其作为条件测度（即归一化的限制测度）的显式定义。

Definition 3.11 (真子集与限制测度). 设可测集 $S \subseteq \mathcal{Y}$ 满足 $0 < \nu_1(S) < 1$ ，且

$$D_2 = S \subsetneq D_1, \quad (15)$$

此处 D_1 标识全集隐变量的支撑、 $D_2 = S$ 标识真子集（ $\subsetneq$ 取严格包含，故 $\nu_1(S) < 1$ ）。第二阶段隐变量测度定义为 ν_1 在 S 上的归一化限制（等价地，条件测度）：

$$\nu_2(dy) = \nu_1(dy | y \in S) = \frac{\mathbf{1}_S(y) \nu_1(dy)}{\nu_1(S)}. \quad (16)$$

(16) 是第一类恒等式：右端 $\mathbf{1}_S \nu_1 / \nu_1(S)$ 显式给出 Radon–Nikodym 密度 $d\nu_2/d\nu_1 = \mathbf{1}_S / \nu_1(S)$ ，因 $\nu_1(S) > 0$ 而良定义，并自动归一（ $\nu_2(\mathcal{Y}) = \nu_1(S) / \nu_1(S) = 1$ ）。它澄清了原稿条件记号的两点含糊：其一，条件化是对隐变量事件 $\{y \in S\}$ 而非对 caption；其二，权重在 S 内按 ν_1 的相对比例保留、在 S 外置零，故 D_2 继承的是 D_1 在子集上的原始相对结构（仅整体重标度 $1/\nu_1(S)$ ），而不是把子集重新均匀化。

Remark 3.12 (caption-fiber 上的相容性). 由(16)，对任一 caption c ，第二阶段的 fiber 条件测度 $\nu_2(dy | c)$ 即把(7) 中的 ν_1 换成 ν_2 ；当 fiber $T_2^{-1}(c)$ 与 S 的交非空时， $\nu_2(\cdot | c)$ 等于 $\nu_1(\cdot | c)$ 在 $S \cap T_2^{-1}(c)$ 上的归一化限制。于是 $q_{2,t}^D(\cdot | c)$ 仍由(14) 给出，只是混合权重收缩到 fiber 内落入 S 的那部分子场。

SKADI 实例. 把上述抽象落到画师案例。设单一原画师 a_0 ，其全集为该画师名下的多人物画风数据：

$$D_1 = \{(a_0, p, w, r) : p \in P_{\text{set}}, \text{SKADI} \in P_{\text{set}}\}, \quad (17)$$

即 A 固定为 a_0 、 P 遍历人物集 P_{set} （其中含目标人物 SKADI）、 W, R 自由。真子集取为其中 SKADI 的图片：

$$D_2 = \{(a_0, \text{SKADI}, w, r)\} \subsetneq D_1, \quad (18)$$

对应(15) 中 $S = \{y : A = a_0, P = \text{SKADI}\}$ 。由于 P_{set} 含 SKADI 之外的人物， $\nu_1(S) < 1$ ，严格包含成立，故(16) 的归一化条件 $0 < \nu_1(S) < 1$ 满足。

Remark 3.13 (窄 W -支撑的风险层级). 若 SKADI 仅有单一套装，则 D_2 的 W -支撑很窄： ν_2 在 $\mathcal{Y}_W$ 上几乎集中于单点。需强调，这不改变集合层面的真子集关系——(18) 与(16) 仍精确成立（第一类）。窄 W -支撑带来的是统计与下游风险，属第三类（经验假设 / 可测诊断）：

- 子集 COV 估计方差上升：在 S 上估计 *posterior score covariance*（即 Sec. 4 的 Σ_2^D 及其全局几何 G_2 ）时， W 方向几乎无变化样本，使该方向的协方差估计方差增大、条件数变差；
- 低频绑定风险：低频出现的 W, R 因子可能被错误绑定到 $P = \text{SKADI}$ 上（把”单一套装”误并入人物身份）。

此两项是可测诊断量（如子集协方差的有效样本数、 W -方向特征值与条件数、跨套装泛化误差），需在第二阶段以经验方式监测；它们影响的是”继承同一 fiber 还是重建 fiber”的方差/可达性权衡（见 Sec. 10 与 Sec. 8），而非 $D_2 \subsetneq D_1$ 这一结构事实本身。

4 从经验测度到全局 COV 几何

本节从有限样本出发，逐层建立训练目标景观 (target landscape) 的二阶几何，并把”局部曲率”与一个跨样本共享的”全局 COV 几何状态 G_i ”显式联系起来。沿用 Sec. 1 与 Sec. 3 的记号：点 $z = (c, x, t)$ ，潜变量 $y = (A, P, W, R)$ ，阶段 i 的潜测度 $\nu_i(dy)$ 、标签映射 $T_i : y \mapsto c$ 、条件潜测度 $\nu_i(dy | c) = \nu_i(dy | T_i(y) = c)$ ，发射核 $q(x | y)$ 与平滑核 K_t 。本节的逻辑链是：经验测度 $\rightarrow$ 平滑后的条件密度 $\rightarrow$ posterior responsibility $\rightarrow$ 混合密度的 score/Hessian 精确分解 $\rightarrow$ 把分解结果中跨样本的二阶项凝结为全局状态 G_i ，再用受限算子 $\mathcal{R}_z$ 还原为局部二阶型。

4.1 经验测度与平滑条件密度

数据以有限样本给出。设全集潜测度 ν_i 由 N 个图像 latent 样本经发射与标注实现，记原始（未平滑）图像 latent 的经验测度为

$$\hat{Q}(dx_1) = \frac{1}{N} \sum_{m=1}^N \delta_{x^{(m)}}(dx_1), \quad (19)$$

其中 $x^{(m)}$ 为第 m 个样本的干净 latent。平滑时间 t 下的平滑核 $K_t(x | x_1)$ （如扩散/flow 的前向高斯核）把每个原子展开为一个光滑成分，得到平滑后的边缘密度

$$q_t(x) = \int K_t(x | x_1) \hat{Q}(dx_1) = \frac{1}{N} \sum_{m=1}^N K_t(x | x^{(m)}). \quad (20)$$

按潜变量 y 分层：设取值 y （更一般地，落入 y 所标记的 fiber）的样本有 N_y 个，记为 $\{x_y^{(m)}\}_{m=1}^{N_y}$ ，则每个 latent 的平滑条件密度为

$$q_t(x | y) = \frac{1}{N_y} \sum_{m=1}^{N_y} K_t(x | x_y^{(m)}). \quad (21)$$

据此，阶段 i 的条件数据密度（见 Sec. 3 的定义）为

$$q_{i,t}^D(x | c) = \int q_t(x | y) \nu_i(dy | c). \quad (22)$$

Definition 4.1 (平滑条件密度，第一类：定义). 以(21)–(22) 定义的 $q_t(x | y)$ 与 $q_{i,t}^D(x | c)$ 称为阶段 i 在平滑尺度 t 下的条件数据密度。这是后续一切 score/Hessian 计算的对象；它本身只是经验测度经核平滑得到的定义性构造，不含任何近似。

Remark 4.2. 经验测度(19) 是奇异的（原子和），其 $\log$ 的导数无定义；平滑核 K_t 起到正则化作用，使 $q_{i,t}^D(\cdot | c)$ 成为光滑正密度，从而 $\nabla_x \log q_{i,t}^D$ 、 $\nabla_x^2 \log q_{i,t}^D$ 处处良定。这正是把”有限样本”过渡到”可微景观”的桥。下文所有恒等式均在使 $q_{i,t}^D(x | c) > 0$ 的点 z 处成立。

4.2 无标签 N 阶 posterior 与 COV 场

若沿用 Sec. 3.2 的无标签纯图像分布，则点中不再包含 caption，局部点可写为 $z_0 = (x, t)$ 。此时 posterior responsibility 不是对 caption fiber 的后验，而是对完整 N 阶联合隐变量的后验：

$$\bar{\alpha}_i^{(N)}(dy_{1:N} | x, t) = \frac{q_t(x | y_{1:N}) \nu_i^{(N)}(dy_{1:N})}{\int_{\mathcal{Y}^{(N)}} q_t(x | y'_{1:N}) \nu_i^{(N)}(dy'_{1:N})} = \frac{q_t(x | y_{1:N}) \nu_i^{(N)}(dy_{1:N})}{q_{i,t}^{D,N}(x)}. \quad (23)$$

定义

$$s_{Y^{(N)}} = \nabla_x \log q_t(x | Y_{1:N}), \quad H_{Y^{(N)}} = \nabla_x^2 \log q_t(x | Y_{1:N}). \quad (24)$$

则无标签 N 阶 COV 场为

$$\Sigma_i^{D,N}(x, t) := \text{Cov}_{\bar{\alpha}_i^{(N)}}(s_{Y^{(N)}}). \quad (25)$$

Proposition 4.3 (无标签 N 阶 COV/Hessian 分解; 第一类). 在 $q_{i,t}^{D,N}(x) > 0$ 且积分号下可两次求导的点 (x, t) , 有精确恒等式

$$\nabla_x \log q_{i,t}^{D,N}(x) = \mathbb{E}_{\bar{\alpha}_i^{(N)}}[s_{Y^{(N)}}], \quad (26)$$

$$\nabla_x^2 \log q_{i,t}^{D,N}(x) = \mathbb{E}_{\bar{\alpha}_i^{(N)}}[H_{Y^{(N)}}] + \Sigma_i^{D,N}(x, t). \quad (27)$$

Proof. 证明与 Proposition 4.8 相同, 只是把条件测度 $\nu_i(dy | c)$ 换成无标签联合测度 $\nu_i^{(N)}(dy_{1:N})$, 把条件边缘 $q_{i,t}^D(x | c)$ 换成无标签边缘 $q_{i,t}^{D,N}(x)$. $\square$

Definition 4.4 (三阶 A, P, W COV 场). 对(12) 的三阶纯图像分布, *posterior responsibility* 为

$$\alpha_i^{APW}(da, dp, dw | x, t) = \frac{\bar{q}_{i,t}(x | a, p, w) \nu_i^{APW}(da, dp, dw)}{q_{i,t}^{D,APW}(x)}. \quad (28)$$

记

$$s_{a,p,w} := \nabla_x \log \bar{q}_{i,t}(x | a, p, w), \quad H_{a,p,w} := \nabla_x^2 \log \bar{q}_{i,t}(x | a, p, w). \quad (29)$$

则三阶 COV 场为

$$\Sigma_i^{APW}(x, t) := \text{Cov}_{\alpha_i^{APW}}(s_{A,P,W}), \quad (30)$$

并满足

$$\nabla_x^2 \log q_{i,t}^{D,APW}(x) = \mathbb{E}_{\alpha_i^{APW}}[H_{A,P,W}] + \Sigma_i^{APW}(x, t). \quad (31)$$

Remark 4.5 (三阶 COV 的可读展开). 按 $A \rightarrow P \rightarrow W$ 的嵌套条件链, 令

$$\mu_A := \mathbb{E}_{\alpha_i^{APW}}[s_{A,P,W} | A], \quad \mu_{A,P} := \mathbb{E}_{\alpha_i^{APW}}[s_{A,P,W} | A, P].$$

由全协方差公式, 三阶 COV 可精确写成

$$\begin{aligned} \Sigma_i^{APW} &= \text{Cov}_{\alpha(A)}(\mu_A) + \mathbb{E}_{\alpha(A)}[\text{Cov}_{\alpha(P|A)}(\mu_{A,P})] \\ &\quad + \mathbb{E}_{\alpha(A,P)}[\text{Cov}_{\alpha(W|A,P)}(s_{A,P,W})]. \end{aligned} \quad (32)$$

三项分别读作: 画师/风格层面的后验 *score* 离散度、同一画师内人物层面的离散度、同一画师-人物条件下衣服/可控属性层面的离散度。换一个条件顺序也可得到等价但语义不同的精确分解: (32) 只是最贴合画师-人物-衣服案例的一种读法。

Remark 4.6 (绑定项的对称 ANOVA 读法). 若希望显式标出”人物-衣服绑定”或”画师-人物-衣服三阶交互”, 可在 *posterior Hilbert* 空间 $L_0^2(\alpha_i^{APW}; \mathbb{R}^d)$ 中对中心化 *score* 做正交 *Hoeffding*/ANOVA 分解:

$$s_{A,P,W} - \mathbb{E}[s_{A,P,W}] = h_A + h_P + h_W + h_{AP} + h_{AW} + h_{PW} + h_{APW}. \quad (33)$$

若各分量按 *posterior* 内积正交, 则

$$\Sigma_i^{APW} = \sum_{\emptyset \neq I \subseteq \{A,P,W\}} \mathbb{E}_{\alpha_i^{APW}}[h_I h_I^\top]. \quad (34)$$

其中 h_{PW} 捕捉人物-衣服绑定, h_{AW} 捕捉画师-衣服风格依赖, h_{APW} 捕捉三阶交互。此分解不是额外训练假设, 而是对同一个 COV 场的不同坐标展开; 实际估计这些项是否稳定, 则属于第三类诊断问题。

4.3 Posterior responsibility 是精确的 Radon–Nikodym 权重

在点 $z = (c, x, t)$ 处，把 $\nu_i(dy | c)$ 视为先验、 $q_t(x | y)$ 视为似然，则联合 $q_t(x | y) \nu_i(dy | c)$ 关于其边缘 $q_{i,t}^D(x | c)$ 的密度即 posterior responsibility:

$$\alpha_i(y | x, c, t) = \frac{q_t(x | y) \nu_i(dy | c)}{\int q_t(x | y') \nu_i(dy' | c)} = \frac{q_t(x | y) \nu_i(dy | c)}{q_{i,t}^D(x | c)}. \quad (35)$$

Remark 4.7 (第一类: 恒等式, 非超参数). $\alpha_i(\cdot | x, c, t)$ 是 y 上的一个概率测度 (其关于 $\nu_i(\cdot | c)$ 的 Radon–Nikodym 导数为 $q_t(x | y)/q_{i,t}^D(x | c)$, 对 $\nu_i(\cdot | c)$ 积分得 1)。它由 ν_i, q_t 唯一决定, 不是可调超参数; 原稿若将其当作权重旋钮处理是误导。下文以 $\mathbb{E}_{\alpha_i}[\cdot]$ 、 $\text{Cov}_{\alpha_i}(\cdot)$ 记关于该后验测度的期望与协方差。

4.4 Score 与 Hessian 的精确分解

引入条件 score 与条件 Hessian (见 Sec. 1):

$$s_Y = \nabla_x \log q_t(x | Y), \quad H_Y = \nabla_x^2 \log q_t(x | Y), \quad (36)$$

并记数据 score 与 posterior score covariance

$$s_i^D = \mathbb{E}_{\alpha_i}[s_Y], \quad \Sigma_i^D \equiv \text{Cov}_{\alpha_i}(s_Y) = \mathbb{E}_{\alpha_i}[(s_Y - s_i^D)(s_Y - s_i^D)^\top]. \quad (37)$$

此处统一记号: Σ_i^D 与 $\text{Cov}_{\alpha_i}(s_Y)$ 指同一对象, 全文不再区分。注意这里出现的 H_Y 是条件对数密度的 Hessian (plain H), 与可达/假设/LoRA 子空间 $\mathcal{H}_i$ (calligraphic) 是不同对象, 切勿混淆。

Proposition 4.8 (混合密度的 score/Hessian 分解; 第一类: 精确恒等式). 在使 $q_{i,t}^D(x | c) > 0$ 的点 $z = (c, x, t)$ 处, 设 $q_t(\cdot | y)$ 关于 x 二阶可微且积分号下求导成立, 则

$$\nabla_x \log q_{i,t}^D(x | c) = \mathbb{E}_{\alpha_i}[s_Y] = s_i^D, \quad (38)$$

$$\nabla_x^2 \log q_{i,t}^D(x | c) = \mathbb{E}_{\alpha_i}[H_Y] + \Sigma_i^D, \quad \Sigma_i^D = \text{Cov}_{\alpha_i}(s_Y). \quad (39)$$

Proof. 记 $m(x) = q_{i,t}^D(x | c) = \int q_t(x | y) \nu_i(dy | c)$ 。一阶:

$$\nabla_x \log m = \frac{\nabla_x m}{m} = \frac{\int \nabla_x q_t(x | y) \nu_i(dy | c)}{m} = \int \frac{q_t(x | y)}{m} \nabla_x \log q_t(x | y) \nu_i(dy | c) = \mathbb{E}_{\alpha_i}[s_Y],$$

其中用了 $\nabla_x q_t = q_t \nabla_x \log q_t$ 与 (35), 得 (38)。二阶: 对 $\nabla_x \log m = \mathbb{E}_{\alpha_i}[s_Y]$ 再求一次 ∇_x 。由 $\nabla_x^2 \log m = \frac{\nabla_x^2 m}{m} - \frac{(\nabla_x m)(\nabla_x m)^\top}{m^2}$, 逐项展开

$$\frac{\nabla_x^2 m}{m} = \mathbb{E}_{\alpha_i}[H_Y + s_Y s_Y^\top], \quad \frac{(\nabla_x m)(\nabla_x m)^\top}{m^2} = s_i^D (s_i^D)^\top,$$

(第一式用 $\nabla_x^2 q_t = q_t(H_Y + s_Y s_Y^\top)$)。两式相减:

$$\nabla_x^2 \log m = \mathbb{E}_{\alpha_i}[H_Y] + \mathbb{E}_{\alpha_i}[s_Y s_Y^\top] - s_i^D (s_i^D)^\top = \mathbb{E}_{\alpha_i}[H_Y] + \text{Cov}_{\alpha_i}(s_Y),$$

即 (39)。□

Remark 4.9 (读解). (39) 是标准的“对数混合密度的 Hessian 恒等式”: 穿过混合两次求导后, 协方差项 $\Sigma_i^D = \text{Cov}_{\alpha_i}(s_Y)$ 是 Fisher 型修正——它度量后验 α_i 在 score 方向上的异质性。结论是逐字面的: 数据异质性 (同一 c 下不同 latent y 的 score 离散程度) 以正半定项的形式直接进入目标景观的曲率 $\nabla_x^2 \log q_{i,t}^D$, 而不仅是描述性说法。 $\mathbb{E}_{\alpha_i}[H_Y]$ 为各成分自身曲率的后验平均, Σ_i^D 为成分间的散布; 两者相加构成完整的局部二阶型。

4.5 全局 COV 几何状态与局部还原算子

(39) 给出的是逐点二阶型，依赖具体 z 。但训练所学到、并可跨阶段继承的，是一个不随单点变化、对整个数据场成立的全局几何对象：posterior cumulant / COV 几何。记之为全局几何状态 $G_i \in \mathcal{G}$ (COV 始终指 posterior score covariance / 数据场协方差几何，绝非卷积)。 G_i 可理解为把(39)的二阶信息在 z 上聚合（按平滑核与数据分布加权）后得到的、参数化的全局协方差几何；其精确实现（例如二阶 cumulant 张量场或其低维参数）在 Sec. 2 中给定。本节只需 G_i 满足下述“可还原到局部”的接口。

原稿在此处用未定义的“ $\approx$ ”与未命名算子把全局量直接当作局部量，构成逻辑跳步。下面显式定义还原算子，并把近似关系的层级与所需假设讲清。

Definition 4.10 (局部还原算子 $\mathcal{R}_z$ ；第一类：定义). 设 $\text{Sym}(\mathbb{R}^d)$ 为 $d \times d$ 实对称矩阵空间。对每个点 $z = (c, x, t)$ ，定义受限/求值算子

$$\mathcal{R}_z : \mathcal{G} \longrightarrow \text{Sym}(\mathbb{R}^d), \quad G \longmapsto \mathcal{R}_z(G), \quad (40)$$

为有界线性算子，把全局几何状态 G 在点 z 处求值，输出该点应有的局部二阶（对称）型。 $\mathcal{R}_z$ 由平滑尺度与局部坐标卡（*local chart*）决定，是 Sec. 2 中 $\mathcal{R}$ 族的逐点特例；当还原到一个子集 *fiber* 时记为 $\mathcal{R}_S$ 。它是读出 算子，不改变 G 本身。

Assumption 4.11 (全局几何在核尺度上缓变；局部光滑性). 存在邻域尺度 ℓ_t （与平滑核 K_t 的带宽同阶）使得：在以 z 为中心、半径 ℓ_t 的局部坐标卡内，真实逐点二阶型 $\nabla_x^2 \log q_{i,t}^D$ 关于 z 的变化量为 $o(1)$ （相对其自身范数），即全局几何 G_i 在核尺度上缓变、且局部卡光滑。等价地， $\mathcal{R}_z(G_i)$ 在该尺度内可代表整个邻域的二阶行为。

Caveat 4.12 (全局 $\rightarrow$ 局部的二阶近似；第二类：局部二阶近似). 在 Assumption 4.11 下，逐点二阶型可由全局状态经 $\mathcal{R}_z$ 还原：

$$\Sigma_i^{\text{loc}}(z) = \nabla_x^2 \log q_{i,t}^D(x | c) = \mathcal{R}_z(G_i) + o(1) \quad (\ell_t \rightarrow 0). \quad (41)$$

此式为第二类（局部二阶近似）：等号成立依赖 Assumption 4.11 的核尺度缓变与局部卡光滑； $o(1)$ 表示当平滑/邻域尺度 $\ell_t \rightarrow 0$ 时相对误差趋于零。原稿中无定义的“ $\approx$ ”在此被替换为带显式假设与误差阶的(41)。其中 $\Sigma_i^{\text{loc}}(z)$ 即 $\mathcal{R}_z$ 作用于 G_i 给出的局部二阶型，与(39)的逐点恒等式相容： $\mathcal{R}_z(G_i)$ 是对 $\mathbb{E}_{\alpha_i}[H_Y] + \Sigma_i^D$ 的全局参数化读出。

Remark 4.13 (楼塔问题：地基与倾斜). (41) 给出一个直观读解（“楼塔/地基”）。 G_i 是地基：改进全局 COV 估计（用更多、更具代表性的数据把 G_i 估得更准）会整体抬高局部二阶型的“基线”，使每个 $\mathcal{R}_z(G_i)$ 都更可靠——地基升高，楼塔随之升高。但当第二阶段把估计限制到真子集 *fiber*（用 $\mathcal{R}_S$ 还原、并以 $\nu_2(dy) = \mathbf{1}_S \nu_1 / \nu_1(S)$ 重估几何，见 Sec. 3）时，子集采样可能使 G 的估计带有系统偏差：还原出的局部型 $\mathcal{R}_S(G)$ 可以数值上更高（子集内方差更集中、对齐更强），却在方向上倾斜（相对全集真实几何存在 *bias*）——即“高，但歪”。这正是 Sec. 8 中 *bias-variance* 权衡与 Sec. 10 中“继承同一 *fiber* 还是用子集重建 *fiber*”决策的几何根源：抬高地基与避免地基倾斜不可兼得，需由可测诊断量（见 Sec. 13）裁决。

Remark 4.14 (与状态递推的衔接). 本节确立：局部曲率不是孤立逐点量，而是单一全局状态 G_i 经 $\mathcal{R}_z$ 的读出（(41)）。因此把 G_i 纳入复合状态 $S_i = (B_i, G_i) \in \mathcal{S} = \mathcal{B} \times \mathcal{G}$ 是自洽的：势能分量 B_i 刻画一阶/对数比景观（见 Sec. 5），几何分量 G_i 刻画二阶 COV 景观；二者的残差 $\mathbf{g}_i = (g_i^{(0)}, \sqrt{\rho_G} g_i^{(G)})$ 中， $g_i^{(G)} = G_i^* - G_{i-1}$ 即全局 COV 残差，驱动几何状态的更新（见 Sec. 6、Sec. 7）。

5 残差势能与 RLHF 形式

本节把“第 i 阶段的对齐目标”严格化为一个残差势能：以当前模型为 reference，理想 reward 恰是目标势能与当前累计势能之差。我们先给出势能的两条定义（基于 Sec. 1 与 Sec. 2 的对象），再从 KL-RLHF 的 Gibbs 闭式解推出残差 reward 的精确命题，随后澄清步长与温度的标定约定，最后给出目标分布的几何平均 + preference-tilt 建模形式，并经 fiberwise centering 得到势能残差 $g_i^{(0)}$ 。逐结论标注其层级。

5.1 累计势能与目标势能

回顾点 $z = (c, x, t)$, base 模型 $p_{0,t}(x|c)$ 、阶段- i 模型 $p_{i,t}(x|c)$ 。

Definition 5.1 (累计势能与目标势能). 设 $p_{i,t}(\cdot|c) \ll p_{0,t}(\cdot|c)$ (ρ -a.e. c)。累计势能 (相对 base 的全部 *log-density* 偏移) 定义为

$$B_i(c, x, t) := \log \frac{p_{i,t}(x|c)}{p_{0,t}(x|c)}, \quad B_0 \equiv 0. \quad (42)$$

若第 i 阶段存在理想目标条件分布 $q_i^*(\cdot|c) \ll p_{0,t}(\cdot|c)$, 其目标势能定义为

$$U_i^*(c, x, t) := \log \frac{q_i^*(x|c)}{p_{0,t}(x|c)}. \quad (43)$$

Remark 5.2 (基点 gauge 的不变性). B_i 与 U_i^* 均以 $p_{0,t}$ 为公共参考基点 (*gauge*)。下文残差只出现差 $U_i^* - B_{i-1} = \log(q_i^*/p_{i-1,t})$, 其中 $p_{0,t}$ 项相消, 故所有下游构造对基点选取不变。这是第一类的结构性事实。

5.2 Gibbs 闭式解与残差 reward

考虑以当前模型 $p_{i-1,t}$ 为 reference 的 KL-regularized 对齐目标。固定 (c, t) , 对条件分布 $P(\cdot|c)$ 求解

$$P_i^*(\cdot|c) = \arg \max_{P(\cdot|c)} \left\{ \mathbb{E}_{P(\cdot|c)}[R_i(c, X, t)] - \beta_i \text{KL}(P(\cdot|c) \parallel p_{i-1,t}(\cdot|c)) \right\}, \quad \beta_i > 0. \quad (44)$$

Lemma 5.3 (条件 Gibbs 闭式解). 设 $\mathbb{E}_{p_{i-1,t}(\cdot|c)}[\exp(R_i/\beta_i)] < \infty$ (ρ -a.e. c)。则(44) 的唯一最优解为指数倾斜

$$\frac{q_i^*(x|c)}{p_{i-1,t}(x|c)} = \frac{\exp(R_i(c, x, t)/\beta_i)}{Z_i^{\text{KL}}(c, t)}, \quad Z_i^{\text{KL}}(c, t) = \mathbb{E}_{p_{i-1,t}(\cdot|c)}[\exp(R_i/\beta_i)], \quad (45)$$

其中 $q_i^* = P_i^*$ 。

Proof. 固定 (c, t) 。(44) 的目标关于 $P(\cdot|c)$ 严格凹 (KL 严格凸, 期望线性), 在归一化约束 $\int P(dx|c) = 1$ 下, 引入 Lagrange 乘子 $\kappa(c)$ 并对 P 取一阶变分:

$$R_i(c, x, t) - \beta_i \left[\log \frac{P(x|c)}{p_{i-1,t}(x|c)} + 1 \right] - \kappa(c) = 0,$$

解得 $P(x|c) \propto p_{i-1,t}(x|c) \exp(R_i/\beta_i)$ 。由可积性假设归一化即得(45), 凹性保证唯一。 $\square$

对(45) 两边取对数并以 $p_{0,t}$ 改写基点 (用(42)-(43)):

$$U_i^*(c, x, t) = B_{i-1}(c, x, t) + \frac{R_i(c, x, t)}{\beta_i} - \log Z_i^{\text{KL}}(c, t). \quad (46)$$

其中 $\log Z_i^{\text{KL}}(c, t)$ 是只依赖 (c, t) 的 fiberwise 归一化常数 (见 §5.4, 它将被 centering 吸收)。

Proposition 5.4 (理想残差 reward). (第一类, 精确恒等式。)在下列前提下: (i) 阶段对齐取(44) 的 *KL-RLHF* 形式且 *reference* 为当前模型 $p_{i-1,t}$; (ii) *Gibbs* 闭式解(45) 成立 (*Lem. 5.3* 的可积性); (iii) 存在绝对目标势能 U_i^* (*Def. 5.1*)。则使(44) 的最优解恰为 q_i^* 的理想 *reward* 满足

$$\boxed{\frac{R_i^{\text{ideal}}(c, x, t)}{\beta_i} = U_i^*(c, x, t) - B_{i-1}(c, x, t)} \quad (47)$$

在 *fiberwise* 加常数 $\log Z_i^{\text{KL}}(c, t)$ 的意义下成立 (该常数不影响条件分布, 见 *Rem. 5.2* 与 §5.4)。

Proof. 由(46) 直接解出 $R_i/\beta_i = U_i^* - B_{i-1} + \log Z_i^{\text{KL}}(c, t)$ 。 $\log Z_i^{\text{KL}}$ 仅依赖 (c, t) ，在每个 c -fiber 上是常数，对 $q_i^*(\cdot|c)$ 的归一化无影响，故略去后得(47)。 $\square$

Caveat 5.5 (这是命题而非无条件递推). (47) 不是 "reward 可任意叠加" 的递推断言。它仅说：若本阶段终点设为 q_i^* ，则等价理想 reward 必为残差势能 $U_i^* - B_{i-1}$ 。前提 (iii) "存在绝对目标势能" 是建模假设；前提 (i) 规定了 reference 是当前模型而非 base，这正是 "多阶段对齐作用在残差势能上" 的来源。有限模型族下，实际更新是该理想残差在可达子空间上的投影（见 Sec. 7），(47) 给出的是其无约束理想终点。

Remark 5.6 (步长 η_i 与温度 $1/\beta_i$ 的标定). (第一类，bookkeeping identity，无近似。) 残差的归一化约定直接决定理想一步更新的匹配系数 η_i ，须与 Sec. 7 的递推 $S_{i+1} = S_i + \eta_i \mathcal{L}_i \mathbf{g}_i + E_i$ 一致。

若把逐阶段残差定义为已除温度的量

$$g_i := R_i/\beta_i = U_i^* - B_{i-1},$$

则理想一步更新为 $B_i = B_{i-1} + g_i$ ，即 $\boxed{\eta_i = 1}$ ：此时 g_i 已自带 $1/\beta_i$ 归一化，匹配系数恒为 1。本文 $g_i^{(0)}$ （下文(51)）正取此约定，故与之配套的步长为 $\eta_i = 1$ 。

系数 $\eta_i = 1/\beta_i$ 仅当残差以未除温度的 reward R_i 本身书写时才出现——此时更新须显式补回 $1/\beta_i$ 方能复原 g_i 。两套约定在残差归一化固定后描述同一恒等式，差别纯属记账。

5.3 目标分布的几何平均与 preference-tilt 形式

理想 reward (47) 需要一个具体的目标分布 q_i^* 。一个自然的选择是在阶段数据场与 base 之间作几何平均插值，并叠加一个 preference 倾斜。回顾阶段数据密度 (Sec. 3)

$$q_{i,t}^D(x|c) = \int q_t(x|y) \nu_i(dy|c).$$

Caveat 5.7 (几何平均 + preference-tilt 是建模选择，非推导). (第三类 / 建模假设。) 以下 q_i^* 的具体形式并非从 Prop. 5.4 导出。Prop. 5.4 只断言 "给定 q_i^* 则理想 reward 为残差势能"，并未指定 q_i^* 。下式是 "数据 vs. base 插值 + preference 重加权" 的自然 Gibbs target：它使 γ_i 控制向数据场倾斜的强度、 $\Phi_i^\dagger$ 注入偏好曲率，且在 $\gamma_i \in \{0, 1\}$ 、 $\Phi_i^\dagger \equiv 0$ 时分别退化为 base 与纯数据场。但其它目标（例如算术插值、 f -散度投影目标、或带约束的 transport target）同样 admissible；选择此形式是一项可被替换的建模决定。

在此建模选择下，取目标分布为加权几何平均叠加 preference-tilt：

$$q_i^*(x|c) = \frac{1}{Z_i(c, t)} q_{i,t}^D(x|c)^{\gamma_i} p_{0,t}(x|c)^{1-\gamma_i} \exp(\Phi_i^\dagger(c, x, t)), \quad \gamma_i \in [0, 1], \quad (48)$$

其中 $\Phi_i^\dagger$ 为 preference 势能， $Z_i(c, t) = \int q_{i,t}^D(x|c)^{\gamma_i} p_{0,t}(x|c)^{1-\gamma_i} \exp(\Phi_i^\dagger) dx$ 是 fiberwise 配分函数（须 $< \infty$ ）。代入(43) 并用 $\log p_{0,t}^{1-\gamma_i} - \log p_{0,t} = -\gamma_i \log p_{0,t}$ ：

$$\boxed{U_i^*(c, x, t) = \gamma_i \log \frac{q_{i,t}^D(x|c)}{p_{0,t}(x|c)} + \Phi_i^\dagger(c, x, t) - \log Z_i(c, t)} \quad (49)$$

此为代入式(48) 后的精确恒等式（第一类，在 Caveat 5.7 选定的 q_i^* 形式之下）。注意 $\log Z_i(c, t)$ 仅依赖 (c, t) 。

5.4 fiberwise centering 与势能残差 $g_i^{(0)}$

在条件 (fiber) 框架下, 每个 c -fiber 上 $p_{i,t}(\cdot|c)$ 必须各自归一化, 故只依赖 c (与 t) 的常数 (如 $\log Z_i^{\text{KL}}$ 、 $\log Z_i$) 是 fiberwise gauge: 它们被归一化吸收, 对条件分布无效。为消除这一 gauge 自由度, 引入 fiberwise centering 算子。

Definition 5.8 (fiberwise centering). 对 $f : (c, x) \mapsto f(c, x)$, 定义

$$C_{i-1}[f](c, x) := f(c, x) - \mathbb{E}_{p_{i-1,t}(\cdot|c)}[f(c, X)], \quad (50)$$

即在 *reference* 模型 $p_{i-1,t}$ 的每个 c -fiber 上减去条件均值。 C_{i-1} 是到 *fiber* 零均值子空间的逐 *fiber* 正交投影; 任何只依赖 (c, t) 的项落入其核。

Remark 5.9 (centering 自动吸收 fiberwise 归一化). 由 *Def. 5.8*, 对任意只依赖 (c, t) 的 $\kappa(c, t)$ 有 $C_{i-1}[f + \kappa] = C_{i-1}[f]$ 。故(46) 中的 $\log Z_i^{\text{KL}}$ 与(49) 中的 $\log Z_i$ 在 *centering* 后自动消失, 无需显式计算配分函数。这正是 *Prop. 5.4* 与(49) 中可略去 *fiber* 常数的严格依据。

据此, 第 i 阶段的势能残差定义为对理想残差 $U_i^* - B_{i-1}$ 作 fiberwise centering。代入(49) (其中 $\log Z_i$ 被 C_{i-1} 吸收, *Rem. 5.9*):

$$g_i^{(0)} = C_{i-1}[U_i^* - B_{i-1}] = C_{i-1}\left[\gamma_i \log \frac{q_{i,t}^D}{p_{0,t}} + \Phi_i^\dagger - B_{i-1}\right]. \quad (51)$$

Proposition 5.10 ($g_i^{(0)}$ 的良定与无 gauge 性). (第一类, 结构性, 在(48) 的建模选择之下。)设(51) 中各 $\log$ 比值 ρ -a.e. c 属于 $L^1(p_{i-1,t}(\cdot|c))$ 。则 $g_i^{(0)}$ 在每个 c -fiber 上满足 $\mathbb{E}_{p_{i-1,t}(\cdot|c)}[g_i^{(0)}(c, X)] = 0$, 故 $g_i^{(0)}$ 落在 *reference* 模型的 *fiber* 切空间内, 且不含任何 *fiberwise* 归一化自由度; 特别地 $g_i^{(0)}$ 与配分函数 Z_i 、 Z_i^{KL} 无关。

Proof. $C_{i-1}[f]$ 的条件均值为 $\mathbb{E}_{p_{i-1,t}(\cdot|c)}[f - \mathbb{E}_{p_{i-1,t}(\cdot|c)}[f]] = 0$, 零均值性即得; 切空间归属与 gauge 无关性由 *Rem. 5.9* 立得。□

Remark 5.11 (与双残差及全局 COV 的衔接). (51) 给出的 $g_i^{(0)}$ 只是复合残差 $\mathbf{g}_i = (g_i^{(0)}, \sqrt{\rho_G} g_i^{(G)})$ 的势能分量。它回答”目标分布相对当前模型还差多少”, 却不刻画该目标场的几何是否稳定、可达、是否由正确的全局 COV 支撑——后者由全局 COV 残差 $g_i^{(G)} = G_i^* - G_{i-1}$ 承担。两者的堆叠、权重 ρ_G 、以及局部二阶投影 $\mathcal{R}_z[g_i^{(G)}]$ 的引入见 *Sec. 6* 与 *Sec. 4*。势能残差 $g_i^{(0)}$ 经 *ridge-regularized* 线性响应算子 $\mathcal{L}_i$ (非投影) 传入状态递推, 见 *Sec. 7*。

6 双残差: 势能残差与全局 COV 残差

本节把第 i 步训练所要驱动的”残差”从单一的势能残差扩展为双残差: 势能残差 $g_i^{(0)}$ 与全局 COV 几何残差 $g_i^{(G)}$, 并把二者堆叠为复合残差 $\mathbf{g}_i$ 。势能残差刻画”目标分布相对当前模型还差多少”, 但它不回答另一个问题: 这个目标场的几何是否稳定、是否可达、是否由正确的全局 COV 支撑。下文先给出动机, 再定义复合残差所在的 Hilbert 空间, 最后给出局部二阶残差的显式分解并修正原稿中以” $\approx$ ”掩盖的跳步。

6.1 动机: 单看势能残差不够

回顾 *Sec. 5* 给出的中心化势能残差

$$g_i^{(0)} = C_{i-1}\left[\gamma_i \log(q_{i,t}^D/p_{0,t}) + \Phi_i^\dagger - B_{i-1}\right] = C_{i-1}[U_i^* - B_{i-1}], \quad (52)$$

其中 $C_{i-1}[f](c, x) = f(c, x) - \mathbb{E}_{p_{i-1,t}(\cdot|c)}[f(c, X)]$ 为 fiberwise centering (只依赖 c 的常数被归一化吸收)。式 (52) 给出”以当前模型 $p_{i-1,t}$ 为 *reference* 时, 理想的 KL-RLHF reward 方向”, 即目标势能 U_i^* 减当前累计势能 B_{i-1} 后在 *fiber* 上中心化。

Remark 6.1 (势能残差的盲区). $g_i^{(0)}$ 只携带一阶（势能落差）信息。它无法分辨两种情形：(i) 目标势能确实需要大幅抬升、且其曲率几何与当前模型一致；(ii) 势能落差很小、但目标场的二阶几何（score covariance / posterior cumulant）与当前模型严重不符。情形 (ii) 下，仅以 $g_i^{(0)}$ 为驱动会沿一个几何不被支撑的方向更新，表现为可达性不足、训练晃动或低频绑定。故须额外引入刻画二阶几何落差的残差分量。

6.2 全局 COV 残差

按 Sec. 4 的约定， $G_i \in \mathcal{G}$ 表示第 i 阶段模型的全局 COV / posterior-cumulant 几何状态（而非某个局部点的 Hessian）。第 i 步控制 u_i 通过阶段数据测度 ν_i 与标签映射 T_i 诱导阶段数据密度 $q_{i,t}^D(x | c) = \int q_t(x | y) \nu_i(dy | c)$ 及 posterior responsibility $\alpha_i(y | x, c, t)$ ，进而诱导一个目标全局几何。

Definition 6.2 (全局 COV 目标与 COV 残差). 记由 $q_{i,t}^D$ 与 α_i 诱导的全局 posterior-cumulant 几何为

$$G_i^*(u_i) \in \mathcal{G} \quad (\text{global posterior cumulant geometry induced by } q_{i,t}^D \text{ and } \alpha_i), \quad (53)$$

其 fiberwise / 逐点限制经 $\mathcal{R}_z$ 给出局部二阶形 $\Sigma_i^D(z) = \text{Cov}_{\alpha_i}(s_Y)$ （见 Sec. 4）。定义全局 **COV** 残差

$$g_i^{(G)} = G_i^*(u_i) - G_{i-1} \in \mathcal{G}. \quad (54)$$

Remark 6.3. 式 (54) 的减法在几何状态空间 $\mathcal{G}$ 上进行。当 $\mathcal{G}$ 是矩阵值场或在固定参考点的切空间上取仿射结构时， $g_i^{(G)}$ 为良定义的 $\mathcal{G}$ 中元素；否则应理解为在 G_{i-1} 处的切向量 $g_i^{(G)} \in T_{G_{i-1}}\mathcal{G}$ 。本文以下默认 $\mathcal{G}$ 取此线性化结构，与状态递推中 $S_i = (B_i, G_i)$ 的加法更新相容。

6.3 复合残差 Hilbert 空间

把势能残差与 COV 残差堆叠，得到驱动状态递推的复合残差。

Definition 6.4 (复合残差与加权内积). 设势能残差所在的（中心化函数）切空间为 $\mathcal{T}$ ，全局几何残差所在的空间为 $\mathcal{G}$ 。给定几何权重 $\rho_G \geq 0$ ，定义复合残差

$$\mathbf{g}_i = (g_i^{(0)}, \sqrt{\rho_G} g_i^{(G)}) \in \mathcal{T} \oplus \mathcal{G}, \quad (55)$$

并在 $\mathcal{T} \oplus \mathcal{G}$ 上赋予加权内积

$$\langle (a, A), (b, B) \rangle = \langle a, b \rangle_M + \rho_G \langle A, B \rangle_{\mathcal{G}}, \quad (56)$$

其中 $\langle \cdot, \cdot \rangle_M$ 是由度量 M （即控制中的训练度量 M_i ，见 Sec. 7）诱导的 $\mathcal{T}$ 内积， $\langle \cdot, \cdot \rangle_{\mathcal{G}}$ 是 $\mathcal{G}$ 上的固定内积。相应范数记为 $\|\mathbf{g}_i\|^2 = \|g_i^{(0)}\|_M^2 + \rho_G \|g_i^{(G)}\|_{\mathcal{G}}^2$ 。

Remark 6.5 (内积中的 $\sqrt{\rho_G}$ 与 ρ_G 一致). 分量 (55) 取 $\sqrt{\rho_G} g_i^{(G)}$ ，而内积 (56) 的第二项权重为 ρ_G ，二者一致：在标准（未加权）内积下计算 $\mathbf{g}_i$ 自身范数， $\|(g_i^{(0)}, \sqrt{\rho_G} g_i^{(G)})\|^2 = \|g_i^{(0)}\|_M^2 + \rho_G \|g_i^{(G)}\|_{\mathcal{G}}^2$ ，恰为 (56) 在对角线上的取值。 $\rho_G = 0$ 退化为纯势能残差驱动（忽略几何残差）， $\rho_G \rightarrow \infty$ 退化为纯几何对齐。 ρ_G 由控制者选择，刻画“一阶势能落差”与“二阶几何落差”的相对重要性。

Caveat 6.6 ($\mathcal{T} \oplus \mathcal{G}$ 为 Hilbert 空间所需假设). $(\mathcal{T} \oplus \mathcal{G}, \langle \cdot, \cdot \rangle)$ 构成 Hilbert 空间，要求：(i) $M \succeq 0$ 且在所考虑的残差子空间上 $M \succ 0$ ，使 $\langle \cdot, \cdot \rangle_M$ 为内积（半正定情形须先商去 M 的零空间）；(ii) $\rho_G \geq 0$ 且 $\langle \cdot, \cdot \rangle_{\mathcal{G}}$ 正定；(iii) $\mathcal{T}$ 、 $\mathcal{G}$ 关于各自范数完备。当 $\rho_G = 0$ 时第二分量退化为半范数，此时 $\mathbf{g}_i$ 取值于商空间 $\mathcal{T}$ 。原稿未声明这些条件即直接使用堆叠内积，此处补全。

6.4 局部二阶残差分解（修正“ $\approx$ ”）

原稿写”局部二阶项约等于全局 COV 残差的投影加局部 Hessian 平均项残差”，以一个未加限定的” $\approx$ ”掩盖了线性化与局部性假设。下面把它拆为两层：抽象的加性恒等式，以及把全局量限制到局部点的第二类近似。

记 $\Delta_i[\cdot]$ 表示同一泛函在第 i 步目标量与第 $i-1$ 步当前量处取值之差（即对应残差），例如 $\Delta_i \mathbb{E}_\alpha[H_Y](z) = \mathbb{E}_{\alpha_i}[H_Y](z) - \mathbb{E}_{\alpha_{i-1}}[H_Y](z)$ ， $\Delta_i \nabla_x^2 \Phi^\dagger(z) = \nabla_x^2 \Phi_i^\dagger(z) - \nabla_x^2 \Phi_{i-1}^\dagger(z)$ 。

Proposition 6.7 (局部二阶残差分解). 在点 $z = (c, x, t)$ 处，把局部二阶残差 $g_i^{(2, \text{loc})}(z)$ 定义为局部二阶形与当前局部二阶形之差。则它加性地分裂为”posterior score covariance 残差”与”条件 Hessian 平均项与 preference curvature 的残差”之和：

$$g_i^{(2, \text{loc})}(z) = \underbrace{(\Sigma_i^D(z) - \Sigma_{i-1}^D(z))}_{\text{COV 残差}} + \underbrace{(\Delta_i \mathbb{E}_\alpha[H_Y](z) + \Delta_i \nabla_x^2 \Phi^\dagger(z))}_{\mathbb{E}_\alpha[H_Y] \text{ 与 preference curvature 的残差}}. \quad (57)$$

进一步，在 Assumption 6.9 的局部性与线性化下，首项的 COV 残差可由全局 COV 残差的限制表示：

$$g_i^{(2, \text{loc})}(z) = \mathcal{R}_z[g_i^{(G)}] + (\Delta_i \mathbb{E}_\alpha[H_Y](z) + \Delta_i \nabla_x^2 \Phi^\dagger(z)) + E_i^{(2)}(z), \quad (58)$$

其中 $\mathcal{R}_z : \mathcal{G} \rightarrow \text{Sym}$ 是把全局几何状态限制到 z 处局部二阶形的（线性化）限制算子； $H_Y = \nabla_x^2 \log q_t(x | y)$ 为条件 log-密度的 Hessian； $\mathbb{E}_\alpha[H_Y]$ 为对 posterior responsibility α_i 的平均； $\Phi_i^\dagger$ 为 preference potential； $E_i^{(2)}(z)$ 为高阶余项。第二类（局部二阶近似）：式 (57) 是抽象加性恒等式，而把 $\Sigma_i^D(z) - \Sigma_{i-1}^D(z)$ 替换为 $\mathcal{R}_z[g_i^{(G)}]$ 依赖 Assumption 6.9；忽略 $E_i^{(2)}(z)$ 即得式 (58) 的局部二阶近似。

Remark 6.8 (式 (57) 的来源). 局部二阶形（即 $\Sigma^{\text{loc}}(z)$ 所对应的景观曲率）由两部分构成：posterior score covariance $\Sigma^D = \text{Cov}_\alpha(s_Y)$ 与条件 Hessian 平均 $\mathbb{E}_\alpha[H_Y]$ ，再叠加 preference 项的曲率 $\nabla_x^2 \Phi^\dagger$ 。其根据是 Sec. 4 的 Hessian-of-log-mixture 分解（COV，非 convolution）

$$\nabla_x^2 \log q_{i,t}^D(x | c) = \mathbb{E}_{\alpha_i}[H_Y] + \Sigma_i^D, \quad \Sigma_i^D = \text{Cov}_{\alpha_i}(s_Y). \quad (59)$$

对其取第 i 步与第 $i-1$ 步之差即得式 (57)： Σ^D 部分的差为首项， $\mathbb{E}_\alpha[H_Y]$ 与 preference 曲率之差合为尾项。 Σ^D 部分的全局对应物即 $g_i^{(G)}$ ，经 $\mathcal{R}_z$ 限制到 z 得式 (58) 的首项；其余两项之差构成尾项。因此式 (57) 为恒等式，而”用 $\mathcal{R}_z[g_i^{(G)}]$ 这一全局量的限制去代表局部 Σ^D 残差”则依赖局部性与线性化，整体结论标为第二类（局部二阶近似）。

Assumption 6.9 (局部性与限制算子线性化). Proposition 6.7 由恒等式 (57) 过渡到可用近似 (58) 须满足：(i) 局部性：在目标点 z 的邻域内 $\Sigma_i^D(z) = \mathcal{R}_z(G_i^*)$ 与 $\Sigma_{i-1}^D(z) = \mathcal{R}_z(G_{i-1})$ 以可忽略误差成立（即全局几何在该 fiber 上的限制能代表局部 score covariance）；(ii) 线性化：限制算子 $\mathcal{R}_z$ 在 G_{i-1} 处可线性化，从而 $\mathcal{R}_z(G_i^*) - \mathcal{R}_z(G_{i-1}) = \mathcal{R}_z[g_i^{(G)}] + o(\|g_i^{(G)}\|)$ ；(iii) 小步： $\|g_i^{(G)}\|$ 与各 Δ_i 充分小，使一阶项主导。若任一条件不成立，式 (58) 的余项 $E_i^{(2)}(z)$ 不可忽略，应保留并归入状态递推的误差项 E_i 。

Caveat 6.10 ($\mathcal{R}_z[g_i^{(G)}]$ 不可与 $g_i^{(2, \text{loc})}$ 混同). 首项 $\mathcal{R}_z[g_i^{(G)}]$ 只是局部二阶残差中”由全局 COV 残差贡献”的部分。当 $\mathbb{E}_\alpha[H_Y]$ 与 preference curvature 的残差不可忽略时， $g_i^{(2, \text{loc})}(z) \neq \mathcal{R}_z[g_i^{(G)}]$ ；原稿以单一” $\approx$ ”隐去尾项，本节将其显式保留为 (58) 的第二个加项。

6.5 概念修正：不直接优化局部 COV，而是限制全局几何

Remark 6.11 (方法论结论). 双残差结构给出一个关键的概念修正：我们不直接以某个局部 COV 矩阵 $\Sigma^{\text{loc}}(z)$ 为优化对象。原因有二。其一，局部二阶形不可由单点直接稳定估计——其样本协方差估计的 bias 与 variance 在样本稀疏时均高，尤其在真子集 $D_2 = S \subsetneq D_1$ 上 $\nu_2 = \mathbf{1}_S \nu_1 / \nu_1(S)$ 的支撑很窄，单 fiber 内有效样本骤减。其二，局部景观本就由全局几何在目标

fiber 上的限制所决定 (Sec. 4)。因此正确做法是：用训练数据估计全局数据场几何 $G_i^*(u_i)$ ，以全局 COV 残差 $g_i^{(G)} = G_i^* - G_{i-1}$ 作为驱动分量，再依赖限制算子 $\mathcal{R}_z$ 在目标点 z 附近给出所需的局部二阶信息。这把高方差的局部量优化，转化为低方差的全局量估计加确定性限制，正是 Sec. 4 所述“楼塔问题”——抬高全局几何地基、并保证其限制到子集 *fiber* 时不偏——的数学动机。（第三类：方法论/经验假设，依赖全局几何可由训练数据稳定估计、且其 $\mathcal{R}_z$ 限制在目标点附近以低 *bias* 代表局部曲率。）

Remark 6.12 (与状态递推的衔接). 复合残差 (55) 正是 Sec. 2 状态递推

$$S_{i+1} = S_i + \eta_i \mathcal{L}_i(S_i, u_i) \mathbf{g}_i(S_i, u_i) + E_i \quad (60)$$

中被算子 $\mathcal{L}_i$ 作用的对象。其中 $\mathcal{L}_i$ 是带 *ridge* 收缩的线性响应算子 $\mathcal{L}_i = \mathcal{L}_i(S_i, u_i)$ ，作用于度量 $M_i[G_i]$ 与 *ridge* λ_i 下的可达空间 $\mathcal{H}_i$ (见 Sec. 7)；仅在 $\lambda_i \rightarrow 0$ 、闭值域、固定度量的极限下 $\mathcal{L}_i$ 才退化为正交投影 Π 。式 (56) 中的度量 M 取为该步的 M_i ，从而残差范数与训练机制所诱导的几何一致。本节只负责定义被驱动的残差及其内积结构； $\mathcal{L}_i$ 如何把 $\mathbf{g}_i$ 投到可达空间 $\mathcal{H}_i$ 、以及由此得到的复合二次型 *minmax* 控制，留待 Sec. 7 展开。

7 复合二次型最优控制与 minmax

本节把“全集-真子集”多阶段对齐刻画为一个状态递推控制问题：以复合状态 $S_i = (B_i, G_i) \in \mathcal{S} = \mathcal{B} \times \mathcal{G}$ 为被控对象（势能场 B_i 与全局 COV 几何 G_i 见 Sec. 5 与 Sec. 6），以阶段控制 u_i 为决策，残差 $\mathbf{g}_i$ 为驱动项。我们逐步给出：控制变量、可达响应算子 $\mathcal{L}_i$ 、状态递推、阶段二次型损失、Bellman 递推与 robust minmax，并在每处标注其层级与所需假设。

7.1 控制变量

第 i 阶段的控制聚合了数据、标签、目标与训练机制三类自由度。

Definition 7.1 (阶段控制). 第 i 阶段控制变量为

$$u_i = (\nu_i, T_i, \gamma_i, \Phi_i^\dagger, \mathcal{H}_i, M_i, \lambda_i, \eta_i) \in \mathcal{U}_i, \quad (61)$$

其中 ν_i 为阶段隐变量测度、 T_i 为标签映射、 $\gamma_i \in [0, 1]$ 为 *data-tilt* 指数、 $\Phi_i^\dagger$ 为偏好势能（以上四者决定目标场 q_i^* 与残差 $\mathbf{g}_i$ ，见 Sec. 5）； $\mathcal{H}_i$ 为可达子空间（*reachable* / *hypothesis* / *LoRA* 子空间）， M_i 为度量、 $\lambda_i \geq 0$ 为 *ridge* 参数、 $\eta_i > 0$ 为步长（以上四者决定训练机制如何把残差投到状态更新上）。 $\mathcal{U}_i$ 为容许控制集。

Caveat 7.2. 此处 $\mathcal{H}_i$ 是可达子空间（ $\mathcal{H}$, *calligraphic*），与条件 *log-density* 的 *Hessian* $H_Y = \nabla_x^2 \log q_t(x|y)$ (*plain H*，见 Sec. 4) 是两个完全不同的对象。原稿在控制元组中写作 H_i ，造成与 *Hessian* 的混淆；本稿一律以 $\mathcal{H}_i$ 记可达子空间，绝不使用裸 H_i 表示子空间。

7.2 可达响应算子

训练机制把残差 $\mathbf{g}_i$ 映射为对状态的实际增量。这一映射受三件事约束：只能在可达子空间 $\mathcal{H}_i$ 内动（参数化/LoRA 限制），度量由几何状态 G_i 诱导，且 *ridge* λ_i 带来收缩。在给出算子前先把“度量由 G_i 诱导”这一表述落实为显式映射，以消除原稿的跳步。

Definition 7.3 (几何诱导度量). 记 $\mathcal{R}_z : \mathcal{G} \rightarrow \text{Sym}$ 为几何状态到点 $z = (c, x, t)$ 处局部二阶形的限制算子（见 Sec. 4 的 *Hessian*/COV 分解）， $\Sigma_i^{\text{loc}}(z) = \mathcal{R}_z G_i \in \text{Sym}$ 。度量由几何状态显式诱导为

$$M_i[G_i](z) = \phi(\mathcal{R}_z G_i) = \phi(\Sigma_i^{\text{loc}}(z)), \quad (62)$$

其中 $\phi : \text{Sym} \rightarrow \text{Sym}_{\geq 0}$ 为一固定的正定化映射（例如 $\phi(\Sigma) = \Sigma + \epsilon \text{id}$ 或 $\phi(\Sigma) = (\Sigma + \epsilon \text{id})$ 之类的 *ridge* 化， $\epsilon > 0$ ），保证 $M_i[G_i](z) \succ 0$ 从而 $\langle \cdot, \cdot \rangle_{M_i[G_i]}$ 为良定内积。

Definition 7.4 (可达响应算子). 给定状态 $S_i = (B_i, G_i)$ 与控制 u_i , 定义可达响应算子

$$\mathcal{L}_i(S_i, u_i) = \Pi_{\mathcal{H}_i}^{M_i[G_i], \lambda_i}, \quad (63)$$

即在度量 $M_i[G_i]$ (由(62) 经 $\mathcal{R}_z$ 从几何状态 G_i 诱导) 下、限制到可达子空间 $\mathcal{H}_i$ 、带 ridge λ_i 的岭正则线性响应算子。在 $M_i[G_i]$ 内积下, 设 P 为 $\mathcal{H}_i$ 上的 (无正则) 正交投影、 A 为相应的响应 (Gram) 算子—— A 为 $M_i[G_i]$ -自伴、半正定, 支集落在 $\mathcal{H}_i$ 上 (故 $PA = AP = A$), 则 $\mathcal{L}_i$ 的作用形如 *shrinkage*:

$$\mathcal{L}_i = A(A + \lambda_i \text{id})^{-1}P, \quad (64)$$

其特征值 (在 $\mathcal{H}_i$ 上为 $a/(a + \lambda_i)$, 在 $\mathcal{H}_i$ 外为 0) 落在 $[0, 1)$ (当 $\lambda_i > 0$)。

Remark 7.5 (度量诱导的层级). (62) 把”度量随几何漂移”显式参数化: $M_i[G_i]$ 随 G_i 更新而变。给定 ϕ 与 G_i 后, $M_i[G_i]$ 是第一类恒等定义; 但用 $\mathcal{R}_z G_i$ (即 Σ_i^{loc}) 作为”训练的有效度量”是一项第三类建模选择 (依赖 COV 几何估计的可测准确性, 见 Sec. 13)。下文”fixed metric”极限即指 $\phi(\mathcal{R}_z G_i)$ 在更新中冻结不变的情形。

Remark 7.6 ($\mathcal{L}_i$ 是收缩线性响应, 不是正交投影; 第一类/第二类). 必须强调: 当 ridge $\lambda_i > 0$ 时, $\mathcal{L}_i$ 是带收缩的线性响应算子, 不是幂等正交投影, 即

$$\mathcal{L}_i^2 \neq \mathcal{L}_i. \quad (65)$$

由(64) 及 $PA = AP = A$, 有 $\mathcal{L}_i^2 = A(A + \lambda_i \text{id})^{-1}A(A + \lambda_i \text{id})^{-1}P \neq \mathcal{L}_i$, 因为 $A(A + \lambda_i \text{id})^{-1}$ 的非零特征值 $a/(a + \lambda_i) \in (0, 1)$ 不满足 $\sigma^2 = \sigma$ 。它退化为正交投影 $\Pi_{\mathcal{H}_i}$ 当且仅当同时满足: $\lambda_i \rightarrow 0$ 、 $\mathcal{H}_i$ 上响应算子 A 闭值域 (closed range, 使 $A(A + \lambda_i \text{id})^{-1} \rightarrow P$ 良定)、且度量 $M_i[G_i]$ 固定 (fixed metric, 不随更新漂移, 见 Rem. 7.5)。该极限恒等式属第一类 (exact identity); 而把有限 λ_i 下的 $\mathcal{L}_i$ 当作投影来推断幅度则是第二类局部近似, 仅在收缩比 $a/(a + \lambda_i) \approx 1$ (强信号方向) 成立。原稿把 $\mathcal{L}_i$ 记为 Π 并隐含幂等性, 本稿在此显式更正。

7.3 状态递推与阶段二次型损失

Definition 7.7 (状态递推). 复合状态按下式演化 (与 Sec. 2 一致):

$$S_{i+1} = F_i(S_i, u_i) = S_i + \eta_i \mathcal{L}_i(S_i, u_i) \mathbf{g}_i(S_i, u_i) + E_i, \quad S_i = (B_i, G_i), \quad (66)$$

其中复合残差 $\mathbf{g}_i = (g_i^{(0)}, \sqrt{\rho_G} g_i^{(G)})$ 由势能残差 $g_i^{(0)} = \mathbf{C}_{i-1}[U_i^* - B_{i-1}]$ 与全局 COV 残差 $g_i^{(G)} = G_i^* - G_{i-1}$ 堆叠 (见 Sec. 6), $\rho_G > 0$ 为两块的相对权重, E_i 为高阶/估计误差项。

Remark 7.8 (递推驱动项的层级). (66) 中”已实现增量 $= \eta_i \mathcal{L}_i \mathbf{g}_i$ ”是一阶 linear response 近似 (小步长 η_i 、 $\mathcal{H}_i$ 内局部线性化), 属第二类; 其线性化误差与 $\eta_i^2 \|\mathbf{g}_i\|^2$ 同阶并吸收进 E_i 。当 $\eta_i \rightarrow 0$ 时该项为 F_i 沿 $\mathbf{g}_i$ 方向的精确方向导数, 方向导数本身属第一类, 幅度推断属第二类。

阶段决策的代价以”未消除的残差”度量。一步更新后剩余残差与其二次型代价定义如下。

Definition 7.9 (残差二次型阶段损失). 单步更新后的剩余残差与阶段损失为

$$r_i = [\text{id} - \eta_i \mathcal{L}_i(S_i, u_i)] \mathbf{g}_i, \quad (67)$$

$$L_i^{\text{stage}}(S_i, u_i) = \langle r_i, Q_i r_i \rangle + \Omega_i(u_i), \quad Q_i \succeq 0, \quad (68)$$

其中 $Q_i \succeq 0$ 为加权矩阵 (以 ρ_G 编码势能块与 COV 块的相对重要性), $\Omega_i(u_i) \geq 0$ 为控制正则 (容量/数据/步长代价)。

Remark 7.10 (阶段损失的层级与几何含义). $r_i = [\text{id} - \eta_i \mathcal{L}_i] \mathbf{g}_i$ 表示”残差中未被本步响应吸收的分量”。算子 $\text{id} - \eta_i \mathcal{L}_i$ 在 $\mathcal{H}_i$ 之外恒为 id (不可达方向残差完全保留), 在 $\mathcal{H}_i$ 之内按 $1 - \eta_i \cdot [a/(a + \lambda_i)]$ 收缩。 L_i^{stage} 在给定(67)–(68) 的二次型设定下是第一类恒等式; 但它作为”真实训练代价”的代理依赖 $\mathbf{g}_i$ 、 $\mathcal{L}_i$ 的二阶近似 (见 Rem. 7.6、Rem. 7.8), 故整体作为决策目标应视为第二类。

7.4 多步最优：Bellman 递推

逐步贪心地最小化各 L_i^{stage} 一般不是多阶段最优（一阶段的 fiber 选择改变 G 与 $\mathcal{H}$ ，影响后续可达性）。正确目标是动态规划。

Definition 7.11 (Bellman 价值递推). 设共 N 阶段、终端目标状态 $S^\dagger$ 、终端代价 $D_T(\cdot, \cdot)$ ，则价值函数满足

$$V_N(S) = D_T(S, S^\dagger), \quad (69)$$

$$V_i(S) = \inf_{u \in \mathcal{U}_i} \left\{ L_i^{\text{stage}}(S, u) + V_{i+1}(F_i(S, u)) \right\}, \quad i = N-1, \dots, 0. \quad (70)$$

最优控制为 $u_i^*(S) \in \arg \min_{u \in \mathcal{U}_i} \{L_i^{\text{stage}}(S, u) + V_{i+1}(F_i(S, u))\}$ 。

Remark 7.12. (70) 的 Bellman 最优性原理对任意满足(66) 的确定性递推与逐阶段可加代价是第一类 (*exact*) 结论；其作为对齐训练的有效目标仅在 F_i, L_i^{stage} 的二阶建模成立时为第二类。下确界的可达性 ($\inf$ 是否取到) 需 $\mathcal{U}_i$ 紧、被积泛函下半连续，否则只能取 ε -最优控制。

7.5 Robust minmax

实际中残差 $\mathbf{g}_i$ 、几何 G_i 、标签映射 T_i 都是估计量，含异质数据扰动、COV 估计误差与标签映射误差。把这些不确定性聚合为对手变量 $\zeta \in \mathcal{Z}_i$ ，得鲁棒控制形式。

Assumption 7.13 (对手扰动模型). 存在紧的不确定集 $\mathcal{Z}_i$ ，使得受扰残差与递推为

$$r_i(S, u, \zeta) = [\text{id} - \eta_i \mathcal{L}_i(S, u)] \mathbf{g}_i(S, u, \zeta), \quad S' = F_i(S, u, \zeta), \quad (71)$$

其中 ζ 同时作用于 $\mathbf{g}_i$ (异质数据/偏好扰动)、 $M_i[G_i]$ 经由 $\mathcal{L}_i$ (COV 估计误差) 与 T_i (标签映射误差)。

Definition 7.14 (Robust minmax 价值). 在 Assumption 7.13 下，鲁棒价值递推为

$$V_i(S) = \inf_{u \in \mathcal{U}_i} \sup_{\zeta \in \mathcal{Z}_i} \left\{ \langle r_i(S, u, \zeta), Q_i r_i(S, u, \zeta) \rangle + V_{i+1}(F_i(S, u, \zeta)) \right\}, \quad (72)$$

即对最坏情况扰动取上确界、再对控制取下确界。

这里必须补全原稿掩盖的一处逻辑跳步： $\inf \sup$ 与 $\sup \inf$ 一般不相等。

Assumption 7.15 (minimax 交换的 Sion 型条件；第三类). (72) 默认采用 $\inf_u \sup_\zeta$ 的次序，是一个 **robust-control** 目标 (对最坏扰动稳健)，并不自动等于经典 *von Neumann* 鞍点 $\sup_\zeta \inf_u$ 。要使两者相等 (*minimax* 交换成立)，需要 Sion 型条件：

(i) 策略集 $\mathcal{U}_i$ 凸、 $\mathcal{Z}_i$ 凸且紧 (*convex compact strategy sets*)；

(ii) *payoff* $J_i(u, \zeta) = \langle r_i(S, u, \zeta), Q_i r_i(S, u, \zeta) \rangle + V_{i+1}(F_i(S, u, \zeta))$ 对 u 拟凸 (*quasiconvex*)、对 ζ 拟凹 (*quasiconcave*)，且分别关于 u 下半连续、关于 ζ 上半连续 (*convex-concave payoff*)。

当 (i)(ii) 成立时

$$\inf_{u \in \mathcal{U}_i} \sup_{\zeta \in \mathcal{Z}_i} J_i(u, \zeta) = \sup_{\zeta \in \mathcal{Z}_i} \inf_{u \in \mathcal{U}_i} J_i(u, \zeta), \quad (73)$$

存在鞍点 (u_i^*, ζ_i^*) ；否则只有弱对偶 $\inf \sup \geq \sup \inf$ ，(72) 仍是良定的 *robust-control* 目标，但不是经典 *von Neumann* 鞍点。

Caveat 7.16 (关于交换条件难成立的提示；第三类). 本问题中 J_i 对 ζ 含二次型 $\langle r_i, Q_i r_i \rangle$ ($Q_i \succeq 0$)，若 r_i 对 ζ 仿射，则该项对 ζ 为凸而非凹，Sion 凹性 (ii) 一般不满足；同时 $\mathcal{U}_i$ 含离散选择 (如 fiber 继承 vs. 重建、 $\mathcal{H}_i$ 的选取) 破坏凸性 (i)。因此(73) 的 *minimax* 交换在一般对齐设定下不可无条件套用；应将(72) 解释为对最坏情况的稳健下确界控制，其层级为第三类 (依赖可验证的凸-凹/紧性结构假设方能升级为鞍点结论)。

Remark 7.17 (与后续偏差-方差分解的衔接). 当对手集退化 ($\mathcal{Z}_i = \{\zeta_0\}$) 时(72) 退回确定性 Bellman (70)。把单阶段 L_i^{stage} 沿 $\mathbf{g}_i$ 展开并代入 r_i 的 $\mathcal{H}_i$ -投影结构，即得“全集投影偏差 + 真子集方差 + 不可达残差”的分解，这正是 Sec. 8 与 Sec. 10 中 fiber 继承/重建判别的代价基础；其中“哪种策略更优”不构成无条件定理，而落到可测诊断量 (见 Sec. 13)。

8 全集–真子集推论：偏差、方差与可达性

第一阶段在全集 D_1 上训练完成后，状态 $S_1 = (B_1, G_1)$ 给出全局几何 $G_1 \in \mathcal{G}$ 与累计势能 B_1 。本节处理真子集 $S = D_2 \subsetneq D_1$ 的核心问题：第二阶段面对的并非“是否继续训练”，而是“继承第一阶段在 S 的纤维上已建立的势能 B_1^S ，还是用真子集重建该纤维以纠正全集投影偏差”。该决策由偏差、方差、可达性、势能残差与终端目标共同支配。原稿在此处以未定义算子 A_S 、 δ_B 与裸 $\approx$ 掩盖了若干逻辑跳步；本节是关键修复节，逐一补全这些定义并标注其层级。

8.1 子集势能 B_1^S ：在受限几何上的对齐映射

第一阶段对全集中每个子点都建立了势能估计。由于 $S \subset D_1$ ，子集 S 中的点在第一阶段已被赋予势能，记为 B_1^S 。原稿把它写成 $B_1^S \approx A_S(\mathcal{R}_S(G_1), D_1)$ 而未定义 A_S 。我们将其改写并显式化： B_1^S 是第一阶段的对齐映射 A_S 在受限几何 $\mathcal{R}_S(G_1)$ 与数据 D_1 上的取值，其中 $\mathcal{R}_S : \mathcal{G} \rightarrow \mathcal{G}$ 是把全局几何状态限制到子集纤维 ($y \in S$, 即 $T_1(y) \in T_1(S)$) 的算子 (见 Sec. 4 的 Hessian/COV 分解给出的 $\mathcal{R}_z, \mathcal{R}_S$)。

Definition 8.1 (第一阶段子集对齐映射 A_S 与子集势能 B_1^S)。设第一阶段在 D_1 上的对齐流以受限几何为度量先验，把残差能量沿可达子空间 $\mathcal{H}_1$ 写入势能。定义对齐映射

$$A_S : (\Gamma, D) \mapsto C_0[\mathcal{L}_1(\Gamma)(U_S^* - B_0)], \quad B_0 \equiv 0, \quad (74)$$

其中 $\Gamma \in \text{Sym}$ 是一个 (受限) 几何二阶型， $\mathcal{L}_1(\Gamma)$ 是以 Γ 为度量、岭参数 λ_1 的线性响应算子 ($\mathcal{L}_1$ 非投影，仅 $\lambda_1 \rightarrow 0$ 、闭值域、固定度量极限退化为 Π ；见 Sec. 6)。子集势能即为

$$B_1^S = A_S(\mathcal{R}_S(G_1), D_1) \quad (75)$$

即“在受限几何 $\mathcal{R}_S(G_1)$ 上、由全集数据 D_1 产生的子集纤维势能”。

Remark 8.2 (B_1^S 不等于“已学会 D_2 ”)。(75) 表明 B_1^S 是全集几何投影到 S 之后的稳定但可能有偏的势能估计，而非真子集目标 B_S^* 。第二阶段决策的本质，是决定是否纠正 $\mathcal{R}_S$ 引入的投影偏差。

分层标注。(74)–(75) 给出的是 B_1^S 对几何 Γ 的依赖结构的精确记号 (第一类, definitional)，其良定义性以 $\mathcal{L}_1$ 在 Γ 上的有界性与 $U_S^* \ll p_{0,t}$ 为条件 (见 Sec. 5)。

8.2 几何估计的偏差–方差分解

第一阶段交付的是有限样本估计 $\hat{G}_1$ ，其受限值 $\mathcal{R}_S(\hat{G}_1)$ 与第二阶段可得直接子集估计 $\hat{G}_S$ 携带不同的误差结构。设 $G_S^* \in \text{Sym}$ 为子集真实目标几何 (S 子目标的二阶型)。

Definition 8.3 (受限全集估计与直接子集估计的误差分解)。

$$\mathcal{R}_S(\hat{G}_1) = G_S^* + \varepsilon_{\text{proj}} + \varepsilon_{\text{stat}}^{(D_1)}, \quad (76)$$

$$\hat{G}_S = G_S^* + \varepsilon_{\text{stat}}^{(S)}. \quad (77)$$

其中：

- $\varepsilon_{\text{proj}} := \mathbb{E}[\mathcal{R}_S(\hat{G}_1)] - G_S^*$ 为确定性投影/近似偏差 (*projection bias*)，刻画“全集几何限制到子集纤维”与“子集真实几何”之间的系统失配；它不随样本数衰减。
- $\varepsilon_{\text{stat}}^{(D_1)} := \mathcal{R}_S(\hat{G}_1) - \mathbb{E}[\mathcal{R}_S(\hat{G}_1)]$ 与 $\varepsilon_{\text{stat}}^{(S)} := \hat{G}_S - \mathbb{E}[\hat{G}_S]$ 为零均值统计误差， $\mathbb{E}[\varepsilon_{\text{stat}}^{(\cdot)}] = 0$ ，其协方差随对应样本计数增大而衰减 (典型地 $\text{Var} \propto 1/N$)。这里假设 $\hat{G}_S$ 关于 G_S^* 渐近无偏，故(77)不含确定性偏差项。

Proposition 8.4 (受限全集 vs. 直接子集：偏差-方差对置). 在 Def. 8.3 的记号下，

$$\text{Bias}(\mathcal{R}_S(\hat{G}_1)) = \varepsilon_{\text{proj}} \neq 0, \quad \text{Bias}(\hat{G}_S) = 0, \quad (78)$$

$$\text{Var}(\mathcal{R}_S(\hat{G}_1)) = \text{Var}(\varepsilon_{\text{stat}}^{(D_1)}) \lesssim \text{Var}(\varepsilon_{\text{stat}}^{(S)}) = \text{Var}(\hat{G}_S), \quad (79)$$

即直接子集估计 $\hat{G}_S$ 偏差更低、方差更高，受限全集估计 $\mathcal{R}_S(\hat{G}_1)$ 偏差更高（含 $\varepsilon_{\text{proj}}$ ）、方差更低。

论证. 偏差式(78) 直接取(76)–(77) 的期望并用 $\mathbb{E}[\varepsilon_{\text{stat}}^{(\cdot)}] = 0$. 方差不等式(79) 中， $|D_1| \geq |S|$ 故 $\mathcal{R}_S(\hat{G}_1)$ 用更多样本估计同一二阶型，统计误差更小； $\lesssim$ 在“两估计采用同型估计量、协方差以样本数为主导标度”的前提下成立。□

Caveat 8.5 ($\lesssim$ 的隐含假设). (79) 把 $\hat{G}_1$ 的全部样本计入对 $\mathcal{R}_S(\hat{G}_1)$ 的方差衰减，隐含假设是全集样本中与子集纤维相关的信息有效转移。若全集异质性高、子集纤维方向与全集主方向相悖，则受限估计的有效样本远少于 $|D_1|$ ， $\lesssim$ 可退化。此为第三类（经验/可测）边界条件，应由子集纤维上的有效样本量诊断。

分层标注。Def. 8.3 是记号约定（第一类）；Prop. 8.4 在无偏性与样本标度假设下为第二类（依赖渐近/有限样本标度），偏差部分则是第一类恒等式。

8.3 势能可定义性误差：从几何扰动到势能扰动

几何估计的误差会经 $\mathcal{A}_S$ 传导到势能本身。原稿用未定义的 δ_B 表示这一传导。我们将其严格定义为对齐映射 $\mathcal{A}_S$ 关于几何的一阶 Fréchet 导数。

Definition 8.6 (势能-几何敏感度算子 δ_B). 设 $\mathcal{A}_S(\cdot, D_1)$ 在 G_S^* 处 Fréchet 可微，其导数记为 $D_G \mathcal{A}_S := D_G \mathcal{A}_S(G_S^*, D_1) : \text{Sym} \rightarrow \mathcal{B}$. 定义势能可定义性误差算子

$$\boxed{\delta_B(\varepsilon) := D_G \mathcal{A}_S \varepsilon} \quad (\varepsilon \in \text{Sym}), \quad (80)$$

即几何扰动 ε 经对齐映射在势能空间 $\mathcal{B}$ 上诱导的一阶（线性化）响应。

把(76) 写成 $\mathcal{R}_S(\hat{G}_1) = G_S^* + (\varepsilon_{\text{proj}} + \varepsilon_{\text{stat}}^{(D_1)})$ ，并对 $\mathcal{A}_S(\cdot, D_1)$ 在 G_S^* 处作一阶 Taylor 展开（记 $B_S^* := \mathcal{A}_S(G_S^*, D_1)$ ），得

$$\boxed{B_1^S = B_S^* + \delta_B(\varepsilon_{\text{proj}}) + \delta_B(\varepsilon_{\text{stat}}^{(D_1)}) + o(\|\varepsilon\|)} \quad (81)$$

分层标注。(80)–(81) 是第二类（局部二阶/一阶线性化近似），其有效性要求几何误差 $\varepsilon = \varepsilon_{\text{proj}} + \varepsilon_{\text{stat}}^{(D_1)}$ 充分小、 $\mathcal{A}_S$ 在 G_S^* 邻域光滑、且高阶余项 $o(\|\varepsilon\|)$ 可忽略。

Remark 8.7 (第二阶段残差是 $U_S^* - B_1^S$ ，而非 $U_S^* - B_0$). 由(81)，第二阶段真子集训练所面对的势能残差不是从零势能 B_0 起算的 $U_S^* - B_0$ ，而是

$$U_S^* - B_1^S = (U_S^* - B_S^*) - \delta_B(\varepsilon_{\text{proj}}) - \delta_B(\varepsilon_{\text{stat}}^{(D_1)}) + o(\|\varepsilon\|), \quad (82)$$

它已经携带第一阶段的稳定性（ $\delta_B(\varepsilon_{\text{stat}}^{(D_1)})$ 项较小）与投影偏差（ $\delta_B(\varepsilon_{\text{proj}})$ 项不衰减）。这是继承路径“低残差但保偏差”的来源：继承同一纤维时，第二阶段的中心化残差为 $g_2^{(0)} = C_1[U_S^* - B_1^S]$ （见 Sec. 6 的双残差 $\mathbf{g}$ ），其中 $\delta_B(\varepsilon_{\text{proj}})$ 不被消去，会沿同一地基被二次强化。

8.4 核心张力与重建判据

综合 Prop. 8.4 与(82)：

核心张力。继承全集纤维 = 低方差、高连续性、保留投影偏差 $\delta_B(\varepsilon_{\text{proj}})$ ；重建真子集纤维 = 低偏差、高方差、上限更高但更不稳定。无条件全序最优不存在：决策取决于数据量、投影误差、可达性、岭强度与终端目标。

设第二阶段步长 η_2 、线性响应 $\mathcal{L}_2$ 、终端二次型度量 $Q \succeq 0$ （由终端目标 U_S^* 与度量 M_2 诱导）。两条路径的期望剩余残差能量定义为施加一步更新 $(\text{id} - \eta_2 \mathcal{L}_2)$ 后的复合残差在 Q 度量下的能量：

$$J_\bullet := \mathbb{E} \left\langle (\text{id} - \eta_2 \mathcal{L}_2) \mathbf{g}_\bullet, Q (\text{id} - \eta_2 \mathcal{L}_2) \mathbf{g}_\bullet \right\rangle, \quad \bullet \in \{\text{inherit}, \text{rebuild}\}, \quad (83)$$

其中继承路径 $\mathbf{g}_{\text{inherit}}$ 以 $g_2^{(0)} = C_1[U_S^* - B_1^S]$ 与 $g_2^{(G)} = G_S^* - \mathcal{R}_S(G_1)$ 堆叠（几何残差小、含偏差），重建路径 $\mathbf{g}_{\text{rebuild}}$ 以直接子集估计 $\widehat{G}_S$ 重设几何（偏差小、方差大）。期望 $\mathbb{E}[\cdot]$ 同时对统计误差 $\varepsilon_{\text{stat}}^{(\cdot)}$ 取平均，故 $J_\bullet$ 含偏差平方项与方差项。

Proposition 8.8 (重建判据：期望剩余残差能量比较). 在(83)的记号与“一步局部线性化、 Q 固定、 $\mathcal{L}_2$ 在两路径上度量可比”的前提下，

$$\boxed{\text{选择重建} \iff J_{\text{rebuild}} < J_{\text{inherit}}} \quad (84)$$

等价地，将 $\mathbb{E} \|\cdot\|_Q^2 = \|\text{Bias}\|_Q^2 + \text{tr}(Q \text{Cov})$ 代入并把各源项展开，重建正收益当且仅当

$$\underbrace{\|\delta_B(\varepsilon_{\text{proj}})\|_{Q'}^2}_{\text{偏差下降 } \text{Bias_reduction}} > \underbrace{\Delta \text{Var}}_{\text{方差增加}} + \underbrace{\Delta \text{Reach}_{\mathcal{H}}}_{\text{可达性损失}} + \underbrace{\Delta \Phi}_{\text{额外势能高度}}, \quad (85)$$

其中 Q' 是经 $(\text{id} - \eta_2 \mathcal{L}_2)$ 与 Q 诱导的有效度量； $\Delta \text{Var} = \text{tr}(Q'(\text{Cov}(\varepsilon_{\text{stat}}^{(S)}) - \text{Cov}(\varepsilon_{\text{stat}}^{(D_1)}))) \geq 0$ 为重建引入的方差增量（由 Prop. 8.4 非负）； $\Delta \text{Reach}_{\mathcal{H}} \geq 0$ 为重建纤维落在可达子空间 $\mathcal{H}_2$ 之外而损失的可写入能量； $\Delta \Phi \geq 0$ 为重建纤维相对继承纤维抬高的势能残差高度（“楼塔地基”项）。

论证. (84) 是 J 比较的定义性陈述。(85) 由偏差-方差分解 $\mathbb{E} \|X\|_Q^2 = \|\mathbb{E} X\|_Q^2 + \text{tr}(Q \text{Cov} X)$ 作用于(83)得到：继承路径的偏差项含 $\delta_B(\varepsilon_{\text{proj}})$ （经(82)），重建路径将其消去但增加方差 $\text{Var}(\varepsilon_{\text{stat}}^{(S)}) > \text{Var}(\varepsilon_{\text{stat}}^{(D_1)})$ ；可达性与势能高度差分别记为 $\Delta \text{Reach}_{\mathcal{H}}, \Delta \Phi$ 。整理同号项即得判据。□

Caveat 8.9 (判据各项均为可测诊断，而非闭式定理). (85) 不给出无条件结论：四项均须落到可测诊断（见 Sec. 13）。具体地—— $\|\delta_B(\varepsilon_{\text{proj}})\|_{Q'}^2$ 由受限几何与子集直接估计之差经 $D_G \mathcal{A}_S$ 传导后估计； ΔVar 由子集纤维上的有效样本量估计； $\Delta \text{Reach}_{\mathcal{H}}$ 由重建方向在 $\mathcal{H}_2$ 上的可达投影残量估计； $\Delta \Phi$ 由两路径的中心化势能残差范数估计。任一项失估，判据即不可判定。

分层标注。Prop. 8.8 为第三类（经验假设 / 可测诊断）：(84) 是定义性比较，(85) 依赖一阶线性化（第二类）与四个可测项的可估性（第三类）。它形式化了原稿的口语判据“重建当且仅当偏差下降 > 方差增加 + 可达性损失 + 额外势能高度”，但明确其为对期望残差能量的不等式，而非无条件最优性陈述。

Remark 8.10 (与“楼塔问题”及一般化的衔接). (85) 解释了“楼变高未必坏”：抬高的势能高度 $\Delta \Phi$ 是代价，但若全局 COV 改善并经局部投影显著提升可达性（即等效地降低 $\delta_B(\varepsilon_{\text{proj}})$ 主导的偏差项），净收益仍可为正——脚下地面升得更多即为赚。该结论与具体模态无关：把 $y = (A, P, W, R)$ 换成 LLM 的领域/任务/风格/偏好，结构不变（见 Sec. 12）；FM 的特殊之处仅在于 COV 场显式出现于 score 的 Hessian H_Y 中（见 Sec. 4），LLM 中则更隐含。继承/重建作为两条具体策略，其纤维路径展开见 Sec. 11。

9 重点案例：先画风后人物

本节把抽象的状态递推对象落到一个具体工程案例：单画师 a_0 的多人物数据集，其中含角色 SKADI；目标是先把画风对齐到 a_0 ，再把人物对齐到 SKADI。本节以严格散文为主，逐一指出该案例在哪些点上与通常的“先学画风、再学人物”直觉相符，又在哪些点上与之相悖。本节不引入新的恒等式，所用全部对象（点 $z = (c, x, t)$ 、潜变量 $y = (A, P, W, R)$ 、全局几何 G_i 、限制算子 $\mathcal{R}_z, \mathcal{R}_S$ 、势能 B_i 、复合状态 $S_i = (B_i, G_i)$ ）均按 Sec. 2、Sec. 4、Sec. 5 已定义者使用；偏差-方差权衡与纤维继承/重建的判据则引用 Sec. 8 与 Sec. 10。

9.1 正确的设定：两阶段、真子集、而非新数据

首先须把工程语言中的”两步训练”精确翻译为本理论的全集–真子集结构，否则后续判据会被错误的数据假设污染。

Definition 9.1 (SKADI 案例的数据结构). 两阶段对齐定义如下。

- 阶段 1 (全集): 单一画师 a_0 的多人物数据集

$$D_1 = (a_0, P_{\text{set}}, W_P, R),$$

即潜变量元组 $y = (A, P, W, R)$ 在该数据集上取 $A = a_0$ (固定画风/域)、 $P \in P_{\text{set}}$ (一组角色, 含 *SKADI*)、 $W = W_P$ (随角色变化的可控属性/服装)、 R 为残差视觉因子。其潜测度记 $\nu_1(dy)$ 。

- 阶段 2 (真子集): 阶段 1 中属于 *SKADI* 的子集

$$D_2 = S = (a_0, \text{SKADI}, W_{\text{SKADI}}, R) \subsetneq D_1,$$

即在同一 ν_1 上条件到事件 $\{P = \text{SKADI}\}$ 。其潜测度由限制给出

$$\nu_2(dy) = \nu_1(dy \mid y \in S) = \frac{\mathbf{1}_S(y) \nu_1(dy)}{\nu_1(S)}, \quad \nu_1(S) \in (0, 1). \quad (86)$$

Remark 9.2 (三处必须澄清的误读). 此设定与三种常见误读不同，它们会改变后文判据的成立条件：

- (i) 阶段 2 不是新数据: D_2 是 D_1 的真子集, ν_2 是 ν_1 的条件测度 (86), 而非外部引入的、可能与 ν_1 互奇异的新分布。这保证阶段 2 不引入新的 *reachability* 方向之外的支撑外质量, 是后文”继承同一 *fiber*”成为合法选项的前提。
- (ii) 阶段 2 不是单张 *SKADI*: D_2 是 *SKADI* 的整个子集 (多姿态、多 W_{SKADI} 、多 R), 故其上的子集几何估计 $\hat{G}_S$ 有非平凡的样本量 $n_2 = \nu_1(S) n_1$ 数量级, 可讨论方差, 而非退化为 δ 测度。
- (iii) 画风标签与人物标签分离: 标签映射 $T_i: y \mapsto c$ 把画风分量 $A = a_0$ 映到独立的 *style fiber* c_A , 把人物分量 $P = \text{SKADI}$ 映到 *person fiber*。二者在 *caption* 中占据可分离的坐标, 故”对齐画风”与”对齐人物”对应不同的条件纤维, 可分别讨论其势能与几何。

Definition 9.3 (相关纤维). 按 $\nu_i(dy \mid c) = \nu_i(dy \mid T_i(y) = c)$, 本案例涉及三条纤维:

- c_A : 画风纤维 ($A = a_0$), 在两阶段中始终作为一条单独的 *fiber* 存在, 因 a_0 在 D_1 与 D_2 中均固定。
- $c_S^{(1)}$: 阶段 1 的 *SKADI* 人物纤维, 即在 ν_1 下条件到 $\{P = \text{SKADI}\}$ 的人物 *fiber*; 它嵌在 a_0 的多人物语境中。
- $c_S^{(2)}$: 阶段 2 的 *SKADI* 人物纤维, 即在 ν_2 下的同一人物 *fiber*。

作为集合, $c_S^{(1)}$ 与 $c_S^{(2)}$ 指向同一语义对象 (同一 *SKADI*), 但二者所依托的几何不同: 前者的 *posterior responsibility* $\alpha_1(\cdot \mid x, c_S^{(1)}, t)$ 在 ν_1 的全集上归一, 后者 α_2 在 ν_2 的子集上归一。这一区别是 8.3 决策的全部根源。

9.2 第一阶段的实质：同时做两件事

工程直觉常把阶段 1 概括为”只学画风”。这是不完整的：用 D_1 训练同时产生了两个对下游有用的产物，分别属于全局几何 G_1 与累计势能 B_1 两个状态分量。

(1) 全局 COV 几何估计 G_1 。阶段 1 在 a_0 的多人物数据上估计全局几何状态

$$G_1 \in \mathcal{G} \quad (\text{全局 COV / posterior-cumulant 几何}),$$

其局部二阶形由限制算子给出 $\Sigma_1^{\text{loc}}(z) = \mathcal{R}_z(G_1)$ ，其中按 Sec. 4 的定义，局部形对应 posterior score covariance $\Sigma_1^D(z) = \text{Cov}_{\alpha_1}(s_Y)$ 。关键之处在于： G_1 的样本支撑是整个 P_{set} ，而非仅 SKADI。多人物覆盖使 G_1 在以下两重意义上更优于任何单角色估计——

- 更稳定（低 *variance*）：估计 G_1 的有效样本量为全集 n_1 ，远大于子集 $n_2 = \nu_1(S) n_1$ ；
- 更广覆盖（低 *bias of the shared geometry*）： a_0 画风所共享的 COV 结构（笔触、配色、构图先验等跨角色不变的二阶几何）由多角色数据共同约束，方向覆盖更全。

此处”更稳定/更广”是关于估计量 $\hat{G}_1$ 的第三类（经验/可测）陈述，其量化与可证伪形式见 Sec. 8：方差随有效样本量下降、共享方向的覆盖随角色多样性上升，均为可测诊断而非无条件定理。

(2) SKADI 子集的单点势能 B_1^S 。因 SKADI 已在 D_1 之中，阶段 1 不仅给出全局几何，还在该几何上为 SKADI 人物纤维建立了势能估计。记

$$B_1^S(c, x, t) = B_1(c, x, t) \Big|_{c \in c_S^{(1)}} = \log \frac{p_{1,t}(x | c)}{p_{0,t}(x | c)} \Big|_{c \in c_S^{(1)}},$$

即累计势能 B_1 在阶段 1 SKADI 纤维上的取值。该势能是构建在 $\mathcal{R}_S(G_1)$ 之上的：限制算子 $\mathcal{R}_S$ 把全局几何 G_1 投影到 SKADI 子集纤维，给出该子集处的二阶形 $\mathcal{R}_S(G_1)$ ，势能更新 $g_1^{(0)} = C_0[U_1^* - B_0]$ 在此度量下被线性响应算子 $\mathcal{L}_1$ 作用而写入 B_1 。

Remark 9.4 (阶段 1 不是”只学画风”)。综合 (1)(2)：阶段 1 的产物是复合状态分量的双重更新——既更新了 G 分量（全局几何 G_1 ），又在该几何的子集限制 $\mathcal{R}_S(G_1)$ 上更新了 B 分量在 SKADI 纤维上的势能 B_1^S 。因此把阶段 1 概括为”仅画风”会丢掉一个关键事实：SKADI 的人物势能在阶段 1 结束时已经非平凡地存在，只是它依托的是全集几何的子集投影 $\mathcal{R}_S(G_1)$ ，而非 SKADI 子集自身估计的几何。这正是阶段 2 决策的对象。

Caveat 9.5 ($\mathcal{R}_S(G_1)$ 携带全集投影偏差)。 B_1^S 依托的二阶形 $\mathcal{R}_S(G_1)$ 是把全集几何 G_1 限制到 SKADI 纤维的结果，而非 SKADI 子集的真实目标几何 G_S^* 。当 a_0 的其他角色在共享 COV 方向上与 SKADI 不一致时， $\mathcal{R}_S(G_1)$ 相对 G_S^* 含有一项不随样本量消失的投影偏差（*projection bias*）

$$b_{\text{proj}} := \mathcal{R}_S(G_1) - G_S^* \quad (\text{的几何度量差}),$$

这是结构性偏差而非估计噪声。该偏差是否需要在阶段 2 修正，正是 8.3 的核心问题；其精确判据属 Sec. 10 的纤维继承/重建分析。此处仅标明： $\mathcal{R}_S(G_1) \neq G_S^*$ 一般成立，等号仅在 SKADI 的子集几何与全集共享几何在 SKADI 纤维上重合时（如 a_0 各角色二阶几何同构）才出现。

9.3 第二阶段的实质：是否用子集几何修正全集投影

承 8.2：阶段 1 已在 $\mathcal{R}_S(G_1)$ 上给出 SKADI 势能 B_1^S ，但 $\mathcal{R}_S(G_1)$ 携带不可约的投影偏差 b_{proj} (Cav. 9.5)。阶段 2 用真子集 $D_2 = S$ 继续训练，其真正的决策不是”要不要学 SKADI”（SKADI 势能已存在），而是：

是否用子集几何估计 $\hat{G}_S$ 去修正阶段 1 的投影 $\mathcal{R}_S(G_1)$ 所含的偏差 b_{proj} ?

(87)

Definition 9.6 (阶段 2 涉及的两个几何). • G_S^* : 目标子集几何, 即 *SKADI* 子集纤维上理想的 *COV/cumulant* 几何 (对应目标 q_S^* 处的 *posterior score covariance*)。它是阶段 2 在 G 分量上想要逼近的真值。

- $\hat{G}_S$: 子集几何估计, 即仅用 $D_2 = S$ 的数据 (样本量 n_2) 估计的 *SKADI* 子集几何。

两条候选路径对应 Sec. 10 的纤维继承 vs. 重建:

- 继承 (**inherit**): 阶段 2 沿用阶段 1 的同一 fiber, 即继续在 $\mathcal{R}_S(G_1)$ 度量上推进 *SKADI* 势能, 不重估几何。其几何分量保留全集投影 $\mathcal{R}_S(G_1)$ 。
- 重建 (**rebuild**): 阶段 2 用子集估计 $\hat{G}_S$ 替换 (或部分替换) $\mathcal{R}_S(G_1)$, 以修正投影偏差 b_{proj} 。

Remark 9.7 (继承与重建的偏差-方差对立). 两条路径恰好落在 Sec. 8 的 *bias-variance* 两端:

- 继承 $\mathcal{R}_S(G_1)$: 低方差、高 (投影) 偏差。几何由全集 n_1 个样本约束, 估计噪声小; 但保留结构性投影偏差 b_{proj} (Cav. 9.5), 即使 $n_2 \rightarrow \infty$ 也不消失。
- 重建 $\hat{G}_S$: 低 (投影) 偏差、高方差。直接对准 G_S^* , 结构性投影偏差被消除 ($\hat{G}_S \rightarrow G_S^*$ 当 $n_2 \rightarrow \infty$); 但仅由子集 n_2 个样本估计, 方差按 $\sim 1/n_2$ 量级, 且在被全集共享几何良好约束的方向上反而劣化 (丢弃了 G_1 的统计力)。

Proposition 9.8 (阶段 2 几何决策的判据形式). 设以几何度量下的均方误差 $\text{MSE}(\hat{G}) = \mathbb{E}\|\hat{G} - G_S^*\|_{\mathcal{M}}^2$ 为准 ($\mathcal{M}$ 为 Sec. 10 指定的、 $\mathcal{G}$ 上的度量, 区别于函数空间度量 M_i), 则”重建优于继承”当且仅当

$$\underbrace{\mathbb{E}\|\mathcal{R}_S(G_1) - G_S^*\|_{\mathcal{M}}^2}_{\approx \|b_{\text{proj}}\|_{\mathcal{M}}^2 + (\text{全集低方差项})} > \underbrace{\mathbb{E}\|\hat{G}_S - G_S^*\|_{\mathcal{M}}^2}_{\approx \text{Var}(\hat{G}_S) (\text{近无偏、高方差} \sim 1/n_2)}. \quad (88)$$

即: 当主导 *LHS* 的投影偏差 $\|b_{\text{proj}}\|_{\mathcal{M}}^2$ (加上全集的小方差项) 超过子集估计方差时, 重建更优; 反之继承更优。更细的做法是按方向 (谱坐标) 分块决策——在全集共享得好的方向继承, 在 *SKADI* 特异方向重建——其精确分解 (含 *ridge* 收缩 λ_i 在两者间插值的最优凸组合) 见 Sec. 10。

Remark 9.9 (分级标注). 本节结论的层级如下, 以免 *over-claiming*:

- Def. 9.1、Def. 9.3、Def. 9.6 及条件测度恒等式 (86) 为第一类 (定义/精确恒等式), 仅依赖 $\nu_1(S) > 0$ 与标签可分离。
- 8.2 中关于 $\hat{G}_1$ ”更稳定、更广覆盖”、8.3 中关于 $\hat{G}_S$ 的方差量级 $\sim 1/n_2$, 均为第三类 (经验/可测诊断), 其可证伪量见 Sec. 8。
- 判据 (88) (*Prop. 9.8*) 为第二类 (局部二阶近似): 它把 *MSE* 在 G_S^* 附近作 *bias² + variance* 的二阶展开, 依赖几何度量 $\mathcal{M}$ 的局部固定、估计量在小邻域内近无偏、以及线性响应算子 $\mathcal{L}_i$ 在 λ_i 处的局部线性化有效; 脱离这些假设, b_{proj} 与 $\text{Var}(\hat{G}_S)$ 的交叉项不再可忽略。

Remark 9.10 (与工程直觉的对照). 回到工程语言: 常见做法”阶段 1 学画风、阶段 2 学 *SKADI*”在本框架下被精确化为——阶段 1 同时给出全局几何 G_1 与建立在 $\mathcal{R}_S(G_1)$ 上的 *SKADI* 势能 B_1^S (8.2); 阶段 2 不是从零学 *SKADI*, 而是决定是否用子集几何 $\hat{G}_S$ 修正阶段 1 的全集投影偏差 (8.3, *Prop. 9.8*)。当 *SKADI* 与 a_0 其余角色的二阶几何高度一致 (b_{proj} 小) 且子集样本 n_2 偏少时, 应继承 $\mathcal{R}_S(G_1)$; 当 *SKADI* 在若干特异方向上明显偏离全集共享几何 (b_{proj} 大) 且 n_2 充足时, 应在那些方向上重建 $\hat{G}_S$ 。这把”画风/人物两步走”从一句操作口诀, 提升为一个有判据、可测量、可分方向决策的几何修正问题。

10 纤维继承与纤维重建的策略空间

本节把第二阶段对子集 $D_2 = S \subsetneq D_1$ 的对齐决策，归结为一个在纤维（fiber）层面上的二选一：在第一阶段已建立的同一条纤维上继续推进势能（纤维继承, inherit），还是借助子集自身的 COV 几何重建纤维（纤维重建, rebuild）。这里“纤维”指由控制 u_i 中的 $(\nu_i, T_i, \mathcal{H}_i, M_i)$ 与全局几何 G_i 经限制算子 $\mathcal{R}_S$ 共同确定的、子集上的局部更新方向族；我们用形式参数 $c_S^{(i)}$ 标记第 i 阶段在子集 S 上实际采用的纤维（即中心化基准 C_{i-1} 、限制 $\mathcal{R}_S G_{i-1}$ 与可达子空间 $\mathcal{H}_i$ 的联合配置）。继承对应 $c_S^{(2)} = c_S^{(1)}$ ，重建对应 $c_S^{(2)} \neq c_S^{(1)}$ 。

为统一记号，约定子集上的目标势能为 $U_S^*(c, x, t) = \log[q_S^*(x|c)/p_{0,t}(x|c)]$ ，第一阶段在子集上遗留的累积势能为 $B_1^S(c, x, t) = B_1(c, x, t)|_{c \in T_2(S)}$ ，子集 COV 几何的样本估计为 $\hat{G}_S$ （由 S 上的 posterior score covariance Σ^D 经聚合得到），全局几何为 G_1 。两种策略共享第一阶段训练所得的参数与全局先验，差别仅在于第二阶段残差 $\mathbf{g}_2$ 的纤维基准与所信赖的几何来源。

10.1 纤维继承： $c_S^{(2)} = c_S^{(1)}$

继承策略保持第二阶段的纤维与第一阶段一致：中心化基准沿用 C_1 （即对 $p_{1,t}(\cdot|c)$ 取条件期望），子集几何不重新估计，而是直接采用对全局先验 G_1 的局部限制 $\mathcal{R}_S G_1$ ，仅在必要处作一阶修正。于是第二阶段的势能残差为

$$g_2^{(0)} = C_1[U_S^* - B_1^S], \quad g_2^{(G)} = \mathcal{R}_S G_1^* - \mathcal{R}_S G_1, \quad (89)$$

其中 $g_2^{(G)}$ 在继承下被压到很小：子集几何只在全局先验上被修正，而非完全重估。复合残差 $\mathbf{g}_2 = (g_2^{(0)}, \sqrt{\rho_G} g_2^{(G)})$ 因 $g_2^{(G)}$ 近零而主要由势能项 $g_2^{(0)}$ 主导。

Remark 10.1 (继承的代价与收益，第三类). (89) 的结构给出如下经验性权衡（其量化均依赖可测诊断，故为第三类）：

- 收益。(i) 势能路径连续： B_2^S 由 B_1^S 经同一纤维平滑推进，势能曲面无跳变；(ii) 残差通常更小：因 B_1^S 已沿该纤维拟合过 S 中的低频共现， $U_S^* - B_1^S$ 在该纤维上的范数一般小于从基模型出发的范数；(iii) 方差低：子集 COV 不被完全重估，避免了少样本下的 $\text{Var}(\hat{G}_S)$ ；(iv) 先验强、优化压力低：更新落在已验证的可达方向 $\mathcal{H}_1$ 上。综括为低方差、低残差、强先验、低优化压力。
- 代价。(i) 保留全局投影 bias： $\mathcal{R}_S G_1$ 把全局几何的投影偏差原样带入子集，凡全集对齐时引入的方向性偏差均被继承；(ii) 势能绑定（potential binding）：单一装束 / 固定低频共现会沿同一条纤维被再次强化，即 C_1 把第一阶段已锚定的低频结构当作基准，使其在第二阶段被进一步加固。综括为保留投影 bias + 势能绑定。

10.2 纤维重建： $c_S^{(2)} \neq c_S^{(1)}$

重建策略仍共享第一阶段参数与全局几何 G_1 ，但更换纤维基准：中心化改以子集自身的条件期望为参照，几何更多依赖子集估计 $\hat{G}_S$ 而非全局限制 $\mathcal{R}_S G_1$ 。相应残差为

$$g_2^{(0)} = C_1[U_S^* - B_1^S], \quad g_2^{(G)} = \hat{G}_S - G_1, \quad (90)$$

其中 $g_2^{(G)}$ 显著非零：它显式地把全局几何替换为子集几何，从而 $\sqrt{\rho_G} g_2^{(G)}$ 在 $\mathbf{g}_2$ 中成为可观分量。注意势能项 $g_2^{(0)}$ 的书写与(89) 同形，但其作用纤维已改变： $U_S^* - B_1^S$ 被投影到由 $\hat{G}_S$ （而非 $\mathcal{R}_S G_1$ ）诱导度量下的可达子空间，故两策略下 $g_2^{(0)}$ 的有效内容并不相同。

Remark 10.2 (重建的代价与收益，第三类). (90) 的结构给出对偶的权衡：

- 收益。(i) 低 bias：用 $\hat{G}_S$ 替换 $\mathcal{R}_S G_1$ 可逃离糟糕的全局投影，去除继承所背负的投影偏差；(ii) 解除旧纤维绑定：换纤维使第一阶段锚定的单一装束 / 低频共现不再被自动强化；(iii) 上限更高：若子集 COV 估计可靠（ $\text{Var}(\hat{G}_S)$ 受控），重建可达到继承无法到达的目标 U_S^* 。综括为低 bias、高上限、脱离旧绑定。

- 代价。(i) 高方差：子集样本少， $\text{Var}(\hat{G}_S)$ 大，几何估计噪声直接进入 $g_2^{(G)}$ ；(ii) 不稳定：高方差几何叠加更换纤维带来的更大势能落差，易诱发低频复述 (recitation)、reward hacking、纹理漂移 (texture drift)；(iii) 对可达性与数据质量敏感：重建依赖 $\mathcal{H}_2$ 是否覆盖 $\hat{G}_S$ 指示的新方向，以及 S 的覆盖与标注质量。综括为高方差、高残差、对 reachability 与数据质量敏感。

Caveat 10.3 (重建的隐含假设, 第三类). 原讨论稿在“重建上限更高”处存在跳步：该结论只在 $\hat{G}_S$ 为 G_S^* 的相合且低方差估计、且重建方向落入可达子空间 $\mathcal{H}_2$ (即 $\mathcal{R}_S(G_S^* - G_1) \in \text{Range}(\mathcal{H}_2)$ 的限制内) 时成立。若任一前提失效，则(90) 的 $g_2^{(G)}$ 主要承载估计噪声，重建非但不降 *bias*，反而以方差换得更差的期望残差能量。下一小节的判别式正是把这一前提显式化为可比较的标量。

10.3 核心判别式：期望残差能量的二次型比较

两策略的取舍不应停留在定性描述，而应落到期望残差能量的标量比较上。沿用状态递推 $S_{i+1} = S_i + \eta_i \mathcal{L}_i \mathbf{g}_i + E_i$ (其中 E_i 为收集非线性、有限步优化与采样误差的误差项)，一步更新后残留在状态空间中、未被线性响应算子 $\mathcal{L}$ 吸收的残差为 $(\text{id} - \eta \mathcal{L}) \mathbf{g}$ ；在度量算子 $Q \succeq 0$ (由复合度量 M_2 与几何权 ρ_G 诱导的对称半正定的能量形) 下，其期望能量定义为

$$J = \mathbb{E} \langle (\text{id} - \eta \mathcal{L}) \mathbf{g}, Q (\text{id} - \eta \mathcal{L}) \mathbf{g} \rangle. \quad (91)$$

此处 $\mathcal{L}$ 为带 ridge 收缩 λ_2 的线性响应算子，并非投影；仅当 $\lambda_2 \rightarrow 0$ 、闭值域且度量固定时其极限才退化为正交投影 Π (见 Sec. 6)。把(89) 与(90) 的复合残差 $\mathbf{g}_2$ 分别代入(91)，得继承与重建两策略下的期望残差能量 J_{inherit} 与 J_{rebuild} 。

Proposition 10.4 (纤维继承/重建判别式, 第三类). 在(91) 的期望残差能量准则下，选择重建当且仅当

$$J_{\text{rebuild}} < J_{\text{inherit}} \quad (\text{第三类: 经验假设 / 可测诊断}). \quad (92)$$

等价地，设 $\Delta J := J_{\text{inherit}} - J_{\text{rebuild}}$ ，则 $\Delta J > 0$ 选重建， $\Delta J < 0$ 选继承， $\Delta J = 0$ 无差异。

Remark 10.5 (判别式的语义分解). (92) 把第 9.1、9.2 节的定性权衡浓缩为单一标量比较，其语义可按 Sec. 8 的 *bias-variance* 分解读出。两策略仅在几何残差项 $g_2^{(G)}$ 上本质不同 (继承为 $\mathcal{R}_S G_1^* - \mathcal{R}_S G_1$ ，重建为 $\hat{G}_S - G_1$)，故 ΔJ 大致由三股力量的代数和决定：

- **bias** 降低 (利重建，使 $\Delta J > 0$)：重建用 $\hat{G}_S$ 替换 $\mathcal{R}_S G_1$ ，消去全局投影偏差在 Q -度量下贡献的那部分确定性残差能量；
- **variance** 增加 (利继承，使 $\Delta J < 0$)： $\mathbb{E} \langle \cdot, Q \cdot \rangle$ 中的期望把 $\text{Var}(\hat{G}_S)$ 经 $(\text{id} - \eta \mathcal{L})$ 传播后计入 J_{rebuild} ，少样本下此项膨胀；
- **reachability** 损失 + 额外势能高度 (利继承，使 $\Delta J < 0$)：若重建方向部分落在 $\mathcal{H}_2$ 之外， $(\text{id} - \eta \mathcal{L})$ 无法将其压缩，残留能量上升；同时换纤维带来的势能落差 ($U_S^* - B_1^S$ 在新纤维下范数增大) 抬高 $g_2^{(0)}$ 的贡献。

因此判别式 $J_{\text{rebuild}} < J_{\text{inherit}}$ 的直白读法是：当且仅当重建所降的 *bias* 能量，超过它所引入的 *variance*、*reachability* 损失与额外势能高度之和时，才应重建。该判据为第三类，因为 $J_{\text{inherit}}, J_{\text{rebuild}}$ 均须经 $\hat{G}_S$ 、 $\text{Var}(\hat{G}_S)$ 与 $\mathcal{H}_2$ 覆盖度等可测诊断估计，而非无条件成立的恒等式 (其估计方法见 Sec. 13)。

11 单步与多步策略分类

本节给出的是一个条件性分类：下表所列每条策略都附带其适用前提、收益方向与失效风险，不构成任何无条件推荐。是否选用某条策略，取决于该场景下可测的样本量、全集到子集的投影偏差、可达性 (即响应算子 $\mathcal{L}_i$ 的谱)、势能残差幅度与终端目标，这些量在不同数据配置下取值不同，因而不存在跨配置的全序最优 (参见 Sec. 9 与 Sec. 14 中的 fiber 策略无条件最优否定结果)。本节属于第三类 (经验假设 / 可测诊断量)：表中“收益”“风险”是对状态递推 $S_{i+1} = F_i(S_i, u_i)$ 各分量定性走向的归纳，其严格化形式见 Sec. 13 的判别条件，此处不充当定理。

Caveat 11.1. 表 1 的“收益”“风险”两列描述的是各策略在典型参数区间内对偏差、方差、可达性与势能残差的影响方向，而非可比较的标量。任意两条策略的优劣只有在固定控制 $u_i = (\nu_i, T_i, \gamma_i, \Phi_i^\dagger, \mathcal{H}_i, M_i, \lambda_i, \eta_i)$ 与数据规模后，经 Sec. 13 的诊断量代入才能判定；脱离这些前提的横向排序无定义。

Table 1: 单步与多步对齐策略的条件性分类（第三类）。

策略	数据结构	收益	风险
单步：单画师 + SKADI + 多衣服	A 固定, P 固定, W 多样	势能集中于单一人物子点、衣服可辨识；样本充足时上限高	多衣服素材不足时不可用；样本少时 COV 估计方差高
单步：单画师 + 多角色	A 固定, P 多样（含 SKADI）	全局画风 COV 几何 G_i 稳定、纹理估计更好	SKADI 单点势能被混合稀释；人物 residual R 更复杂
单步：多画师 + 多角色	$A/P/W$ 全多样	覆盖全面、上限高	各子场 COV 方向可能相悖；大合集常因异质 COV 在 $\mathcal{H}_i$ 中不可达而被平均化
两步：先人物后画风	先建低频人物势能，再做画风几何迁移	先锁定对象、后抬升局部地基	第二步局部场估计偏差大时，势能线性叠加近似失效
两步：先画风后人物	$D_1 =$ 单画师多人物, $D_2 =$ SKADI 真子集 ($D_2 \subsetneq D_1$)	先稳定全局 COV 并在其上建子点势能 B_1^S ，再做子集校正	继承 / 重建 fiber 的 bias-variance 选择是核心

对表中关键判断作三点澄清，以避免逻辑跳步：

- 第三行“被平均化”不是经验描述而有几何根源：当多画师 / 多角色 / 多衣服的条件 score s_y 方向冲突时，其后验 score covariance $\Sigma_i^D = \text{Cov}_{\alpha_i}(s_Y)$ 各向异性增大；若这些主方向落在 LoRA 可达子空间 $\mathcal{H}_i$ 之外（即 $\mathcal{L}_i$ 在该方向上谱值趋零），则训练无法分辨地写入，残差被压成各子场的平均。
- 第四行“线性叠加近似失效”指的是：把第二步的势能更新近似为在第一步势能上叠加 $\eta_i \mathcal{L}_i \mathbf{g}_i$ 这一线性响应步，仅在小步长、局部、 $\mathcal{L}_i$ 近似为定度量响应时成立；当局部场 $\Sigma_i^{\text{loc}}(z) = \mathcal{R}_z(G_i)$ 的估计偏差大时该线性化前提被破坏（见下方 caveat 11.2）。
- 第五行的“子集校正”即 Sec. 9 与 Sec. 10 所述：第一步已在全集几何投影 $\mathcal{R}_S(G_1)$ 上为 SKADI 子点建立 B_1^S ，第二步的真正决策是继承同一 fiber（低方差、保留投影偏差）还是用真子集重建 fiber（低偏差、高方差）。

Caveat 11.2. “两步：先人物后画风”一行的风险陈述依赖一个被原稿隐去的前提：势能的两步叠加被当作线性响应。严格地， $S_{i+1} = S_i + \eta_i \mathcal{L}_i(S_i, u_i) \mathbf{g}_i + E_i$ 中的余项 E_i 仅在局部二阶近似下可忽略（第二类）。若先建人物势能后做画风迁移时，第二步对局部场 $\Sigma_i^{\text{loc}}(z) = \mathcal{R}_z(G_i)$ 的估计偏差较大，则 $\mathcal{L}_i$ 不再近似为固定度量下的响应， E_i 不可忽略，线性叠加图景失效。此即该顺序的特有风险来源。

11.1 为什么大合集 LoRA 常失败

更多画师、更多角色、更多衣服并不自动让 COV 几何更稳定。这里有两股相反的力：一方面样本增多降低估计的 sampling variance；另一方面数据更异质会抬高内禀的 COV 冲突。当不同画师 / 角色 / 衣服的 score 方向在当前 LoRA 可达子空间 $\mathcal{H}_i$ 中相互抵触、且这些方向 $\mathcal{L}_i$ 写不进去时，训练只能落到各方向的平均，表现为纹理糊化、细节丢失或错误绑定。其逻辑链为三行（第三类）：

$$\begin{array}{l}
\text{更多数据} \implies \text{更低的 sampling variance;} \\
\text{更异质的数据} \implies \text{可能更高的内禀 COV conflict;} \\
\text{成功要求 COV 方向在 } \mathcal{H}_i \text{ 中可达对齐 (reachable alignment).}
\end{array} \tag{93}$$

Remark 11.3. 式 (93) 是第三类经验诊断而非定理：三行各自对应一个可测量——*sampling variance* 可由重采样估计，内禀 *COV conflict* 可由后验 *score covariance* Σ_i^D 的各向异性度量，*reachable alignment* 可由 $\mathcal{L}_i$ （或其在目标方向上的谱投影）刻画。它解释的是“大合集 *LoRA* 常失败”这一经验现象的来源，而非断言其必然失败：当异质 COV 的主方向恰好落入 $\mathcal{H}_i$ 且彼此不相悖时，大合集反而上限更高（参见表 1 第三行的“收益”列与 *Sec. 13* 的可达性诊断）。前两行的“相反力”是否净为负，须由具体诊断量代入判定，不可无条件下结论。

12 推广到 LLM 与一般任务

前面各节的状态递推 $S_{i+1} = F_i(S_i, u_i) = S_i + \eta_i \mathcal{L}_i(S_i, u_i) \mathbf{g}_i(S_i, u_i) + E_i$ 及其全集-真子集张力（见 *Sec. 9* 的先画风后人物案例、*Sec. 11* 的纤维继承/重建策略空间）是在图像 / Flow Matching 语境中显式建立的。本节说明：该结构并非角色画风 *LoRA* 专属，而是任何”全集对齐之后再对真子集对齐”任务的共性。推广的代价与限度必须逐项交代——LLM 与 FM 在潜变量记号与 *COV* 几何的显式性上有实质差异，照搬恒等式会越界。本节所有断言均为第三类（结构类比 / 经验假设）：它们指出”同构”，但同构是否真的成立须由可测诊断量在具体数据、架构、训练机制下检验，而非由推导保证。

12.1 潜变量与几何的对应映射

回顾图像潜变量 $y = (A, P, W, R)$ （ A 风格/画师/域， P 角色/实体， W 可控属性/服饰， R residual 视觉因子）。把它逐分量替换为 LLM / 一般任务中的对应对象，即得同一形式框架。注意：原讨论稿把 LLM 侧列为”领域、任务、风格、用户群、问题类型、偏好类型”六项，比图像侧的四个分量多；这是因为图像侧的可控属性槽 W 与 residual 槽 R 在 LLM 中各自分裂为两类可观测维度。下表给出严格的多对一/一对多对应，而非逐字一一对应。

潜变量分量	图像语义	LLM / 一般任务语义
A	画师 / 风格 / 域	领域 (domain): 知识域、语料源、行业
P	角色 / 实体	任务类型 (task) / 问题类型 (question-type): 指令族、技能
W	可控属性 / 服饰	风格 / 用户群 (style / user-group): 语气、人格、受众
R	residual 视觉因子	residual 偏好因子 (preference-type): 答案细节、格式、未标注偏好

Remark 12.1 (映射的层级). 该对应是一个建模选择，不是恒等式。它声明”存在一个潜变量分解 $y = (A, P, W, R)$ 与标签映射 $T_i: y \mapsto c$ ，使 LLM 阶段数据测度 $\nu_i(dy)$ 、条件 fiber $\nu_i(dy | c)$ 与图像侧同构”。该声明成立的前提是：LLM 任务确有可分离的领域/任务/风格/偏好结构，且训练 *caption* (*system prompt*、*task tag*、*preference label*) 确实落在 T_i 的像中。前提不满足时（例如域与任务在数据中纠缠不可分），下表的分量对应退化，但全集-真子集的偏差-方差结构仍可在不分解 y 的粗粒度上成立。此为第三类。

12.2 两阶段结构的同构

在上述映射下，全集-真子集两阶段对齐写成与图像侧完全相同的控制问题。设 $D_2 = S \subsetneq D_1$ ， $\nu_2(dy) = \nu_1(dy | y \in S) = \mathbf{1}_S \nu_1 / \nu_1(S)$ ，则

$$\text{Stage 1 (全集对齐): 在 } D_1 \text{ 上做全局 RLHF / SFT} \Rightarrow S_1 = (B_1, G_1), \tag{94}$$

$$\text{Stage 2 (子集对齐): 在 } D_2 \text{ 上对齐} \Rightarrow \text{继承 (inherit) 或重建 (rebuild) fiber.} \tag{95}$$

其中 B_1 为累计势能状态, $G_1 \in \mathcal{G}$ 为全局几何状态。与图像侧一致, Stage 1 在全集几何上同时为 D_2 中的子点建立了势能估计 B_1^S (即 B_1 限制到 S 上的分量, 建立在投影 $\mathcal{R}_S(G_1)$ 之上); Stage 2 的真正决策不是”是否继续训练”, 而是(95)中的继承/重建二选一。这与 Sec. 6–11 建立的判别完全平行: 继承对应低方差、低残差、保留全集投影偏差; 重建对应低偏差、高方差、上限更高但对可达性与数据质量更敏感。

Remark 12.2 (LLM 中”重建 fiber”的工程对应). 图像侧”继承同一 *SKADI fiber* 还是换一条 fiber”的抽象选择, 在 LLM 工程中有直接对应: 第二阶段是否沿用原有的 *task tag*、*reward head* 或 *adapter route*。沿用同一条件路径即继承 ($c_S^{(2)} = c_S^{(1)}$), 换新 *task tag* / 新 *reward head* / 新 *adapter* / 重定义对齐路线即重建 ($c_S^{(2)} \neq c_S^{(1)}$)。因此”是否复用任务标签 / *reward head* / *adapter route*”本质上就是继承–重建抉择的工程外化, 受同一组诊断量 (见 Sec. 13: 全集投影偏差 $\|\mathcal{R}_S(G_1) - G_S^*\|$ 、子集估计方差 $\text{Var}(\hat{G}_S)$ 、势能残差 $\|C[U_S^* - B_1^S]\|$ 、可达性 $\mathcal{L}_i$ 之谱或 χ_k) 支配。此为第三类 (可测诊断, 非无条件定理)。

12.3 LLM 中的几何状态 G

图像侧 G_i 是 posterior score covariance / 数据场协方差几何, 并通过 $\mathcal{R}_z(G_i) = \Sigma_i^{\text{loc}}(z)$ 给出局部二阶形式 (见 Sec. 4 的 Hessian 分解 $\nabla_x^2 \log q_{i,t}^D = \mathbb{E}_{\alpha_i}[H_Y] + \Sigma_i^D$)。在 LLM 中, 几何状态 $G_i \in \mathcal{G}$ 可由下列任一对象实例化:

- 语义特征共现几何 (semantic co-occurrence geometry): token / 概念在条件 fiber 下的二阶共现结构;
- 偏好 reward manifold: reward 模型在回答空间上诱导的曲率流形;
- 任务分布场 (task-distribution field): 指令族在表示空间中的协方差几何;
- 指令–回答映射的局部曲率 (instruction–answer local curvature);
- 领域知识图谱的 posterior covariance (domain-KG posterior covariance)。

Caveat 12.3 (COV 几何的显式性差异: 勿照搬 Hessian 恒等式). 图像 / FM 的关键便利是: 数据场是连续状态 $x \in \mathbb{R}^d$ 上的密度, 故 COV 几何显式地以 *score Hessian* 的形式出现——

$$\nabla_x^2 \log q_{i,t}^D(x | c) = \mathbb{E}_{\alpha_i}[H_Y(x, t)] + \Sigma_i^D(x, t | c), \quad \Sigma_i^D = \text{Cov}_{\alpha_i}(s_Y),$$

这是第一类恒等式 (见 Sec. 4), 其成立依赖 x 连续、 $q_t(x | y)$ 二阶可微、*posterior responsibility* α_i 良定义。LLM 的生成对象 $z = (c, y)$ 是 token 序列上的离散对象, 不存在 $\nabla_x^2 \log q_t$, 故该 Hessian 分解不能逐字搬运: LLM 中 COV 几何是隐含的 (结构上同型, 但没有现成的二阶导数恒等式承载它)。要在 LLM 中复现”显式 COV”, 须先固定一个连续表示 (如末层 *hidden state* 或 *reward* 模型的连续 *score*) 并在其上引入平滑核 K_t , 才能谈 *score*、*Hessian* 与 *posterior cumulant*; 否则 G_i 只能作为抽象几何状态使用, 其 $\mathcal{R}_z$ 投影、 $g_i^{(G)} = G_i^* - G_{i-1}$ 残差、以及对局部景观的影响均退为第三类 (结构假设), 其量化须经可测诊断而非恒等式。这是 FM 与 LLM 在本框架内最重要的一处错配, 必须显式声明而非以”结构相同”掩盖。

Remark 12.4 (离散侧的绝对连续性反而更好). 须指出一处方向相反的差异: 累计势能 $B_i(c, x, t) = \log[p_{i,t}(x | c)/p_{0,t}(x | c)]$ 的良定义依赖绝对连续性 $p_i \ll p_0$ 。在 LLM 中 $z = (c, y)$ 为 token 序列上的计数测度, 绝对连续性自动成立, 故势能残差 $g_i^{(0)} = C_{i-1}[U_i^* - B_{i-1}]$ 与残差 *reward* 恒等式 $R_i/\beta_i = U_i^* - B_{i-1}$ (见 Sec. 5) 在 LLM 中作为第一类恒等式比连续图像空间更稳健——后者需借公共参考测度或平滑边缘才良定义。换言之: 势能侧在 LLM 中更干净, 几何侧在 LLM 中更隐含。两侧的层级在跨域时并不同步迁移。

12.4 一般化结论

综合以上，得到本框架的最终一般化命题。

Proposition 12.5 (全集-真子集张力的普遍性). 设任一任务满足: (i) 存在真子集关系 $D_2 \subsetneq D_1$; (ii) 先在全集 D_1 上对齐得到状态 $S_1 = (B_1, G_1)$, 再在真子集 D_2 上对齐. 则该任务必然面临低方差全集几何与高方差子集几何之间的同一抉择:

$$\mathcal{R}_S(\hat{G}_1) = G_S^* + \epsilon_{\text{proj}} + \epsilon_{\text{stat}}^{(D_1)}, \quad \hat{G}_S = G_S^* + \epsilon_{\text{stat}}^{(S)}, \quad \text{且 } \text{Var}(\hat{G}_S) \gtrsim \text{Var}(\mathcal{R}_S(\hat{G}_1)), \quad \|\epsilon_{\text{proj}}\| \text{ 可观}.$$

继承全集 *fiber* 承接 $\mathcal{R}_S(\hat{G}_1)$ (低方差、含投影偏差 ϵ_{proj}); 重建子集 *fiber* 改用 $\hat{G}_S$ (无投影偏差、统计方差 $\epsilon_{\text{stat}}^{(S)}$ 更高). 何者更优由偏差-方差-可达性-势能残差-终端目标共同决定, 不存在无条件全序最优 (与 Sec. 9、Sec. 14 的子集偏差-方差分解一致)。

Remark 12.6 (命题 12.5 的说明 (非证明, 第三类)). 偏差-方差分解 $\mathcal{R}_S(\hat{G}_1) = G_S^* + \epsilon_{\text{proj}} + \epsilon_{\text{stat}}^{(D_1)}$ 与 $\hat{G}_S = G_S^* + \epsilon_{\text{stat}}^{(S)}$ 是 Sec. 14 中已建立的 (在那里 G 的具体实例为图像 COV 几何). 本命题仅断言: 只要 G 是某个可由数据估计、可由全集向子集投影 $\mathcal{R}_S$ 限制的几何状态, 上述分解的代数形式与方差排序 $\text{Var}(\hat{G}_S) \gtrsim \text{Var}(\mathcal{R}_S(\hat{G}_1))$ (因 $|S| < |D_1|$, 子集样本更少) 即成立, 与 G 取语义共现几何、reward manifold、任务分布场还是 *KG posterior covariance* 无关. 代数成立; 但每一项的量值 ($\|\epsilon_{\text{proj}}\|$ 是否真大、 $\text{Var}(\hat{G}_S)$ 是否真高到淹没偏差收益) 是经验量, 须由 Sec. 13 的诊断量测得. 故本命题为结构性 (第三类), 不是无条件定理。

Theorem 12.7 (FM-LLM 同构与其限度). 在映射 Rem. 12.1、两阶段结构(94)-(95) 与几何实例化之下, 图像 / FM 的全集-真子集对齐与 LLM / 一般任务的全集-真子集对齐在状态递推 $S_{i+1} = F_i(S_i, u_i)$ 的层面同构. 二者的唯一结构差异在于 COV 几何的显式性:

$$\text{FM: COV 显式出现在 score Hessian } \nabla_x^2 \log q_{i,t}^D = \mathbb{E}_{\alpha_i}[H_Y] + \Sigma_i^D \text{ (第一类恒等式); LLM: COV 隐含, 结构}$$

Caveat 12.8 (同构是结构层面的, 不是恒等式层面的). Thm. 12.7 的“同构”必须严格读作第三类: 它断言两域共享同一控制结构 (同一状态空间 $\mathcal{S} = \mathcal{B} \times \mathcal{G}$ 、同一递推算子族、同一继承/重建抉择), 不断言图像侧的第一类恒等式 (Hessian 分解、残差 reward) 在 LLM 侧自动升级为恒等式. 正确的层级迁移规则是: 势能侧恒等式 ($R_i/\beta_i = U_i^* - B_{i-1}$ 、fiberwise centering C_{i-1}) 因离散绝对连续性而保持第一类 (Rem. 12.4); 几何侧 COV 结构因缺连续表示而降为第三类 (Cav. 12.3); 一切“某策略更优”的判断在两域中同为第三类, 落到可测诊断量. 把本节同构当作“LLM 中也有显式 score-Hessian COV 恒等式”来引用, 即构成 over-claiming.

13 可测诊断量、判别条件与失败模式

本节把前文 (见 Sec. 7 的复合二次型最优控制、Sec. 4 的 Hessian / COV 分解、Sec. 6 的双残差结构) 所建立的全部判别量收束为一组可测诊断: 每一个量都可由当前阶段的模型、数据与训练机制直接估计, 从而把“继承第一阶段 fiber 还是用真子集重建 fiber”这一决策落实到数字上, 而非无条件定理. 本节所有诊断量与判别条件整体标注为第三类 (empirical assumption / measurable diagnostic): 它们的定义多数来自前文的第一类恒等式或第二类局部展开, 但其作为“应继承 / 应重建 / 已失败”之阈值判据的使用, 依赖经验校准, 须由实验确定阈值与权重, 故合并降级为第三类。

Remark 13.1 (本节的层级约定). 表 2 中各诊断量的解析形式继承自其在前文的精确或近似定义; 本节不重新证明这些定义. 本节新增的内容是: 将这些量组织成一个判别系统, 并据此刻画失败模式. 该“判别 + 失败模式”系统作为整体是第三类——它给出可测的告警信号, 但把信号映射为决策的函数 (阈值、单调合成) 须经验校准. 凡引用前文近似处, 已在相应行注明其原始层级。

13.1 诊断量总表

设第一阶段（全集 D_1 ）训练完成后得到状态 $S_1 = (B_1, G_1)$ ，第二阶段目标针对真子集 $S \subsetneq D_1$ （即 $D_2 = S$, $\nu_2(dy) = \mathbf{1}_S \nu_1 / \nu_1(S)$ ）。记 G_S^* 为真子集上的目标全局 COV / posterior-cumulant 几何， U_S^* 为子集目标势能， B_1^S 为第一阶段在子集 fiber 上继承下来的累积势能， S^* 为终端目标复合状态。表 2 列出六个核心诊断量。

Table 2: 真子集对齐的可测诊断量（全部第三类：作为判据须经验校准）

诊断量	形式	解释
全集投影偏差	$\ \mathcal{R}_S(G_1) - G_S^*\ $	全集几何投影到子集后是否歪
子集估计方差	$\text{Var}(\hat{G}_S)$	真子集几何是否不稳
势能残差	$\ C[U_S^* - B_1^S]\ $	继承状态下子集还差多少
可达性	$\mathcal{L}_i$ 的谱 / χ_k	目标方向当前训练机制能否写入
重复写入强度	$\text{mass}(S \subset D_1) + \text{mass}(S \subset D_2, \text{ same fiber})$	真子集是否被同一路径二次加权
终端误差	$D_T(S_N, S^*)$	最终目标是否达成

各量的读法如下。

- 全集投影偏差 $\beta_{\text{proj}} := \|\mathcal{R}_S(G_1) - G_S^*\|$ 。此处 $\mathcal{R}_S: \mathcal{G} \rightarrow \mathcal{G}$ 是把全局几何状态限制到子集 fiber 的 restriction 算子（见 Sec. 4 的 $\mathcal{R}_z, \mathcal{R}_S$ 定义）。 β_{proj} 小，说明把全集学到的几何直接投影到 S 上与真子集目标几何吻合，继承是廉价且无偏的； β_{proj} 大，说明全集几何对 S 存在系统性偏置（bias），继承会把这种歪带进第二阶段。该量的定义为第一类（给定 G_1, G_S^* 后由范数确定），但 G_S^* 通常需估计，故实际使用时含估计误差。
- 子集估计方差 $\sigma_{\text{sub}}^2 := \text{Var}(\hat{G}_S)$ ，其中 $\hat{G}_S$ 是仅用真子集样本对 G_S 的估计。 σ_{sub}^2 度量真子集自身重建几何的统计稳定性。 $|S|$ 小或 fiber 内样本覆盖稀疏时 σ_{sub}^2 大，重建几何不可靠。这与 β_{proj} 构成经典的 bias-variance 权衡：继承吃 β_{proj}^2 的偏差、省方差；重建吃 σ_{sub}^2 的方差、去偏差（其形式化的最优折中见 Sec. 8）。
- 势能残差 $r_U := \|C[U_S^* - B_1^S]\|$ 。 $C = C_{i-1}$ 是 fiberwise centering 算子 $C_{i-1}[f](c, x) = f(c, x) - \mathbb{E}_{p_{i-1,t}(\cdot|c)}[f(c, X)]$ （消去与 caption 同变的常数偏移，只保留可由训练写入的“形状”分量）。 r_U 度量在继承第一阶段几何状态的前提下，子集目标势能 U_S^* 相对已继承势能 B_1^S 还差多少。 r_U 即复合残差中势能分量 $g_i^{(0)} = C_{i-1}[U_i^* - B_{i-1}]$ 在子集上的实例化（见 Sec. 6），其作为残差的定义为第一类。
- 可达性 $\text{Reach} := \text{spec}(\mathcal{L}_i)$ 与方向级系数 $\chi_k \in [0, 1]$ 。 $\mathcal{L}_i$ 是带岭收缩 λ_i 的线性响应算子（ridge-regularized linear response operator），不是投影；仅在 $\lambda_i \rightarrow 0$ 、闭值域、固定 metric 的极限下其行为退化为正交投影 Π （见 Sec. 7）。 $\mathcal{L}_i$ 的谱刻画各方向被一步更新放大/衰减的比率；方向级可达性 χ_k 把“第 k 个目标方向能否被当前训练机制写入”量化到 $[0, 1]$ ，受数据覆盖、LoRA rank、target modules、NTK/Fisher 谱、metric M_i 与 λ_i 共同影响。 $\chi_k \approx 0$ 的方向，无论残差多大都写不进去——这是机制性约束，不靠加大步长 η_i 解决。
- 重复写入强度 $w_{\text{rep}} := \text{mass}(S \subset D_1) + \text{mass}(S \subset D_2, \text{ same fiber})$ 。真子集 S 既在第一阶段作为 D_1 的一部分被训练过，又在第二阶段作为 D_2 被训练；若两次落在同一 fiber（同一 T_i 标签路径），则 S 沿同一方向被二次加权。 w_{rep} 大意味着该 fiber 的有效学习率被隐式放大，是低频背诵（memorization）与过度集中的早期指标。该量为可直接由数据计数得到的第三类诊断。
- 终端误差 $D_T(S_N, S^*)$ 。在复合状态空间 $\mathcal{S} = \mathcal{B} \times \mathcal{G}$ 上的终端距离（ D_T 为该空间上选定的二次型 / Bregman 型偏差度量，见 Sec. 7），度量经过 N 步递推后的状态 S_N 与终端目标 S^* 的差距。这是唯一直接对应“最终目标是否达成”的量；前五个诊断是过程量， $D_T(S_N, S^*)$ 是结果量。注意 D_T 同时含势能分量 B 与几何分量 G ，故“几何对齐”不蕴含“终端对齐”——这一点在下节失败模式 (iv) 中关键。

Remark 13.2 (判别条件的合成). 继承 *vs.* 重建的判别可写为: 当 $\beta_{\text{proj}}^2 \lesssim \sigma_{\text{sub}}^2$ 且 r_U 小且目标方向 χ_k 充分时, 继承 (吃小偏差、省方差、残差可写入); 当 $\beta_{\text{proj}}^2 \gtrsim \sigma_{\text{sub}}^2$ 且 σ_{sub}^2 可控时, 重建 (去掉系统性投影偏差)。该合成规则中的 “ $\lesssim$ ” 阈值与各量权重为经验校准对象, 故整条规则为第三类。其 *bias-variance* 形式化基础见 Sec. 8。

13.2 失败模式

下列失败模式各对应表 2 中某一诊断越界而仍执行错误决策的后果。每一条均给出触发该模式的诊断签名, 使其可测、可预警。

- (i) 投影偏差大仍继承 $\Rightarrow$ 稳定但错误绑定。 诊断签名: $\beta_{\text{proj}} = \|\mathcal{R}_S(G_1) - G_S^*\|$ 大, 却因 σ_{sub}^2 大 (子集样本少) 而选择继承。结果: 训练在数值上稳定 (方差小、loss 平滑), 但子集几何被锁定到全集的歪投影上, 形成稳定的错误绑定——caption 与目标几何之间建立了一致但偏置的对应。表现为子集内细类被全集主导风格 “拉平”, 且因稳定性高而难以察觉。
- (ii) 子集方差大强行重建 $\Rightarrow$ 低频背诵 / **reward hacking** / 纹理漂移。 诊断签名: $\sigma_{\text{sub}}^2 = \text{Var}(\hat{G}_S)$ 大 (且常伴 w_{rep} 大), 却强行用真子集重建 fiber。结果: 在样本不足的几何上拟合高频细节, 触发三类典型病态——低频背诵 (模型记住少数样本的低频结构而非泛化)、*reward hacking* (沿被二次加权的同一 fiber 把 reward R_i 推高而不改善真实目标)、以及纹理漂移 (高方差方向上的几何估计随训练步漂移, 纹理统计逐步偏离目标)。 w_{rep} 大会放大全部三者, 因为同一路径的二次加权进一步抬高有效学习率。
- (iii) 可达性不足 $\Rightarrow$ 细节学不到 / 被平均化。 诊断签名: 目标方向上 $\chi_k \approx 0$, 或 $\mathcal{L}_i$ 在该方向谱值近零 ($\text{spec}(\mathcal{L}_i)$ 在该方向附近趋零)。结果: 无论残差 r_U 多大、步长 η_i 多大, 目标方向都写不进当前训练机制 (LoRA rank 不足、target modules 未覆盖、metric M_i 或岭 λ_i 压制了该方向)。细节学不到, 残差被投影到可达子空间后被平均化到邻近可达方向, 表现为目标特征 “糊掉”。此模式不能靠加大 η_i 修复, 须改 control u_i 中的 $\mathcal{H}_i$ (LoRA / target modules) 或 λ_i, M_i 。
- (iv) 终端势能未对齐 $\Rightarrow$ 几何看似改善但推理不指向目标。 诊断签名: 几何分量距离小 ($\|\mathcal{R}_S(G_N) - G_S^*\|$ 已降), 但终端误差 $D_T(S_N, S^*)$ 的势能分量大 (即 r_U 未收敛)。结果: COV / 几何状态看似已对齐, 采样几何 “像” 目标, 但累积势能 B_N 未对齐 U_S^* , 故条件分布的众数 / 推理方向不指向真子集目标。表现为 “风格 / 结构对、内容 / 语义错”。根因是 $S = (B, G)$ 两分量须联合对齐, 单看 G 会漏掉 B 。
- (v) 局部贪心 $\Rightarrow$ 每步 loss 好看但破坏未来结构、多步总目标下降。 诊断签名: 单步 $\eta_i \mathcal{L}_i \mathbf{g}_i$ 使当前 loss 显著下降, 但若干步后 $D_T(S_N, S^*)$ 反升。结果: 逐步最小化即时残差 (贪心) 会破坏后续阶段所依赖的状态结构——全局几何 G 、累积势能 B 、条件 Hessian H_Y 、metric M 之间的相容性被打乱, 使后续步的可达性与残差几何恶化。这正是 Sec. 7 把问题写成多步最优控制 (Bellman / minmax) 而非逐步最小化的理由: 单步最优 $\neq$ 终端最优, 须以 $D_T(S_N, S^*)$ 为目标做前瞻规划。

Caveat 13.3 (诊断的可测性边界). 表 2 中 $\beta_{\text{proj}}, r_U, D_T$ 均依赖目标量 (G_S^*, U_S^*, S^*), 它们在实践中需用 *held-out* 子集数据或参考模型估计, 故诊断含其自身的估计误差; σ_{sub}^2 须用重采样 / *bootstrap* 估计; χ_k 与 $\text{spec}(\mathcal{L}_i)$ 须用 *NTK* / *Fisher* 谱或方向探针估计。因此本节的告警是条件可测——在给定估计协议下可测。这正是整节标注为第三类、而非把判别条件升格为定理的原因: 缺少对目标量估计无偏性的额外假设, 任一诊断的越界判定都不能无条件成立。失败模式 (i)–(v) 应理解为可被这些诊断预警的风险, 而非由诊断必然推出的结论。

14 形式化命题与推论

本节把前文 (Sec. 5 的残差势能、Sec. 4 的 Hessian 分解、Sec. 8 的偏差-方差结构、Sec. 10 的纤维继承/重建) 整理为带显式假设、证明梗概与层级标注的编号结论。原讨论稿在多处用 “ $\approx$ ” 或未定义算子 ($\mathcal{R}_z, A_S, \delta_B$) 掩盖了逻辑跳步; 下文凡涉及此类跳步, 均以

Caveat 14.1. 或

Remark 14.2. 命名所缺假设并补全。层级标注沿用全文约定：第一类为精确恒等式，第二类为局部二阶近似（需声明线性化/小步长/局部性假设），第三类为经验假设或可测诊断。

14.1 残差势能与数据场曲率（精确结构）

Proposition 14.3 (残差势能递推). (第一类。) 设第 i 阶段目标分布 $q_i^*(\cdot | c)$ 与当前模型 $p_{i-1,t}(\cdot | c)$ 在同一基座 $p_{0,t}(\cdot | c)$ 上以累积势能表示，即 $U_i^*(c, x, t) = \log \frac{q_i^*(x|c)}{p_{0,t}(x|c)}$, $B_{i-1}(c, x, t) = \log \frac{p_{i-1,t}(x|c)}{p_{0,t}(x|c)}$ 。若第 i 阶段采用 *KL-RLHF* 的 *Gibbs* 闭式解，并以当前模型 $p_{i-1,t}$ 为 *reference*（而非以基座为 *reference*），则 *ideal reward* R_i 与逆温度 β_i 满足精确恒等式

$$\frac{R_i(c, x, t)}{\beta_i} = U_i^*(c, x, t) - B_{i-1}(c, x, t) \quad (\text{up to a } c\text{-only constant}). \quad (96)$$

在条件模型中，经 *fiberwise* 中心化算子 $C_{i-1}[f](c, x) = f(c, x) - \mathbb{E}_{p_{i-1,t}(\cdot|c)}[f(c, X)]$ 吸收仅依赖 c 的规范自由度后，势能残差

$$g_i^{(0)} = C_{i-1}[U_i^* - B_{i-1}] \quad (97)$$

为良定义（即对 $U_i^* \mapsto U_i^* + \phi(c)$ 不变）。

证明梗概. *Gibbs* 解 $q_i^* \propto p_{i-1,t} \exp(R_i/\beta_i)$ 对 x 取对数: $\log q_i^* = \log p_{i-1,t} + R_i/\beta_i - \log Z_i(c, t)$ 。两端各减 $\log p_{0,t}$ 得 $U_i^* = B_{i-1} + R_i/\beta_i - \log Z_i(c, t)$ ，移项即(96)；其中 $\log Z_i(c, t)$ 仅依赖 (c, t) ，故为 c -only 常数。该常数在条件 fiber 上不影响 ∇_x ，且被中心化算子精确消去：对任意 $\phi(c)$ 有 $C_{i-1}[\phi] = \phi - \mathbb{E}_{p_{i-1,t}(\cdot|c)}[\phi] = 0$ 。故(97) 与规范选择无关。□

Remark 14.4. (96) 是精确变分结构而非近似：其唯一前提是目标取 *Gibbs* 形式且 *reference* 取当前模型 $p_{i-1,t}$ 。若误取基座 $p_{0,t}$ 为 *reference*，则右端退化为 U_i^* （丢失已累积的 B_{i-1} ），这正是原稿在“第二阶段面对的 *residual* 是 $U_S^* - B_1^S$ 而非 $U_S^* - B_0$ ”一处强调的路径依赖来源（见 *Sec. 8*）。

Proposition 14.5 (数据场 Hessian 分解). (第一类。) 设阶段数据密度由隐变量混合给出， $q_{i,t}^D(x | c) = \int q_t(x | y) \nu_i(dy | c)$ ，其中 $q_t(x | y)$ 关于 x 二次连续可微且可在积分号下两次求导。记条件 *score* $s_y = \nabla_x \log q_t(x | y)$ 、条件 *Hessian* $H_Y = \nabla_x^2 \log q_t(x | y)$ 、*posterior responsibility* $\alpha_i(y | x, c, t) = q_t(x | y) \nu_i(dy | c) / q_{i,t}^D(x | c)$ 、混合 *score* $s_i^D = \mathbb{E}_{\alpha_i}[s_Y]$ 。则

$$\nabla_x^2 \log q_{i,t}^D(x | c) = \mathbb{E}_{\alpha_i}[H_Y] + \text{Cov}_{\alpha_i}(s_Y) \quad (98)$$

其中 $\text{Cov}_{\alpha_i}(s_Y) = \mathbb{E}_{\alpha_i}[(s_Y - s_i^D)(s_Y - s_i^D)^\top] = \Sigma_i^D$ 为 *posterior score covariance*（即 COV 几何的局部形）。

证明梗概. 对 $\log q_{i,t}^D = \log \int q_t(x | y) \nu_i(dy | c)$ 一次求导得 $\nabla_x \log q_{i,t}^D = \mathbb{E}_{\alpha_i}[s_Y] = s_i^D$ （*responsibility* 即 Radon-Nikodym 权重）。再求导，对 $s_i^D = \int s_y \alpha_i dy$ 用乘积法则： $\nabla_x s_i^D = \int (\nabla_x s_y) \alpha_i dy + \int s_y (\nabla_x \alpha_i)^\top dy$ 。第一项为 $\mathbb{E}_{\alpha_i}[H_Y]$ ；由 $\nabla_x \alpha_i = \alpha_i(s_y - s_i^D)$ （对 α_i 取对数求导），第二项为 $\mathbb{E}_{\alpha_i}[s_Y(s_Y - s_i^D)^\top] = \text{Cov}_{\alpha_i}(s_Y)$ （因 $\mathbb{E}_{\alpha_i}[s_i^D(s_Y - s_i^D)^\top] = 0$ ）。合并即(98)。详见 *Sec. 4* 的 Hessian 分解。□

Remark 14.6. (98) 表明数据异质性真实进入目标景观曲率：交叉项 $\text{Cov}_{\alpha_i}(s_Y) \succeq 0$ 恒为半正定，故混合总使曲率不低于条件 *Hessian* 的 *posterior* 平均。多画师/多角色/多衣服在抬升 $\mathbb{E}_{\alpha_i}[H_Y]$ 稳定性的同时，可能因子场 *score* 方向相悖而放大 Σ_i^D ——这是 *Sec. 9* 中“大合集 *LoRA* 平均化”现象的曲率根源。

14.2 全集-真子集的偏差-方差分解

Proposition 14.7 (全集-真子集偏差-方差分解). (第二类 / 可测。) 设 $D_2 = S \subsetneq D_1$, 全局几何状态 $G \in \mathcal{G}$, 限制算子 $\mathcal{R}_S : \mathcal{G} \rightarrow \mathcal{G}$ 把全集几何投影到子集 *fiber*, G_S^* 为子集真实目标几何。在如下假设下:

- (A1) 估计无偏性: $\mathbb{E}[\hat{G}_1] = G_1^*$ 、 $\mathbb{E}[\hat{G}_S] = G_S^*$ (各自数据下的统计估计渐近无偏);
- (A2) 投影偏差可加性: $\mathcal{R}_S(G_1^*) = G_S^* + \varepsilon_{\text{proj}}$, $\varepsilon_{\text{proj}}$ 为确定性投影偏差, 源于全集几何不能精确还原子集几何;
- (A3) 误差小量线性化: $\mathcal{R}_S$ 在 G_1^* 邻域可线性化, 估计涨落 $\hat{G}_1 - G_1^*$ 经 $\mathcal{R}_S$ 传播的高阶项可略。

则全集投影路径与子集重估路径分别满足

$$\mathcal{R}_S(\hat{G}_1) = G_S^* + \varepsilon_{\text{proj}} + \varepsilon_{\text{stat}}^{(D_1)}, \quad (99)$$

$$\hat{G}_S = G_S^* + \varepsilon_{\text{stat}}^{(S)}, \quad (100)$$

其中 $\varepsilon_{\text{stat}}^{(D_1)} = \mathcal{R}_S(\hat{G}_1 - G_1^*)$ 、 $\varepsilon_{\text{stat}}^{(S)} = \hat{G}_S - G_S^*$ 为统计涨落。由 $|S| < |D_1|$ 通常有 $\text{Var}(\varepsilon_{\text{stat}}^{(S)}) \gtrsim \text{Var}(\varepsilon_{\text{stat}}^{(D_1)})$ 而 $\mathbb{E}[\varepsilon_{\text{proj}}] \neq 0$ 仅出现在(99)。故继承(投影) = 低方差/保留偏差 $\varepsilon_{\text{proj}}$; 重建(重估) = 低偏差/高方差。

证明梗概. (99): 由 (A2) 写 $\mathcal{R}_S(\hat{G}_1) = \mathcal{R}_S(G_1^*) + \mathcal{R}_S(\hat{G}_1 - G_1^*) = G_S^* + \varepsilon_{\text{proj}} + \varepsilon_{\text{stat}}^{(D_1)}$, 末步用 (A3) 的线性化. (100): 由 (A1) 直接得。方差比较: 在每点估计方差随样本量约 $\propto 1/N$ 的标准假设下, $N_S = |S| < N_{D_1} = |D_1|$ 给出 $\text{Var}(\varepsilon_{\text{stat}}^{(S)}) \gtrsim \text{Var}(\varepsilon_{\text{stat}}^{(D_1)})$ 。两式相减即得偏差-方差对照。 $\square$

Caveat 14.8. 原稿写 $B_1^S \approx A_S(\mathcal{R}_S(G_1), D_1)$ 与 $B_1^S = B_S^* + \delta_B(\varepsilon_{\text{proj}}) + \delta_B(\varepsilon_{\text{stat}}^{(D_1)})$, 但 A_S 、 δ_B 均未定义, 构成跳步。本节将其严格收窄为: 势能估计算子 A_S 满足偏差传导一阶可微假设——存在线性映射 $\delta_B = \partial A_S / \partial G|_{G_S^*}$, 使几何误差经 A_S 传到势能的领头项为 $\delta_B(\varepsilon_{\text{proj}}) + \delta_B(\varepsilon_{\text{stat}}^{(D_1)})$ 。此为第二类近似(一阶 *Taylor*), 其有效性要求 $\varepsilon_{\text{proj}}, \varepsilon_{\text{stat}}$ 落在 A_S 的线性响应域内; 超出则(99)–(100)向势能层的传导不再加性可分。

14.3 策略最优性的条件结构

Corollary 14.9 (fiber 策略无条件最优不存在). (第三类。) 设两种纤维策略: 继承 *inherit* ($c_S^{(2)} = c_S^{(1)}$, 势能残差 J_{inh}) 与重建 *rebuild* ($c_S^{(2)} \neq c_S^{(1)}$, 势能残差 J_{reb}), 残差能量统一写为 $J \approx \langle (\text{id} - \eta_i \mathcal{L}_i) \mathbf{g}_i, Q_i (\text{id} - \eta_i \mathcal{L}_i) \mathbf{g}_i \rangle$ ($Q_i \succeq 0$)。若不指定 (i) 子集样本量 $|S|$ 、(ii) 投影误差 $\varepsilon_{\text{proj}}$ 量级、(iii) 可达性 ($\mathcal{L}_i$ 在 $\mathcal{H}_i$ 上的 *reachability*)、(iv) 正则强度 λ_i 、(v) 终端目标 $S^\dagger$, 则在 $\{\text{inherit}, \text{rebuild}\}$ 上不存在与上述变量无关的全序最优: 即不存在使 $J_{\text{inh}} \leq J_{\text{reb}}$ (或反向) 对所有配置一致成立的无条件定理。

证明梗概. 构造两个反向情形即证。情形甲: $\varepsilon_{\text{proj}}$ 大而 $|S|$ 充足、可达性高, 则由 Prop. 14.7, 重建消去 $\varepsilon_{\text{proj}}$ 而引入的 $\varepsilon_{\text{stat}}^{(S)}$ 受控, 得 $J_{\text{reb}} < J_{\text{inh}}$ 。情形乙: $\varepsilon_{\text{proj}}$ 小而 $|S|$ 极少、 $\hat{G}_S$ 方差高、可达性低, 则重建抬升 $\mathbf{g}_i$ 的几何残差且 $\mathcal{L}_i$ 写入受阻, 得 $J_{\text{inh}} < J_{\text{reb}}$ 。两情形并存即否定无条件全序; 最优只能是 Pareto / Bellman 型条件最优 (见 Sec. 7 的 Bellman 递推)。 $\square$

Remark 14.10. 判别落到可测充要式: *rebuild* 正收益 $\iff$ 偏差下降量 $>$ 方差增量 + 可达性损失 + 额外势能高度 (对应 $J_{\text{reb}} < J_{\text{inh}}$)。这是诊断条件而非定理, 量纲与测量见 Sec. 13。

Corollary 14.11 (楼塔收益条件). (第二类。) 固定方向 k (某可达基方向), 设该方向上的逐方向残差能量为 $(1 - \eta \chi_k(\mathcal{R}_z(G)))^2 (g_k^{(0)})^2$, 其中 $\mathcal{R}_z(G) = \Sigma^{\text{loc}}(z)$ 是全局几何 G 在点 $z = (c, x, t)$ 的局部限制, $\chi_k(\mathcal{R}_z(G)) \in [0, 1]$ 是 $\mathcal{L}_i$ 在方向 k 上的 *reachability* 系数 (随 $\mathcal{R}_z(G)$ 在该方向 *better-conditioned* 而单调递增), η 为步长, $g_k^{(0)}$ 为该方向的势能残差分量 (即 “目标高度”)。在

小步长线性响应假设（ $\mathcal{L}_i$ 局部线性、 χ_k 对 G 一阶可微）下，一个抬高目标复杂度的策略仍可净收益，其充分条件为该策略引起的变化满足

$$\Delta \left[(1 - \eta \chi_k(\mathcal{R}_z(G)))^2 (g_k^{(0)})^2 \right] < 0 \quad (101)$$

即使其中 $\Delta[(g_k^{(0)})^2] > 0$ （目标变高）亦可成立。

证明梗概. 对(101) 左端按乘积法则取一阶变分。记 $a = (1 - \eta \chi_k)^2$ 、 $b = (g_k^{(0)})^2$ ，则 $\Delta(ab) = a \Delta b + b \Delta a + o(\cdot)$ 。其中 $\Delta a = 2(1 - \eta \chi_k) \cdot (-\eta) \Delta \chi_k$ ，而由链式法则 $\Delta \chi_k = \chi'_k(\mathcal{R}_z(G)) \mathcal{R}_z(\Delta G)$ 。故全局 COV 改善（ ΔG 使 $\mathcal{R}_z(G)$ 在方向 k 更 well-conditioned） $\Rightarrow \Delta \chi_k > 0 \Rightarrow \Delta a < 0$ 。只要 $b|\Delta a| > a \Delta b$ ，即地基抬升带来的残差税下降超过目标变高带来的残差上升，(101) 成立。□

Remark 14.12 (逻辑链显式化). 楼塔条件的因果链须逐环讲清，避免原稿“地基升得多就赚”的口语跳步：

1. 全局 COV 几何改善： $G \rightarrow G'$ 使 *posterior score covariance* 更稳定；
2. 经局部限制传导： $\mathcal{R}_z(G) = \Sigma^{\text{loc}}(z)$ 在方向 k 上 *better-conditioned*（条件数下降）；
3. *reachability* 上升：训练算子 $\mathcal{L}_i$ 在该方向更易写入， $\chi_k(\mathcal{R}_z(G)) \uparrow$ ；
4. 逐方向残差税下降：残差因子 $(1 - \eta \chi_k)^2 \downarrow$ （因 $\chi_k \rightarrow$ 较大值使 $1 - \eta \chi_k$ 趋小）；
5. 净残差可降：即便目标高度 $(g_k^{(0)})^2 \uparrow$ （楼变高），只要因子下降占优，逐方向残差能量 $(1 - \eta \chi_k)^2 (g_k^{(0)})^2$ 仍下降。

一句话：楼变高不一定坏；只要脚下地面升得更多（*reachability* 抬升带来的残差税下降超过目标高度的上升），就是赚。

Caveat 14.13. (101) 是逐方向（*fixed k*）的第二类局部判据，依赖三项假设，缺一则结论失效：(i) $\mathcal{L}_i$ 的局部线性响应（小步长 η ，使一阶变分主导， $o(\cdot)$ 可略）；(ii) χ_k 对 $\mathcal{R}_z(G)$ 单调且一阶可微（COV 改善确能单调传为 *reachability* 上升）；(iii) $\eta \chi_k < 1$ （残差因子非负且未越过临界，否则 $1 - \eta \chi_k$ 变号、过冲使能量回升）。跨方向求和 $\sum_k$ 时还需 Q_i 在该基近似对角，否则不同方向的耦合项不可逐项分解——此即 *Sec. 9* 中异质 COV 导致大合集“平均化/糊化”的机制。

15 术语表、参考文档与公式总览

本节汇总全文使用的核心术语、所依据的两篇前置文档，以及把各节结论压缩为一处的公式总览附录。术语表（*Table 3*）给出每个对象的最简定义，其严格定义与所需假设见对应正文章节；公式总览仅复述已在正文中证明或假设的关系式，并对每条标注其层级（第一类精确恒等式 / 第二类局部二阶近似 / 第三类经验假设），不在此处引入新结论。

15.1 术语表

15.2 参考文档

本理论建立在以下两篇前置文档之上：本文的状态递推框架可视为二者在“全集-真子集两阶段对齐”场景下的合流。

- 文档一：《多阶段对齐的残差势能投影框架：从 *KL-RLHF* 闭式解到 *Posterior Cumulant* 景观递推》（即本仓库 *11_rlhf_interaction_theory*）。提供累计势能 B_i 、残差 *reward* R_i 、条件 *fiber*、可达投影 Π （作为 $\mathcal{L}_i$ 在 $\lambda_i \rightarrow 0$ 闭值域定度量极限下的特例）、路径依赖，以及 *posterior cumulant landscape recursion*——即本文核心状态递推 $S_{i+1} = F_i(S_i, u_i)$ 的势能分量来源。
- 文档二：《动力学几何与流匹配：经验数据场分解与复合二次型能量》。提供经验测度正则化、*posterior responsibility* α_i 、*score / Hessian* 分解（ s_Y, H_Y ）、*posterior score covariance* Σ_i^D 、多阶 *cumulant tower*，以及 *Flow Matching* 复合二次型能量——即本文全局 COV 几何分量 G_i 与复合残差 $\mathbf{g}_i$ 的来源。

Table 3: 核心术语与含义。严格定义见各节正文；本表仅作参考。

术语	含义
B_i	第 i 阶段后模型相对基座的累计势能 $B_i(c, x, t) = \log[p_{i,t}(x c)/p_{0,t}(x c)]$ ，是势能空间 $\mathcal{B}$ 中的元素（见 Sec. 5）。
G_i	第 i 阶段后模型学到的全局 COV / 数据场几何，即全局几何状态 $G_i \in \mathcal{G}$ ；其在点 $z = (c, x, t)$ 处的局部二阶形式由 $\mathcal{R}_z(G_i) = \Sigma_i^{\text{loc}}(z)$ 给出（见 Sec. 4）。
COV 场	posterior score covariance $\Sigma_i^D = \text{Cov}_{\alpha_i}(s_Y)$ ，刻画同一条件 c 下不同隐变量子场 y 的 score s_y 之间的干涉与交叉协方差几何（始终指 covariance，绝非卷积，见 Sec. 4）。
fiber	条件化路径，即把控制 $u_i = (\nu_i, T_i, \dots)$ 固定后由标签映射 T_i 与可达子空间 $\mathcal{H}_i$ 诱导的条件结构，例如人物标签、任务标签、adapter route、reward head（见 Sec. 10）。
继承 fiber	第二阶段沿用第一阶段子集的条件化路径（同一 $T_i, \nu_i _S, \mathcal{H}_i$ ），其抽象含义为低 variance、低残差、强先验、低优化压力，代价是保留全集投影偏差（见 Sec. 9、Sec. 10）。
重建 fiber	第二阶段为真子集 S 换一条条件化路径或重新定义子集对齐路线（改写 $T_i, \mathcal{H}_i$ 或用 ν_2 重估几何），其抽象含义为低 bias、高上限、可逃离旧绑定，代价是高 variance、高残差、对可达性与数据质量更敏感（见 Sec. 9、Sec. 10）。
投影偏差	全集几何经限制算子投影到真子集后与真子集真实几何之间的偏差 $\varepsilon_{\text{proj}} = \mathcal{R}_S(G_1) - G_S^*$ （见 Sec. 9 的 $\mathcal{R}_S$ 分解）。
子集方差	真子集 S 样本少导致的 COV / 数据场估计不稳定，记为统计误差 $\varepsilon_{\text{stat}}^{(D_1)}$ 等统计涨落项（见 Sec. 8、Sec. 9）。
可达性 (reachability)	当前模型、LoRA 子空间 $\mathcal{H}_i$ 、优化器与正则（度量 M_i 、ridge λ_i 、步长 η_i ）能够把目标方向写入势能的程度，由线性响应算子 $\mathcal{L}_i$ 在 $\mathcal{H}_i$ 上的有效增益刻画（见 Sec. 7、Sec. 10）。

15.3 公式总览

以下按对象生成顺序复述全文已建立的关系式，并标注层级。除特别说明外，期望下标 $\alpha = \alpha_i(y|x, c, t)$ ， C_{i-1} 为关于 $p_{i-1,t}(\cdot|c)$ 的 *fiberwise centering* 算子。

(A) 数据场与 **posterior** 几何（第一类，精确恒等式）。由定义直接成立的边缘化、*Bayes* 权与一、二阶 *score* 恒等式（见 *Sec. 3*、*Sec. 4*）。先是不含标签的 N 阶纯图像分布：

$$\begin{aligned} q_{i,t}^{D,N}(x) &= \int q_t(x|y_{1:N}) \nu_i^{(N)}(dy_{1:N}), \\ \bar{\alpha}_i^{(N)}(dy_{1:N}|x, t) &= \frac{q_t(x|y_{1:N}) \nu_i^{(N)}(dy_{1:N})}{q_{i,t}^{D,N}(x)}, \\ \Sigma_i^{D,N}(x, t) &= \text{Cov}_{\bar{\alpha}_i^{(N)}}(s_{Y^{(N)}}), \\ \nabla_x^2 \log q_{i,t}^{D,N}(x) &= \mathbb{E}_{\bar{\alpha}_i^{(N)}}[H_{Y^{(N)}}] + \Sigma_i^{D,N}(x, t). \end{aligned}$$

三阶画师-人物-衣服特例为

$$\begin{aligned} q_{i,t}^{D,APW}(x) &= \int \bar{q}_{i,t}(x|a, p, w) \nu_i^{APW}(da, dp, dw), \\ \Sigma_i^{APW}(x, t) &= \text{Cov}_{\alpha_i^{APW}}(s_{A,P,W}), \\ \Sigma_i^{APW} &= \text{Cov}_{\alpha(A)}(\mu_A) + \mathbb{E}_{\alpha(A)}[\text{Cov}_{\alpha(P|A)}(\mu_{A,P})] + \mathbb{E}_{\alpha(A,P)}[\text{Cov}_{\alpha(W|A,P)}(s_{A,P,W})]. \end{aligned}$$

引入 *caption* 后，条件版本为：

$$\begin{aligned} q_{i,t}^D(x|c) &= \int q_t(x|y) \nu_i(dy|c), \\ \alpha_i(y|x, c, t) &= \frac{q_t(x|y) \nu_i(dy|c)}{\int q_t(x|y') \nu_i(dy'|c)}, \\ s_i^D &= \mathbb{E}_\alpha[s_Y], \\ \Sigma_i^D &= \text{Cov}_\alpha(s_Y) = \mathbb{E}_\alpha[(s_Y - s_i^D)(s_Y - s_i^D)^\top], \\ \nabla_x^2 \log q_{i,t}^D &= \mathbb{E}_\alpha[H_Y] + \Sigma_i^D. \end{aligned}$$

最后一式即 *conditional Hessian* 的“期望 *Hessian* 加 *posterior score covariance*”分解，是第一类恒等式（ $H_Y = \nabla_x^2 \log q_t(x|y)$ 为条件对数密度 *Hessian*，与可达子空间 $\mathcal{H}_i$ 是不同对象）。

(B) 势能与残差（第一类，定义恒等式）。累计势能、势能残差与全局 COV 残差，以及二者堆叠成的复合残差（见 *Sec. 5*、*Sec. 6*）：

$$\begin{aligned} B_i &= \log(p_{i,t}/p_{0,t}), \\ g_i^{(0)} &= C_{i-1}[U_i^* - B_{i-1}], \\ g_i^{(G)} &= G_i^* - G_{i-1}, \\ \mathbf{g}_i &= (g_i^{(0)}, \sqrt{\rho_G} g_i^{(G)}). \end{aligned}$$

其中 $U_i^*(c, x, t) = \log(q_i^*(x|c)/p_{0,t}(x|c))$ 为目标势能， $\rho_G \geq 0$ 为几何分量的相对权重。这些均为定义层面的恒等式（第一类）。

(C) 状态递推（第二类，局部二阶近似）。复合状态 $S_i = (B_i, G_i) \in \mathcal{S} = \mathcal{B} \times \mathcal{G}$ 的单步更新（见 *Sec. 2*、*Sec. 7*）：

$$S_{i+1} = S_i + \eta_i \mathcal{L}_i(S_i, u_i) \mathbf{g}_i + E_i.$$

Caveat 15.1. 此式为第二类结论。它依赖于：(i) 小步长 η_i 下对训练映射的一阶线性化，使响应由 *ridge* 正则的线性响应算子 $\mathcal{L}_i$ （度量 M_i 、*ridge* λ_i ）刻画； $\mathcal{L}_i$ 不是投影，仅在 $\lambda_i \rightarrow 0$ 、闭值域、定度量极限下退化为正交投影 Π 。(ii) 局部性： $\mathbf{g}_i$ 在更新邻域内近似不变。高阶项与建模误差被收进 E_i ；其有界性与方差控制属第三类经验假设（见 *Sec. 8*）。

(D) 最优控制值函数（第二类，**minmax Bellman**）。对抗扰动 ζ 下的 *Bellman* 递推（见 *Sec. 7*）：

$$V_i(S) = \inf_u \sup_{\zeta} \left\{ \langle r_i, Q_i r_i \rangle + V_{i+1}(F_i(S, u, \zeta)) \right\}.$$

此为复合二次型代价下的 *minmax* 动态规划（第二类），其有效性建立在 (C) 的状态递推近似与二次型局部代价 $\langle r_i, Q_i r_i \rangle$ 之上； r_i 为终端残差， $Q_i \succeq 0$ 为代价度量。 $\inf_u \sup_{\zeta}$ 与 $\sup_{\zeta} \inf_u$ 互换（从而存在鞍点）需 *Sion minmax* 条件：代价对 u 拟凸、对 ζ 拟凹，且控制域与扰动域之一为紧凸——此为局部二次化近似下的标准假设（见 *Sec. 7*）。

(E) 全集 $\rightarrow$ 真子集限制与子集势能（第三类，经验分解假设）。对 $S = D_2 \subsetneq D_1$ ，全集几何经限制算子 $\mathcal{R}_S$ 投到子集，以及第一阶段子集势能的对应分解（见 *Sec. 9*）：

$$\begin{aligned} \mathcal{R}_S(G_1) &= G_S^* + \varepsilon_{\text{proj}} + \varepsilon_{\text{stat}}^{(D_1)}, \\ B_1^S &= B_S^* + \delta_B(\varepsilon_{\text{proj}}) + \delta_B(\varepsilon_{\text{stat}}^{(D_1)}). \end{aligned}$$

Remark 15.2. 此两式为第三类结论。 $\varepsilon_{\text{proj}}$ （投影偏差）与 $\varepsilon_{\text{stat}}^{(D_1)}$ （子集统计方差）是可测诊断量而非零； $\delta_B(\cdot)$ 是把几何误差搬运到势能误差的（在 *Caveat 15.1* 同款线性化下的）一阶灵敏度算子。因此 B_1^S 是“全集几何投到 S 后的稳定但可能有偏的势能估计”，第二阶段是否值得用 $\nu_2 = \mathbf{1}_S \nu_1 / \nu_1(S)$ 重建 *fiber*，取决于重估降低的 $\varepsilon_{\text{proj}}$ 是否超过其引入的 *variance*、可达性损失与额外势能高度——此为本文判据，不构成无条件全序最优（见 *Sec. 8*、*Sec. 11*）。